



*Centre universitari adscrit a la*



**Universitat  
Pompeu Fabra**  
*Barcelona*

**Grau en Enginyeria Informàtica de Gestió i Sistemes  
d'Informació**

**APRENTATGE AUTOMÀTIC APLICAT A  
BIOINFORMÀTICA**

**Memòria**

**Martí Rivero Garcia**  
**Tutor: Carles Bonet Papell**

2025/2026





## **Agraïments**

Vull expressar el meu agraïment al tutor del Treball Final de Grau, Carles Bonet Papell, per l'acompanyament, la disponibilitat i les orientacions aportades al llarg del desenvolupament del projecte. El seu seguiment ha estat de gran ajuda per enfocar correctament el treball i afrontar les diferents decisions tècniques amb més criteri i claredat.

## **Abstract**

This project develops a reproducible analytical pipeline to classify Consensus Molecular Subtypes (CMS) in colorectal cancer from RNA-seq gene expression data using machine learning. It is based on previously processed public datasets, such as those from The Cancer Genome Atlas. The goal is not to create new models, but to provide a controlled framework for comparing algorithms under homogeneous preprocessing conditions. The project emphasizes transparency, reproducibility and methodological clarity.

## **Resum**

Aquest treball desenvolupa un pipeline analític reproduïble per classificar els subtipus moleculars CMS del càncer colorectal a partir de dades RNA-seq mitjançant tècniques d'aprenentatge automàtic. El projecte es basa en dades públiques prèviament processades, com les de The Cancer Genome Atlas. L'objectiu no és crear nous models, sinó establir un entorn controlat per comparar algorismes sota condicions homogènies de preprocessament. El treball posa l'accent en la transparència, la reproductibilitat i la claredat metodològica.

## **Resumen**

Este trabajo desarrolla un pipeline analítico reproducible para clasificar los subtipos moleculares CMS del cáncer colorrectal a partir de datos RNA-seq mediante técnicas de aprendizaje automático. El proyecto se basa en datos públicos previamente procesados, como los de The Cancer Genome Atlas. El objetivo no es crear nuevos modelos, sino establecer un entorno controlado para comparar algoritmos bajo condiciones homogéneas de preprocesamiento. El trabajo pone el acento en la transparencia, la reproducibilidad y la claridad metodológica.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

# Índex

|                                                                          |   |
|--------------------------------------------------------------------------|---|
| Índex.....                                                               | 2 |
| Índex de figures .....                                                   | 2 |
| 1. Objecte del projecte.....                                             | 2 |
| 2. Estat de l'art.....                                                   | 2 |
| 2.1 Marc teòric del càncer colorectal i dels subtipus CMS .....          | 2 |
| 2.1.1. Conceptes generals del càncer colorectal.....                     | 2 |
| 2.1.2. Caracterització dels subtipus CMS .....                           | 2 |
| 2.2 Antecedents en classificació mitjançant aprenentatge automàtic ..... | 2 |
| 2.2.1. Estudis representatius.....                                       | 2 |
| 2.3. Necessitats d'informació .....                                      | 2 |
| 2.3.1. Bases de dades transcriptòmiques i RNA-seq.....                   | 2 |
| 2.3.2 Tipus de dades i formats requerits .....                           | 2 |
| 2.3.3 Criteris de selecció de conjunt de dades .....                     | 2 |
| 2.3.4 Limitacions esperades de les dades.....                            | 2 |
| 2.3.5 Eines existents per a la classificació CMS.....                    | 2 |
| 2.3.6 Bibliografia inicial i recursos .....                              | 2 |
| 3. Objectius i abast .....                                               | 2 |

## APRENENTATGE AUTOMÀTIC APLICAT A BIOINFORMÀTICA

|                                                         |   |
|---------------------------------------------------------|---|
| 3.1. Objectius del client .....                         | 2 |
| 3.2. Objectius del producte .....                       | 2 |
| 3.2.1. Objectiu principal.....                          | 2 |
| 3.2.2. Objectius específics.....                        | 2 |
| 3.3. Abast del projecte .....                           | 2 |
| 3.3.1. Marc de dades .....                              | 2 |
| 3.3.2. Preprocessament i classificació.....             | 2 |
| 3.3.3. Models i comparació .....                        | 2 |
| 3.3.4. Avaluació i validació .....                      | 2 |
| 3.3.5. Implementació i estructura.....                  | 2 |
| 3.4. No-abast del projecte .....                        | 2 |
| 3.4.1. Marc de dades .....                              | 2 |
| 3.4.2. Anàlisi biològica .....                          | 2 |
| 3.4.3. Machine learning.....                            | 2 |
| 3.4.4. Infraestructura i implementació .....            | 2 |
| 4. Metodologia.....                                     | 2 |
| 4.1 Enfocament general i disseny del treball .....      | 2 |
| 4.2 Estratègies de cerca i selecció d'informació.....   | 2 |
| 4.3 Dades i obtenció del conjunt d'estudi.....          | 2 |
| 4.3.1 Construcció de la cohort al GDC Data Portal ..... | 2 |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

|                                                                    |   |
|--------------------------------------------------------------------|---|
| 4.3.2 Fitxers de descàrrega.....                                   | 2 |
| 4.3.3 Descàrrega massiva amb GDC Data Transfer Tool.....           | 2 |
| 4.4 Preparació de dades i preprocessament .....                    | 2 |
| 4.5 Models i alternatives considerades .....                       | 2 |
| 4.6 Protocol experimental i ajust d'hiperparàmetres .....          | 2 |
| 4.7 Avaluació i comparació .....                                   | 2 |
| 4.8 Reproductibilitat i traçabilitat .....                         | 2 |
| 4.9 Eines i entorn de treball .....                                | 2 |
| 4.10 Consideracions d'ètica acadèmica i qualitat de les fonts..... | 2 |
| 5. Requisits funcionals i tecnològics .....                        | 2 |
| 5.1 Requisits funcionals.....                                      | 2 |
| 5.2 Requisits no funcionals.....                                   | 2 |
| 5.3 Requisits tecnològics .....                                    | 2 |
| 5.3.1 Entorn de desenvolupament .....                              | 2 |
| 5.3.2 Llibreries i programari .....                                | 2 |
| 5.3.3 Gestió de projecte i control de versions .....               | 2 |
| 6. Desenvolupament .....                                           | 2 |
| 6.1 Entorn de treball i infraestructura del projecte .....         | 2 |

|                                                                      |   |
|----------------------------------------------------------------------|---|
| 6.1.1 Entorn d'execució i gestió de dependències .....               | 2 |
| 6.1.2 Estructura del repositori .....                                | 2 |
| 6.1.3 Documentació tècnica amb MkDocs .....                          | 2 |
| 6.1.4 Automatització amb GitHub Actions.....                         | 2 |
| 6.1.5 Estratègia de control de versions amb Git .....                | 2 |
| 6.2 Descàrrega de dades del GDC .....                                | 2 |
| 6.2.1 La cohort TCGA-COAD i el portal GDC .....                      | 2 |
| 6.2.2 El client gdc-client i l'automatització de la descàrrega ..... | 2 |
| 6.3 Preprocessament de les dades RNA-seq.....                        | 2 |
| 6.3.1 Integració dels fitxers de comptatge .....                     | 2 |
| 6.3.2 Filtratge inicial i tractament de les dades.....               | 2 |
| 6.3.3 Transformacions aplicades.....                                 | 2 |
| 6.3.4 Decisions adoptades durant el preprocessament .....            | 2 |
| 6.4 Anàlisi exploratori i reducció de dimensionalitat .....          | 2 |
| 6.4.1 Verificacions inicials de qualitat.....                        | 2 |
| 6.4.2 Exploració de l'estructura de les dades.....                   | 2 |
| 6.4.3 Incidències detectades i correccions adoptades .....           | 2 |
| 6.5 Entrenament dels models .....                                    | 2 |
| 6.5.1 Construcció del conjunt d'entrenament .....                    | 2 |
| 6.5.2 Models implementats .....                                      | 2 |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

|                                                           |   |
|-----------------------------------------------------------|---|
| 6.5.3 Script d'entrenament .....                          | 2 |
| 6.5.4 Control de reproductibilitat en l'entrenament ..... | 2 |
| 6.5.5 Artefactes generats .....                           | 2 |
| 6.5.6 Tancament de l'etapa d'entrenament .....            | 2 |
| 6.6 Avaluació del pipeline .....                          | 2 |
| 6.6.1 Objectiu de l'etapa d'avaluació.....                | 2 |
| 6.6.2 Entrada de l'etapa d'avaluació .....                | 2 |
| 6.6.3 Mètriques utilitzades .....                         | 2 |
| 6.6.4 Script d'avaluació .....                            | 2 |
| 6.6.5 Fitxers i figures generats .....                    | 2 |
| 6.6.6 Tancament de l'etapa d'avaluació.....               | 2 |
| 6.7 Resultats i validació de les hipòtesis .....          | 2 |
| 6.7.1 Resultat del conjunt de dades final .....           | 2 |
| 6.7.2 Resultats globals dels models .....                 | 2 |
| 6.7.3 Resultats per subtipus CMS i patrons d'error .....  | 2 |
| 6.7.4 Validació de les hipòtesis.....                     | 2 |
| 6.7.4.3 Criteris de decisió.....                          | 2 |
| 6.7.5 Síntesi dels resultats .....                        | 2 |

|                                                                         |   |
|-------------------------------------------------------------------------|---|
| 7. Estudi de viabilitat del projecte .....                              | 2 |
| 7.1 Planificació inicial .....                                          | 2 |
| 7.2 Pressupost .....                                                    | 2 |
| 7.2.1 Recursos humans.....                                              | 2 |
| 7.2.2 Recursos materials i llicències .....                             | 2 |
| 7.2.3 Cost global del projecte.....                                     | 2 |
| 7.3 Viabilitat .....                                                    | 2 |
| 7.3.1 Anàlisi de viabilitat tècnica.....                                | 2 |
| 7.3.2 Anàlisi de viabilitat econòmica.....                              | 2 |
| 7.3.3 Anàlisi de viabilitat mediambiental .....                         | 2 |
| 7.3.4 Aspectes Legals.....                                              | 2 |
| 7.3.5 Gestió de la diversitat i la perspectiva de gènere .....          | 2 |
| 8. Conclusions .....                                                    | 2 |
| 9. Possibles ampliacions.....                                           | 2 |
| 9.1 Incorporació de dades crues i processament primari .....            | 2 |
| 9.2 Integració de múltiples cohorts i correcció d'efectes de batch..... | 2 |
| 9.3 Validació externa dels models .....                                 | 2 |
| 9.4 Comparació amb classificadors CMS especialitzats .....              | 2 |
| 9.10 Síntesi de les ampliacions .....                                   | 2 |
| 10. Bibliografia.....                                                   | 2 |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

|                                                                         |   |
|-------------------------------------------------------------------------|---|
| *-11. Annexos .....                                                     | 2 |
| 11.1 Entrevista .....                                                   | 2 |
| 11.1.1 Introducció .....                                                | 2 |
| 11.1.2 Preguntes i respostes .....                                      | 2 |
| 11.1.3 Conclusió .....                                                  | 2 |
| 11.2 Prova de reproductibilitat en Windows 10 .....                     | 2 |
| 11.2.1 Introducció .....                                                | 2 |
| 11.2.2 Entorn utilitzat.....                                            | 2 |
| 11.2.3 Verificació de les eines base .....                              | 2 |
| 11.2.4 Clonació del repositori .....                                    | 2 |
| 11.2.5 Creació i activació de l'entorn Conda.....                       | 2 |
| 11.2.6 Instal·lació del paquet local i verificació de dependències..... | 2 |
| 11.2.7 Execució de les etapes principals del pipeline .....             | 2 |
| 11.2.8 Conclusió .....                                                  | 2 |

## Índex de figures

|                                                                                                                                        |    |
|----------------------------------------------------------------------------------------------------------------------------------------|----|
| Figura 1. Crida a la funció CMScaller amb els paràmetres utilitzats per a la classificació CMS a partir de dades RNA-seq.....          | 12 |
| Figura 2. Sortida en R de l'objecte res generat per CMScaller, amb les columnes de predicció CMS i mètriques associades.....           | 13 |
| Figura 3. Heatmap generat per CMScaller que mostra el patró d'expressió gènica associat als subtipus CMS.....                          | 14 |
| Figura 4. Fragment de codi en R corresponent a l'execució de CMSFFPE.....                                                              | 16 |
| Figura 5. Extracte de la sortida del classificador CMSFFPEClassifier mostrant les probabilitats associades a cada subtipus CMS .....   | 16 |
| Figura 6. Vista principal del Genomic Data Commons (GDC) Data Portal. ....                                                             | 25 |
| Figura 7. Pantalla de l'Analysis Center del GDC Data Portal, des d'on es poden crear cohorts personalitzades. ....                     | 26 |
| Figura 8. Interfície de l'eina Cohort Builder del GDC Data Portal, mostrant la selecció del projecte TCGA-COAD.....                    | 26 |
| Figura 9. Pantalla del repositori (Repository) del GDC Data Portal mostrant la llista de fitxers associats a la cohort TCGA-COAD. .... | 28 |
| Figura 10. Execució del GDC Data Transfer Tool mitjançant línia de comandes. ....                                                      | 29 |
| Figura 11. Fitxer enviroment.yml.....                                                                                                  | 37 |
| Figura 12 Diagrama C4 Context .....                                                                                                    | 39 |
| Figura 13. Diagrama C4 Contenidors.....                                                                                                | 40 |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

|                                                                                                            |    |
|------------------------------------------------------------------------------------------------------------|----|
| Figura 14. Lloc web de documentació desplegat a GitHub Pages .....                                         | 42 |
| Figura 15. GitHub Actions executant-se correctament .....                                                  | 43 |
| Figura 16. Mostra dels commits i branques de GitHub.....                                                   | 44 |
| Figura 17. Fitxer gdc_manifest.txt mostrant les primeres línies .....                                      | 45 |
| Figura 18. Diagrama C4 Etapa 1: Descàrrega .....                                                           | 45 |
| Figura 19. Diagrama C4 Etapa 2: Preprocessament.....                                                       | 47 |
| Figura 20. Histograma amb nombre de mostres que expressen cada gen .....                                   | 52 |
| Figura 21. Execució de l'script train.py des de la terminal. ....                                          | 57 |
| Figura 22. Execució de l'script evaluate.py .....                                                          | 62 |
| Figura 23. Fitxers generats per l'etapa d'avaluació. ....                                                  | 63 |
| Figura 24. Comparació de mètriques globals dels models. ....                                               | 66 |
| Figura 25. F1-score per subtipus CMS.....                                                                  | 68 |
| Figura 26. Matriu de confusió de Random Forest.....                                                        | 68 |
| Figura 27. Matriu de confusió de SVM.....                                                                  | 69 |
| Figura 28. Matriu de confusió de Logistic Regression .....                                                 | 69 |
| Figura 29. Diagrama PERT del projecte que mostra la seqüència de tasques. ....                             | 79 |
| Figura 30. Diagrama de Gantt del projecte que mostra la planificació temporal de les diferents fases. .... | 81 |

|                                                                                              |     |
|----------------------------------------------------------------------------------------------|-----|
| Figura 31. Fotografia corresponent a una sessió d'entrevista. ....                           | 92  |
| Figura 32. Estructura de la carpeta d'evidències de la prova. ....                           | 96  |
| Figura 33. Versió del sistema operatiu Windows 10.....                                       | 96  |
| Figura 34. Informació de CPU, memòria i versió del sistema. ....                             | 97  |
| Figura 35. Generació del fitxer systeminfo_windows10.txt. ....                               | 97  |
| Figura 36. Verificació de les versions de Conda, Git i Python. ....                          | 97  |
| Figura 37. Clonació del repositori i comprovació de l'estat amb Git. ....                    | 98  |
| Figura 38. Creació de l'entorn Conda a partir de environment.yml.....                        | 99  |
| Figura 39. Instal·lació del paquet local en mode editable i comprovació de dependències..... | 99  |
| Figura 40. Execució de l'etapa de descàrrega de dades. ....                                  | 100 |
| Figura 41. Execució de l'etapa de preprocessament. ....                                      | 100 |
| Figura 42. Execució de l'etapa d'entrenament dels models. ....                               | 101 |
| Figura 43. Execució de l'etapa d'avaluació. ....                                             | 102 |

## Índex de taules

|                                                                               |    |
|-------------------------------------------------------------------------------|----|
| Taula 1. Resum del conjunt de dades final utilitzat pel pipeline.....         | 64 |
| Taula 2. Distribució de mostres per subtipus CMS.....                         | 65 |
| Taula 3. Resultats globals i F1-score per subtipus dels models avaluats ..... | 65 |
| Taula 4. F1-score per subtipus CMS i mitjana per model.....                   | 67 |
| Taula 5. Formulació estadística de les hipòtesis d'avaluació.....             | 72 |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

|                                                                                                  |    |
|--------------------------------------------------------------------------------------------------|----|
| Taula 6. Resultats estadístics de les hipòtesis d'avaluació.....                                 | 74 |
| Taula 7. Contrast de la dificultat de classificació de CMS3 respecte a la resta de subtipus .... | 75 |
| Taula 8. Contrast de l'impacte del preprocessament complet respecte al pipeline .....            | 76 |
| Taula 9. Resolució final de les hipòtesis amb criteri estadístic .....                           | 77 |
| Taula 10. Estimació temporal de les tasques del projecte segons el mètode PERT.....              | 79 |
| Taula 11. Temporalització de les etapes del projecte.....                                        | 82 |
| Taula 12. Desglossament dels costos estimats del projecte per tipus de recurs .....              | 83 |

## **Glossari**

### **Batch effect**

Variabilitat tècnica no desitjada introduïda durant la generació de dades (p. ex. diferències entre laboratoris o protocols), que pot afectar l'anàlisi transcriptòmica.

### **CMScaller**

Eina implementada en R que permet classificar mostres de càncer colorectal en els subtipus moleculars CMS a partir de dades d'expressió gènica.

### **CMSFFPEClassifier**

Classificador específic per a dades procedents de mostres FFPE, dissenyat per assignar subtipus CMS tenint en compte les particularitats d'aquest tipus de mostres.

### **Consensus Molecular Subtypes (CMS)**

## APRENENTATGE AUTOMÀTIC APLICAT A BIOINFORMÀTICA

Sistema de classificació molecular del càncer colorectal que defineix quatre subtipus principals (CMS1–CMS4) basats en perfils transcriptòmics.

### **Deep learning**

Subcamp de l'aprenentatge automàtic basat en xarxes neuronals profundes. En aquest treball no s'utilitza, ja que queda fora de l'abast definit.

### **FDR (False Discovery Rate)**

Mètrica estadística que controla la proporció de falsos positius entre els resultats considerats significatius en anàlisis múltiples.

### **Genomic Data Commons (GDC)**

Plataforma del National Cancer Institute que proporciona accés centralitzat a dades genòmiques harmonitzades de projectes com TCGA.

### **Machine Learning (Aprentatge automàtic)**

Conjunt de tècniques computacionals que permeten als models aprendre patrons a partir de dades, utilitzades en aquest treball per a la classificació de subtipus CMS.

### **Normalització**

Procés de preprocessament aplicat a les dades d'expressió gènica per reduir biaixos tècnics i fer comparables les mostres.

### **PERT (Program Evaluation and Review Technique)**

Mètode de planificació de projectes utilitzat per estimar la durada de les tasques a partir de valors mínim, probable i màxim.

### **Pipeline bioinformàtic**

Seqüència estructurada de passos computacionals aplicada a dades biològiques, des del preprocessament fins a l'anàlisi i la visualització de resultats.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## **RNA-seq**

Tècnica de seqüenciació que permet quantificar l'expressió gènica a partir de RNA, utilitzada com a font de dades en aquest projecte.

## **Reproductibilitat**

Capacitat de repetir una anàlisi i obtenir els mateixos resultats utilitzant les mateixes dades i configuracions, aspecte clau del treball.

## **TCGA (The Cancer Genome Atlas)**

Projecte internacional que ha generat i publicat dades genòmiques de múltiples tipus de càncer, inclòs el càncer colorectal.

## **Validació de models**

Procés d'avaluació del rendiment d'un model utilitzant dades no emprades durant l'entrenament, per estimar la seva capacitat de generalització..



**Heading 1 al text que voleu que aparegui aquí.**

# **1. Objecte del projecte**

El present treball té com a objecte el disseny, desenvolupament i documentació d'un pipeline analític reproduïble per a la classificació dels subtipus moleculars CMS (Consensus Molecular Subtypes) del càncer colorectal a partir de dades d'expressió gènica RNA-seq, mitjançant tècniques d'aprenentatge automàtic.

La classificació molecular del càncer colorectal permet classificar tumors segons patrons transcriptòmics. Tot i que l'existència de models i metodologies prèviament publicades, la seva aplicació pràctica, sovint requereix pipelines bioinformàtics complexos. Aquesta situació dificulta l'adopció d'aquestes metodologies per part d'investigadors no especialitzats en bioinformàtica.

En aquest context, el projecte es troba dins del marc de la bioinformàtica aplicada a l'anàlisi transcriptòmica i l'avaluació de models d'aprenentatge automàtic amb l'objectiu de contribuir a la millora de la transparència i la reproductibilitat. El treball se centra en l'anàlisi de matrius d'expressió RNA-seq ja processades, provinents de conjunts de dades públics com els de The Cancer Genome Atlas, evitant fases prèvies de processament primari.

L'objecte del projecte no és el desenvolupament de nous models ni la interpretació biològica dels subtipus, sinó l'establiment d'un entorn controlat que permeti comparar diversos algorismes sota condicions homogènies de preprocessament. El treball pretén facilitar la reproducció dels resultats mitjançant una documentació detallada del pipeline.

D'aquesta manera, el projecte aporta valor en l'àmbit acadèmic, alineat amb les bones pràctiques de la recerca computacional. Contribueix a reforçar la importància de la reproductibilitat i la claredat metodològica.



**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## **2. Estat de l'art**

### **2.1 Marc teòric del càncer colorectal i dels subtipus CMS**

#### **2.1.1. Conceptes generals del càncer colorectal**

El càncer colorectal és un dels tumors més destacats i representa una de les principals causes de mortalitat [2]. Tradicionalment, el càncer s'ha classificat segons criteris anatòmics com la localització al còlon o al recte i histològics, l'observació de les cèl·lules al microscopi. La recerca ha demostrat que aquest càncer és molt variant molecularment, el qual indica que tumors que poden semblar similars des del punt de vista físic, poden respondre de manera molt diferent a tractaments. Aquesta variabilitat és el motiu pel qual s'ha impulsat la classificació molecular del càncer colorectal, basada en patrons d'expressió genètica i no només en característiques físiques del tumor.

La classificació molecular consisteix a identificar patrons d'activitat genètica compartits entre grups de tumors. Aquesta metodologia computacional requereix recollir dades procedents de diferents cohorts, el qual implica que necessàriament hem de tenir un procés de normalització i harmonització de dades per garantir la fiabilitat en les comparacions. Un cop establert un format coherent de les dades, podem fer agrupacions segons similituds en els seus perfils i identificar subgrups amb patrons moleculars coherents i amb comportaments clínics diferenciats.

En aquest context, Guinney et al. (2015) van dur a terme una anàlisi integradora de múltiples estudis i plataformes transcriptòmiques per unificar les diferents propostes de classificació molecular existents. Mitjançant aquesta integració, van identificar un conjunt estable de patrons d'expressió gènica que es repetia de manera consistent entre cohorts independents, fet que va permetre establir una classificació consensuada i reproduïble. Aquest procés d'harmonització

va donar lloc a quatre grups moleculars ben definits, que actualment serveixen com a referència per caracteritzar la diversitat biològica del càncer colorectal. La classificació CMS es converteix així en un marc conceptual que permet relacionar patrons moleculars amb diferències funcionals del tumor, i constitueix la base metodològica per a estudis computacionals posteriors [1].

Segons Guinney et al. (2015), els subtipus CMS representen «el sistema de classificació més robust disponible actualment per al càncer colorectal, amb una interpretabilitat biològica clara, i constitueixen la base per a futures estratificacions clíniques i intervencions terapèutiques dirigides segons subtipus» [1].

### **2.1.2. Caracterització dels subtipus CMS**

#### **2.1.2.1 CMS1: MSI-immune**

CMS1 es caracteritza per la seva hipermutació i la presència majoritària de tumors amb inestabilitat de microsatèl·lits (MSI). Això indica que el tumor acumula moltes alteracions genètiques vinculades a defectes en el mecanisme de reparació de l'ARN. [1]

A nivell transcriptòmic, CMS1 presenta una activació del sistema immunitari notable, el qual es reflecteix en un augment dels gens relacionats amb la resposta immunitària. Aquest efecte es pot notar amb una infiltració immune elevada al microambient tumoral. Això implica que el tumor es desenvolupa envoltat de cèl·lules immunitàries. [1]

De la mateixa manera, el tumor, també activa mecanismes d'evasió immune evitant ser eliminat, fet que permet que el tumor coexisteixi amb una resposta immune intensa. [1]

En últim lloc, CMS1 s'associa amb tumors de còlon dret, presenta una proporció més elevada de casos en dones i s'associa a graus histopatològics més elevats. Aquestes característiques no defineixen el subtipus per si soles, però aporten context clínic i ajuden a interpretar com es manifesta CMS1 a la població.[1]

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

#### **2.1.2.2. CMS2: canonical / proliferatiu**

CMS2, es considera el subtipus més clàssic, per això l'anomenem el subtipus “canònic”. Aquest té un perfil principalment epitelial, és a dir que es desenvolupa al teixit epitelial que recobreix el còlon i el recte. També es caracteritza per tenir vies que s'activen coordinadament associades a la proliferació, especialment relacionades amb les vies anomenades WNT i MYC.[1]

Un altre de les característiques associades amb aquest subtipus és la inestabilitat cromosòmica (CIN), això provoca guanys o pèrdues de fragments o de cromosomes sencers. Això pot produir perfils moleculars molt canviants i signatures, transcriptòmiques més epitelials, és a dir, pertanyents al tumor i no tantes d'immunes o d'estroma.[1]

Anatòmicament, CMS2 tendeix a aparèixer més sovint en el costat esquerre. I el seu pronòstic sol ser més favorable a comparació amb altres subtipus.[1]

#### **2.1.2.3. CMS3: metabòlic**

El CMS3 es defineix principalment per l'activació de molts gens relacionats amb el metabolisme de les cèl·lules. En termes pràctics, això vol dir, que el subtipus pot estar més condicionat per com gestiona l'energia i nutrients.[1]

Tot i que aquest subtipus també presenta característiques epitelials, es distingeix gràcies a aquestes signatures metabòliques.[1]

En l'àmbit genètic, les mutacions més freqüents són les del gen KRAS. Aquest gen participa en rutes de senyalització clau com són les que regulen la proliferació, supervivència i metabolisme cel·lular, provocant perfils funcionals molt diferenciats.[1]

#### **2.1.2.4. CMS4: mesenquimal / stromal-rich**

CMS4 es caracteritza per tenir un perfil dominant de vies mesenquimals i una gran contribució del microambient estromal. A efectes pràctics, això implica que la senyal transcriptòmica, no només reflecteix cèl·lules tumorals, immunes o d'estroma, sinó que podem notar una alta presència de components com fibroblasts i matriu extracel·lular.[1]

En aquest subtipus, s'observa una alta activació de la via TGF- $\beta$  i un augment de signatures d'EMT. Això indica que el tumor activa programes associats al canvi de comportament de les cèl·lules, fet que les fa menys estables i més preparades per desplaçar-se. Paral·lelament, també es detecten signatures relacionades amb la creació de nous vasos sanguinis i amb la reorganització del teixit que envolta el tumor.[1]

Aquest conjunt de senyals, indiquen que el tumor depèn fortament del microambient tumoral i que tendeix a ser més invasiu. El tumor no creix, sinó que modifica el teixit del seu voltant per facilitar l'expansió local i la seva dispersió.[1]

Clínicament, CMS4 s'associa amb una biologia agressiva molt influenciada per estroma i programes de migració o invasió, el qual dona lloc a una pitjor evolució, menor supervivència i amb tendència a etapes més avançades.[1]

## **2.2 Antecedents en classificació mitjançant aprenentatge automàtic**

En aquest apartat es fa una revisió dels principals estudis representatius que han abordat la classificació de càncer colorectal usant enfocaments supervisats d'aprenentatge automàtic amb dades transcriptòmiques. Es donarà èmfasi en les diferents maneres d'abordar usats, inclosa l'entrada de dades, els models o metodologia emprats i les estratègies de validació.

### **2.2.1. Estudis representatius**

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

### **2.2.1.1 Guinney et al. (2015)**

Aquest estudi utilitza dades massives procedents de múltiples cohorts públiques, inclou tant microarrays com RNA-seq. A partir d'aquestes dades, es fa una selecció d'aquells tumors que presenten un perfil molecular clar i consistent entre diferents mètodes de subclassificació transcriptòmica prèviament publicats. Aquest conjunt de mostres s'usa com a base per a la construcció dels subtipus CMS i per l'entrenament del model predictiu, reduint així el soroll. [1]

Els autors proposen un plantejament enfocat en aprenentatge automàtic basat en un model de Random Forest. Aquest, s'entrena usant les mostres prèviament definides amb l'objectiu d'aprendre patrons d'expressió gènica associats a cada subtipus. L'ús de "Random Forest", permet gestionar les dades massives i capturar relacions no lineals entre gens, oferint robustesa davant del soroll propi en aquest tipus de dades. [1]

Aquest model genera, per cada mostra, una assignació al subtipus CMS juntament amb mesures de confiança. Això permet identificar mostres clarament classificables i mostres amb perfils mixtos. [1]

### **2.2.1.2 de Back et al. (2024) CMSFFPE**

Aquest treball aborda la classificació CMS usant dades d'expressió gènica procedents de mostres formalin-fixed paraffin-embedded (FFPE) i de mostres fresh-frozen, els quals representen el tipus més habitual en la pràctica clínica. Aquest enfocament, permet analitzar l'impacte en la subclassificació que tenen les mostres amb RNA degradat, posant el focus en les limitacions d'un classificador entrenat amb dades de més qualitat en un entorn clínic real. [4]

Des del punt de vista metodològic, CMSFFPE manté l'enfocament proposat per Guinney et al. (2015), basat en un model supervisat de Random Forest. La principal contribució es fixa en una selecció de gens optimitzada per dades FFPE. [4]

Els resultats mostren una clara millora en l'exactitud de la classificació CMS en aquest tipus de mostres, provant que de l'adaptació del model al tipus de dada d'entrada és un factor determinant. [4]

### **2.2.1.3 Sirinukunwattana et al. (2021) - imCMS**

L'estudi proposa la classificació dels subtipus CMS a partir d'imatges histològiques de talls tenyits amb hematoxilina-eosina (H&E). Les dades d'entrada consisteixen en imatges digitalitzades de tumors procedents de múltiples cohorts. Aquest enfocament permet explorar informació morfològica del tumor. És una alternativa a l'anàlisi d'expressió gènica. [6]

El projecte usa xarxes neuronals profundes entrenades a partir de regions de la imatge histològica. El model s'entrena usant com a etiquetes els subtipus CMS obtinguts prèviament, aprenent a relacionar patrons morfològics amb els diferents subtipus. [6]

Els autors reporten un bon nivell de concordança entre la classificació transcriptòmica i la histològica, amb una capacitat destacable a l'hora d'identificar heterogeneïtat intratumoral i a classificar mostres que havien estat prèviament no classificables.

### **2.2.1.4 Alharbi & Vakanski (2023)**

Aquest article exposa una revisió dels principals mètodes d'aprenentatge automàtic aplicats a la classificació del càncer usant dades d'expressió gènica. Aquest, se centra a analitzar els algorismes que s'han usat amb més èxit, sota quines condicions i presentar les limitacions quan s'apliquen a dades d'alta dimensionalitat i poques mostres. [7]

Els autors revisen mètodes de ML com Random Forest, Support Vector Machines, k-Nearest Neighbors, Naive Bayes i Regressió logística i arbres de decisió. Conclouen que no existeix un algorisme universalment òptim per a la classificació de càncer amb dades d'expressió gènica. El rendiment dels models depèn de factors com les dades i nombre de mostres. En aquest

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

context, els algorismes Random Forest i Support Vector Machines, poden ser les opcions més sòlides quan hi ha poques dades d'alta dimensionalitat. Altres mètodes poden ser útils en situacions més específiques. [7]

L'article també revisa enfocaments d'aprenentatge profund, destacant el potencial en detectar relacions complexes no lineal. Descarta aquest enfocament, ja que aquests algorismes requereixen grans volums de dades. [7]

### **2.2.2. Síntesi dels antecedents i implicacions**

Els estudis revisats posen de manifest que la subclassificació molecular del càncer pot ser abordada de diferents maneres, especialment tenint en compte el tipus de dades d'entrada i la metodologia de subclassificació. Els treballs de Guinney et al. (2015) i de Back et al.(2024) mostren que els models d'aprenentatge automàtic supervisat són una opció sòlida i reproducible, mentre que l'estudi de Sirinukunwattana et al. (2021) mostra que és possible afrontar el problema mitjançant aprenentatge profund. No obstant això, aquest enfocament respon a un context molt específic on s'usa un tipus de dades concret i es treballa amb un gran volum de dades d'entrada, el qual no és directament extrapolable a altres contextos.[1][4][6]

La interpretació d'Alharbi i Vakanski (2023) reforça la idea que, en escenaris on hi ha una gran dimensionalitat de dades i un nombre reduït de mostres, els algorismes d'aprenentatge automàtic ofereixen un rendiment sòlid i comparable o fins i tot superior al rendiment d'altres enfocaments basats en aprenentatge profund. Els autors destaquen especialment els algorismes Random Forest i Support Vector Machine com a opcions més robustes en aquest context. [7]

## **2.3. Necessitats d'informació**

### **2.3.1. Bases de dades transcriptòmiques i RNA-seq**

TCGA és un dels programes de referència en genòmica del càncer i constitueix una font àmpliament usada en recerca. L'accés a les dades disponibles de TCGA es realitza principalment mitjançant el repositori Genomic Data Commons (GDC) el qual permet explorar i descarregar les dades. [11][8]

Aquest portal ofereix dades de diferents tipologies i formats associats a les cohorts, incloent-hi dades de seqüenciació i fitxers derivats. En el cas d'RNA-seq, el repositori inclou dades de quantificació d'expressió i documenta els processos de normalització i transformació més habituals. [9][10]

L'adequació d'aquest repositori com a font de dades es veu reforçada pel fet que els principals treballs de Guinney et al. (2015) i treballs posteriors com de Back et al. (2024), es basen en cohorts públiques i dades transcriptòmiques per establir i aplicar classificadors. En conseqüència, el repositori GDC/TCGA proporciona una base de dades coherent amb la literatura. [1][4][8][11]

### **2.3.2 Tipus de dades i formats requerits**

Per aquest projecte, és imprescindible disposar d'una gran quantitat de dades transcriptòmiques en format de matriu d'expressió acompanyada de metadades que permetin un bon filtratge de mostres. [11][9]

Es considera essencial que totes les mostres del conjunt de dades estiguin generades sota un mateix esquema de normalització, per tal d'evitar que diferències tècniques interfereixin en la comparabilitat de mostres. [9][10]

D'altra banda, es descartaran dades crues FASTQ, ja que la seva utilització implicaria implementar un pipeline que inclogui processos de control de qualitat, alineament i normalització. [11]

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Finalment, els algorismes considerats per la literatura, requereixen com a entrada una matriu numèrica homogènia i són sensibles a l'escala de les variables, fet que reforça la necessitat de treballar amb formats consistents i amb una transformació i normalització uniformes. [7]

### **2.3.3 Criteris de selecció de conjunt de dades**

Per assegurar que el conjunt de dades és homogeni i reproduïble, s'ha seleccionat la cohort TCGA-COAD com a font de mostres. Per garantir que totes les mostres provenen del mateix tipus de dada transcriptòmica, es farà un filtratge restringint l'estratègia experimental RNA-seq del perfil transcriptòmica. També se seleccionaran els fitxers quantificats amb STAR-Counts, ja que aquest proporciona quantificacions a nivell de gen en format de comptatges, adequat per construir matrius d'expressió. Finalment, només es treballarà amb dades d'accés obert per assegurar la reproductibilitat del procés i es restringirà el tipus de teixit de la mostra per usar només mostres de teixit tumoral perquè minimitza la variabilitat biològica. [8][9][10][11]

### **2.3.4 Limitacions esperades de les dades**

Tot i aplicar criteris de selecció estrictes per a garantir homogeneïtat, s'espera que el conjunt presenti algunes limitacions. En primer lloc, la subclassificació CMS es pot veure afectada per l'heterogeneïtat intratumoral, en què la que algunes mostres poden mostrar perfils mixtos o en transició. En segon lloc, les dades de comptatges poden tenir valors nuls, fet que pot requerir un tractament previ abans de l'entrenament dels models. Finalment, és possible trobar un desequilibri en la representació dels subtipus, ja que alguns poden estar menys representats i condicionar el rendiment dels classificadors.

### **2.3.5 Eines existents per a la classificació CMS**

La classificació CMS proposada per Guinney et al. (2015), s'ha acabat traduint en diferents eines computacionals amb l'objectiu d'analitzar les mostres de càncer colorectal a partir de diferents dades d'expressió gènica.

CMScaller, un paquet en R basat en signatures d'expressió (conjunt de seqüències d'ADN en ubicacions específiques) que compara el perfil d'una mostra amb patrons característics detectats a cada subtipus. És especialment útil per comparar contextos d'expressió heterogenis. [1][3]

CMSFFPE, és un classificador dissenyat específicament per a dades RNA-seq procedents de mostres clíniques, incloent-hi teixit FFPE, la qual és un tipus de mostra habitual en entorns hospitalaris i l'ARN d'aquest tipus de mostra, acostuma a estar més degradat. El mètode posa èmfasi a mantenir la classificació CMS robusta en condicions més pròximes a la pràctica clínica. [1][4]

### **2.3.5.1 CMScaller**

#### **2.3.5.1.1 Dades d'entrada**

CMScaller requereix una matriu numèrica d'expressió gènica (emat) la qual representa quantitativament el nivell d'expressió dels gens. Aquesta matriu segueix la següent estructura: les files corresponen als gens i les columnes expressen les mostres. Cada cel·la de la graella, conté un valor numèric el qual representa el nivell d'expressió d'un gen corresponent a una mostra.[5]

Els valors que conté la matriu, s'extrauen de tècniques d'extracció de dades transcriptòmiques com poden ser microarrays o RNA-seq. [5]

En cas d'usar microarrays, les dades d'entrada corresponen a intensitats d'hibridació i ja estan normalitzades. Els valors d'expressió representen la intensitat amb què fragments d'RNA es fixen a sondes complementàries d'un xip. Aquestes ja venen processades i no cal normalitzar.[5]

Quan s'usen dades d'RNA-seq, la informació prové de lectures obtingudes per seqüenciació, un cop fet, es fa un comptatge per gen i això genera valors anomenats “counts”. En aquest cas,

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

CMScaller, permet treballar amb aquestes dades no normalitzades aplicant el paràmetre RNAseq, el qual aplica una sèrie de transformacions per homogeneïtzar les dades i fer-les comparables.[5]

Un cop extrets els valors numèrics, cal saber quin tipus d'identificador de gen s'usa, per això hi ha tres tipus: Entrez Gene ID del NCBI, símbols genèrics oficials i identificadors Ensembl.[5]

A més, CMScaller, necessita un segon paràmetre d'entrada anomenat plantilla. Aquest paràmetre determina en quins subgrups moleculars s'ha de classificar i quins gens són els que caracteritzen cadascun d'aquests subgrups. La plantilla per defecte és CMS, que inclou els gens marcadors proposats per Guinnet et al. (2015), però també s'ofereixen les plantilles CRIS i MSI, les quals permeten altres classificacions.[5]

```
res <- CMScaller(  
  emat = emat,  
  templates = CMScaller::templates.CMS,  
  rowNames = "ensg",  
  RNAseq = TRUE,  
  seed = 1,  
  nPerm = 1000,  
  FDR = 0.05,  
  doPlot = TRUE  
)
```

*Figura 1. Crida a la funció CMScaller amb els paràmetres utilitzats per a la classificació CMS a partir de dades RNA-seq.*

#### **2.3.5.1.2 Metodologia usada**

CMScaller usa la classificació basada en plantilles i l'algorisme Nearest Template Prediction (NTP). Aquest algorisme defineix cada subgrup mitjançant la plantilla amb gens marcadors. Per cada mostra, es calcula la correlació entre la mostra i cada plantilla i extreu les distàncies. La distància segueix la següent fórmula:

$$d.class = \sqrt{\frac{1}{2} * (1 - (cor(mostra, plantilla)))}$$

El subgrup assignat a la mostra, és el que tingui menor distància. [5]

```
> head(res)
```

|                                      | prediction | d.CMS1    | d.CMS2    | d.CMS3    | d.CMS4    | p.value   | FDR         |
|--------------------------------------|------------|-----------|-----------|-----------|-----------|-----------|-------------|
| 00ae9ab8-6eaa-4085-af72-26f96df97fa3 | <NA>       | 0.6973057 | 0.7721449 | 0.7119852 | 0.8166185 | 0.9340659 | 0.943836498 |
| 00cdf29-697a-4a17-ba67-cf55c006b827  | CMS4       | 0.7860009 | 0.6414483 | 0.7188153 | 0.6164826 | 0.0010000 | 0.001241645 |
| 01947597-c83a-4c5d-8a45-f1fe27992ad5 | CMS4       | 0.7804601 | 0.6547004 | 0.6902641 | 0.5623541 | 0.0010000 | 0.001241645 |
| 0194feb1-d8be-45e5-9b95-0596090e9ecc | CMS2       | 0.7974932 | 0.5967580 | 0.6365932 | 0.7056326 | 0.0010000 | 0.001241645 |
| 019bfec7-ec6c-4cd6-808b-3e6e058e55f9 | CMS4       | 0.6598812 | 0.6661418 | 0.6729015 | 0.5967174 | 0.0010000 | 0.001241645 |
| 01d414a2-2b77-41e8-8622-98b277f5dc85 | CMS2       | 0.8309703 | 0.6304638 | 0.7660596 | 0.6649532 | 0.0010000 | 0.001241645 |

Figura 2. Sortida en R de l'objecte res generat per CMScaller, amb les columnes de predicció CMS i mètriques associades.

L'algorisme també usa el p-value i l'FDR com a mètodes per evitar assignacions quan la mostra no s'assembla prou a cap plantilla.[5]

### 2.3.5.1.3 Resultats

Com a resultat principal de CMScaller, s'obté una graella on es mostra la predicció de subgrup, les distàncies de la mostra per cada plantilla, el p-value i l'FDR. Quan s'activa el paràmetre “doPlot”, CMScaller genera un heatmap. Aquest gràfic mostra l'expressió dels gens marcadors de les plantilles en forma de mapa de calor. El color indica l'expressió relativa dels gens marcadors. [5]

El vermell indica que, per a un gen concret, la mostra presenta un nivell d'expressió relativament alt, mentre que blau indica un nivell relativament més baix. La saturació del color, reflecteix la magnitud, com més intens el color, més diferència hi ha.[5]

Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.

#### 2.3.5.1.4 Limitacions detectades




Figura 3. Heatmap generat per CMScaller que mostra el patró d'expressió gènica associat als subtipus CMS.

### 2.3.5.1.4 Limitacions detectades

Tot i que CMScaller és una eina útil i transparent a l'hora de classificar mostres de càncer colorectal en subtipus CMS, té algunes limitacions de disseny quan es vol fer una classificació més flexible i aplicable a diferents contextos. Quan s'activa el paràmetre RNAseq, aplica internament un preprocessament que consisteix en un "pseudocount", una transformació "log2" i una "quantile normalization". [5] Aquest pas és important, ja que la "quantile normalization" és una normalització entre mostres el que impossibilita l'anàlisi d'una mostra aïllada.

Això és una limitació pràctica si es vol un classificador que funcioni de forma fiable analitzant una sola mostra.

En segon lloc, CMScaller es basa en un únic mètode de classificació: NTP. Aquesta metodologia basada en distàncies entre mostra i plantilles, limita la capacitat del model per adaptar-se a patrons que no quedin ben representats per la signatura. Comparat amb sistemes ML, aquest mètode pot tenir més dificultats per capturar relacions complexes o no lineals entre gens.

Finalment, CMScaller depèn directament de la qualitat i la profunditat de les plantilles, ja que aquestes defineixen quins gens actuen com a marcadors i, per tant, quina informació s'utilitza per prendre les decisions. En cas que la cohort analitzada tingui característiques diferents o la signatura no representa bé certs casos, el mètode pot produir prediccions de menys confiança.

### 2.3.5.2 CMSFFPE

#### 2.3.5.2.1 Dades d'entrada

CMSFFPE és un classificador de càncer colorectal orientat a proves preservades en FFPE, un mètode molt habitual en la pràctica clínica el qual degrada l'RNA complicant l'anàlisi transcriptòmic. [4]

L'eina rep com entrada una matriu numèrica on les files representen els gens i les columnes les mostres.[4][12]

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Un aspecte clau de CMSFFPE és que no fa servir tots els gens, sinó que usa un conjunt reduït de gens característics més robustos en mostres FFPE. En concret, se seleccionen 144 gens, els quals se seleccionen usant el Transcript Integrity Number (TIN) com a criteri, de manera que se seleccionen el gens amb una mitjana de  $TIN > 20$ . [4][12]

#### 2.3.5.2.2 Metodologia usada

A diferència de CMScaller, aquest projecte usa un model supervisat entrenat per predir directament el subtipus CMS. S'entrena un classificador Random Forest sobre una cohort d'entrenament amb els 144 gens seleccionats.[4]

Usa un conjunt d'arbres de decisió en el qual, cada arbre vota un subgrup (CMS1-CMS4) a partir de patrons i el model final combina aquests vots. El resultat és una probabilitat per classe la qual s'interpreta com a confiança. [4][12]

A la implementació, aquest mateix concepte apareix com a llindar de decisió representat pel paràmetre “minPosterior” el qual permet evitar assignar un subtipus quan la confiança no supera el mínim establert. [12]

```
152 labels_ffpe <- CMSFFPEClassifier(  
153   Expr = Expr_sym,  
154   minPosterior = 0.5,  
155   log2transform = FALSE  
156 )
```

*Figura 4. Fragment de codi en R corresponent a l'execució de CMSFFPE.*

#### 2.3.5.2.3 Resultats

El resultat principal de l'eina és una predicció CMS per mostra. El classificador també produeix probabilitats de predicció associades a cada subtipus útils per detectar mostres amb fenotip CMS mixtos. [12]

```
> res_tbl
```

|    | file_id                              | cnsffpe.CMS1 | cnsffpe.CMS2 | cnsffpe.CMS3 | cnsffpe.CMS4 | cnsffpe.nearest | cnsffpe.predicted | sample_id        | preservation |
|----|--------------------------------------|--------------|--------------|--------------|--------------|-----------------|-------------------|------------------|--------------|
| 1  | 04288a35-71ba-421d-80a4-52bb0853aa9f | 0.440        | 0.150        | 0.198        | 0.212        | CMS1            | <NA>              | TCGA-A6-5661-01B | FFPE         |
| 2  | 14eb25f3-a5ea-4589-9fdc-73da9e2ca081 | 0.354        | 0.194        | 0.360        | 0.092        | CMS3            | <NA>              | TCGA-A6-6780-01B | FFPE         |
| 3  | 3e43db02-7668-4a5e-8ffd-7df2ce478ffc | 0.130        | 0.062        | 0.042        | 0.766        | CMS4            | CMS4              | TCGA-A6-2674-01B | FFPE         |
| 4  | 457ab960-e085-4103-97e9-4868dbc364a2 | 0.026        | 0.792        | 0.036        | 0.146        | CMS2            | CMS2              | TCGA-A6-3810-01B | FFPE         |
| 5  | 82ab3359-565c-4360-ac4c-b02a7aec600e | 0.008        | 0.910        | 0.026        | 0.056        | CMS2            | CMS2              | TCGA-A6-2677-01B | FFPE         |
| 6  | 90b8a6ce-af5d-48ec-8d64-6642b0882598 | 0.020        | 0.656        | 0.042        | 0.282        | CMS2            | CMS2              | TCGA-A6-5656-01B | FFPE         |
| 7  | 97fb41bc-f5a9-4b70-b631-9da9ff44b5fd | 0.716        | 0.086        | 0.116        | 0.082        | CMS1            | CMS1              | TCGA-A6-3809-01B | FFPE         |
| 8  | 985d5043-cf68-4f4b-bba1-1aa621ab20c9 | 0.590        | 0.072        | 0.142        | 0.196        | CMS1            | CMS1              | TCGA-A6-5665-01B | FFPE         |
| 9  | b7aa491d-f50f-4f9b-b8ac-1572cd6cd1ef | 0.068        | 0.266        | 0.036        | 0.630        | CMS4            | CMS4              | TCGA-A6-2684-01C | FFPE         |
| 10 | bba0553b-afd2-470f-b0f3-a31ef377e62d | 0.514        | 0.144        | 0.168        | 0.174        | CMS1            | CMS1              | TCGA-A6-2672-01B | FFPE         |
| 11 | de0f7996-1854-4b32-a2f9-1c99484b9e54 | 0.020        | 0.002        | 0.002        | 0.976        | CMS4            | CMS4              | TCGA-A6-6781-01B | FFPE         |
| 12 | ed0ffe0c-0094-41b3-86aa-20492e0d0157 | 0.000        | 0.988        | 0.012        | 0.000        | CMS2            | CMS2              | TCGA-A6-5659-01B | FFPE         |
| 13 | fce8e7c5-f4f8-4d2e-8b55-a8a73d5524eb | 0.006        | 0.850        | 0.138        | 0.006        | CMS2            | CMS2              | TCGA-A6-6650-01B | FFPE         |

Figura 5. Extracte de la sortida del classificador CMSFFPEClassifier mostrant les probabilitats associades a cada subtipus CMS

## 2.3.5.2.4 Limitacions detectades

Tot i que CMSFFPE aborda un problema real, el mateix article situa l'eina com una eina d'investigació i posa èmfasi en la dependència de la qualitat de les dades.

El model es construeix sobre 144 gens seleccionats segons el criteri TIN. Això el fa més resistent a la degradació, però el fa més dependent de si aquests gens existeixen a la cohort analitzada i si l'escala d'expressió és compatible amb el model.

Finalment, l'article destaca que els classificadors Random Forest previs es van concebre per aplicar-se a múltiples mostres i que això pot afectar a la robustesa en la classificació de mostres clíniques aïllades.

## 2.3.6 Bibliografia inicial i recursos

Repositoris i documentació de dades

- [11] TCGA (NCI): descripció del programa i del tipus de dades moleculars disponibles per a cohorts de càncer.
- [8] GDC Data Portal: plataforma per explorar i descarregar dades harmonitzades associades a TCGA.
- [9] GDC – Expression mRNA Pipeline: documentació dels valors de normalització/transformació emprats (p. ex. TPM/FPKM/FPKM-UQ).

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

- [10] GDC – STAR-Counts: definició del workflow i del tipus de sortida per a quantificació d'expressió a nivell de gen.

#### Eines i documentació per a classificació CMS

- [3] CMScaller (Eide et al.): eina de referència per a assignació CMS basada en signatures/plantilles.
- [5] Documentació CMScaller (rdr.io): guia pràctica d'ús i paràmetres de la implementació.
- [4] de Back et al. (2024) – CMSFFPE: adaptació/validació dels classificadors CMS per a contextos clínics (FFPE) i implicacions del tipus de mostra.
- [12] CMSFFPE (yswutan) – repositori GitHub amb la implementació en R del classificador, instruccions d'instal·lació i exemple d'ús.

#### Articles científics base

- [1] Guinney et al. (2015): definició dels subtipus CMS i establiment del marc de classificació.
- [6] Sirinukunwattana et al. (2021) – imCMS: enfocament alternatiu basat en deep learning sobre imatges histològiques.
- [7] Alharbi & Vakanski (2023): revisió metodològica d'algorismes ML per a classificació amb dades d'expressió gènica.

## **3. Objectius i abast**

### **3.1. Objectius del client**

La pipeline desenvolupada en aquest projecte té com a usuari objectiu investigadors en bioinformàtica i personal de recerca biomèdica que necessiten aplicar la classificació CMS en dades d'expressió genètica d'una manera estructurada, reproduïble i transparent i busquen comparar diferents models.

Les necessitats del client no se centren en el desenvolupament de nous models, mètodes o algorismes de classificació. Tampoc es busca una interpretació biològica dels resultats. Es centra en el desenvolupament d'un entorn de treball estandarditzat que permeti executar i comparar diferents models de ML en la classificació CMS.

En aquest context, els objectius principals del client són:

- Disposar d'un flux de treball reproduïble que garanteixi la traçabilitat dels passos de preprocessament, execució i comparació de resultats.
- Garantir la comparació de diferents models de ML aplicats a la classificació CMS en un "benchmark", evitant biaixos derivats del preprocessament o de l'execució.
- Reduir barreres d'ús del procés usant una documentació clara i una estructura comprensible facilitant l'ús del projecte en entorns de recerca.

### **3.2. Objectius del producte**

#### **3.2.1. Objectiu principal**

Desenvolupar un pipeline reproduïble per a la classificació del càncer colorectal en els subtipus CMS a partir de dades d'expressió genètica RNA-seq. Comparar diversos algorismes d'aprenentatge automàtic amb l'objectiu d'establir un benchmark sota condicions homogènies.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

### **3.2.2. Objectius específics**

#### **3.2.2.1 Tractament de dades**

Disposar d'un preprocessament de dades RNA-seq estandaritzat que garanteixi la qualitat i coherència de les dades d'entrada.

Aplicar tècniques de normalització adequades a la cohort de mostres, assegurant la comparabilitat entre dades.

Definir un procés de selecció de característiques que millori el rendiment dels models d'aprenentatge automàtic.

#### **3.2.2.2. Models d'aprenentatge automàtic**

Disposar de diversos algorismes d'aprenentatge automàtic entrenats per a la subclassificació del càncer colorectal en els subtipus CMS.

Establir un benchmark comparatiu dels diferents algorismes d'aprenentatge automàtic sota condicions homogènies i mitjançant mètriques quantitatives adequades.

#### **3.2.2.3. Reproductibilitat i documentació**

Documentar de manera completa, estructurada i fàcilment comprensible i reproduïble el pipeline desenvolupat descrivint totes les etapes i metodologies.

Publicar el pipeline en un repositori obert amb tots els scripts i documentació per garantir la transparència, la traçabilitat i la reproductibilitat.

### **3.3. Abast del projecte**

Aquest apartat defineix els límits funcionals i metodològics del projecte, especificant quins aspectes són inclosos dins del treball desenvolupat i delimitat clarament.

### **3.3.1. Marc de dades**

Treballar únicament amb matrius d'expressió RNA-seq processades, sense dades crues.

Utilitzar conjunts de dades públics.

Operar sobre un únic conjunt de dades, mantenint el flux analític homogeni.

### **3.3.2. Preprocessament i classificació**

Centrar l'anàlisi en la classificació dels subtipus CMS.

Incloure només visualitzacions exploratòries bàsiques quan siguin necessàries per interpretar resultats.

### **3.3.3. Models i comparació**

Incloure un benchmark de models supervisats clàssics.

Aplicar-los sota un mateix esquema de preprocessament i partició de dades.

### **3.3.4. Avaluació i validació**

Generació de taules comparatives i visualitzacions bàsiques (matriu de confusió i gràfics de mètriques).

### **3.3.5. Implementació i estructura**

Execució principal mitjançant notebooks, amb el suport de scripts modulars.

Repositori obert amb pipeline, scripts i README amb documentació essencial.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## **3.4. No-abast del projecte**

En aquest apartat, es defineix explícitament aquells aspectes que queden fora de l'abast del projecte, amb l'objectiu de delimitar les funcionalitats no contemplades.

### **3.4.1. Marc de dades**

No s'inclou mètodes d'alineació de seqüències ni de quantificació de lectures a partir de formats de dades crues.

No es realitza la integració de múltiples cohorts de dades ni l'aplicació de correccions d'efectes de batch.

### **3.4.2. Anàlisi biològica**

No es porta a terme interpretació biològica associada als resultats obtinguts.

No es duen a terme validacions clíniques ni es treballa amb dades de pacients procedents d'entorns hospitalaris.

### **3.4.3. Machine learning**

No es desenvolupen nous models ni tècniques d'aprenentatge automàtic.

No s'utilitzen models basats en aprenentatge profund ni arquitectures neuronals complexes.

### **3.4.4. Infraestructura i implementació**

No s'implementen aplicacions web, APIs ni interfícies gràfiques d'usuari.

No es realitza cap desplegament en servidor ni s'usen contenidors ni entorns de producció.



**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## **4. Metodologia**

### **4.1 Enfocament general i disseny del treball**

Aquest projecte s'organitza com una pipeline de classificació transcriptòmica dels subtipus CMS del càncer colorectal a partir de matrius d'expressió RNA-seq ja processades. Per realitzar-ho, se segueix un flux metodològic en dues fases.

- Fase en cascada: S'estableixen els requisits del projecte, s'identifiquen les fonts i els recursos necessaris, es defineix el conjunt de dades i es defineix el procés de preprocessament d'aquestes.
- Fase iterativa: S'implementa i ajusta el pipeline mitjançant iteracions curtes organitzades en les fases d'entrenament, ajust d'hiperparàmetres i avaluació de resultats, introduint millores a cada iteració.

Aquesta estructura permet mantenir una planificació clara a l'inici i incorporar iteracions durant la part experimental on és essencial revisar decisions segons el comportament dels models i els resultats obtinguts.

### **4.2 Estratègies de cerca i selecció d'informació**

Per construir el marc teòric, s'ha consultat articles científics sobre diferents tipus de càncer, sobre la subclassificació de càncer colorectal en els subtipus CMS. La documentació usada per descriure les dues eines explorades es basa en documentació oficial de la llibreria i del mateix repositori de l'autor.

### **4.3 Dades i obtenció del conjunt d'estudi**

El conjunt principal de dades s'obté del portal de dades GDC Data Portal. En aquest portal, es poden trobar fitxers corresponent a molts projectes, per aquest projecte, usarem les dades del TCGA-COAD el qual inclou dades de tumors colorectals.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

### 4.3.1 Construcció de la cohort al GDC Data Portal

Per poder extreure les dades que es necessiten d'aquest portal, primer s'ha d'accedir a la plana principal del GDC Data Portal i seleccionar l'opció "Explore our Cancer Datasets", en la qual es pot explorar diferents projectes i iniciar la construcció de la cohort.




Figura 6. Vista principal del Genomic Data Commons (GDC) Data Portal.

A continuació, s'ha d'usar l'eina "Cohort Builder" per a crear la cohort específica. Aquest pas filtrarà entre els 50270 casos disponibles actualment en la base de dades, deixant tots els fitxers disponibles dels casos que compleixin aquestes característiques.

En aquest projecte, s'ha creat una cohort orientada a dades transcriptòmiques del càncer colorectal. Els filtres que s'han usat són els següents.

# APRENENTATGE AUTOMÀTIC APLICAT A BIOINFORMÀTICA




Figura 7. Pantalla de l'Analysis Center del GDC Data Portal, des d'on es poden crear cohorts personalitzades.

## Project: TCGA-COAD

Aquest projecte del programa “TCGA” proporciona una cohort àmplia de pacients amb adenocarcinoma de còlon (tipus més comú de càncer colorectal) i conté dades moleculars, incloses dades “RNA-seq”.




Figura 8. Interfície de l'eina Cohort Builder del GDC Data Portal, mostrant la selecció del projecte TCGA-COAD.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## **4.3.2 Fitxers de descàrrega**

Un cop fet, s'accedeix a l'apartat "Repository", en el qual, gràcies a la cohort creada, es pot visualitzar tots els fitxers associats als casos seleccionats. El repositori pot mostrar fitxers addicionals vinculats als mateixos casos, el qual implica un segon filtratge per finalment obtenir únicament els fitxers desitjats. Per aquest segon filtratge, cal aplicar filtres aplicats següents:

### **Data Category: Transcriptome Profiling**

Limita els resultats a perfils que continguin fitxers de transcriptòmica.

### **Experimental Strategy: RNA-seq**

Se selecciona RNA-seq per assegurar que les dades transcriptòmiques provenen de seqüenciació d'RNA, això permet obtenir perfils quantitius d'expressió genètica a escala genòmica. També ens assegurem excloure dades transcriptòmiques d'altres orígens els quals no serien comparables directament.

### **Workflow Type: STAR-Counts**

Aquesta característica produeix comptatges per gen (gene counts). Aquest format és el més adequat per construir una matriu d'expressió.

### **Access: Open**

En el cas de GDC Data Portal, compta amb dades obertes i restringides, normalment sent les restringides aquelles amb informació confidencial i requereixen un tipus d'autorització dbGaP. Per aquest projecte assegurem que podem obtenir el conjunt de dades i que es pugui reproduir de manera transparent.

### **Tissue Type: Tumor**

## APRENENTATGE AUTOMÀTIC APLICAT A BIOINFORMÀTICA

Per obtenir un conjunt homogeni de perfils tumorals transcriptòmics evitant mostres d'una altra tipologia que podrien introduir soroll a la classificació dels subtipus.

Com es pot veure a la figura, s'ha reduït la dimensió de la mostra de dades a 2,21 GB.




Figura 9. Pantalla del repositori (Repository) del GDC Data Portal mostrant la llista de fitxers associats a la cohort TCGA-COAD.

Després d'obtenir el conjunt final de dades, es pot continuar a la descàrrega d'aquestes. Per aconseguir-ho, s'afegeixen els fitxers al “Cart” i es descarreguen els següents fitxers:

- Manifest: Conté una llista d'identificadors dels fitxers seleccionats
- Metadata: Metadates per relacionar fitxers, mostres i casos
- Sample Sheet: Informació resum de les mostres

### 4.3.3 Descàrrega massiva amb GDC Data Transfer Tool

Finalment, per descarregar el volum de fitxers de manera eficient, GDC recomana usar la seva pròpia eina anomenada GDC Data Transfer Tool usant el manifest. Aquest és el mètode estàndard per descàrregues de dades massives.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

```
C:\Users\rivs\Downloads>gdc-client.exe download -m gdc_manifest.2025-12-17.142355.txt
100% [#####] Time: 0:00:04 889.4 KiB/s
100% [#####] Time: 0:00:02 1.4 MiB/s
100% [#####] Time: 0:00:02 1.4 MiB/s
100% [#####] Time: 0:00:02 1.7 MiB/s
100% [#####] Time: 0:00:02 1.5 MiB/s
100% [#####] Time: 0:00:04 847.5 KiB/s
100% [#####] Time: 0:00:02 1.9 MiB/s
100% [#####] Time: 0:00:03 1.0 MiB/s
100% [#####] Time: 0:00:02 1.5 MiB/s
100% [#####] Time: 0:00:02 1.6 MiB/s
```

Figura 10. Execució del GDC Data Transfer Tool mitjançant línia de comandes.

## 4.4 Preparació de dades i preprocessament

Per aquest projecte, es necessiten matrius d'expressió com a dades d'entrada. Per poder construir-les, s'importen els fitxers de quantificació d'expressió de gens i es disposen en files amb els gens, columnes que indiquen la mostra i valors que representen el comptatge per gen. Les dades del GDC provenen d'un procés d'harmonització orientat a facilitar l'anàlisi conjunta i reduir la variabilitat. [14]

Un cop constituïda la matriu, i abans d'aplicar transformacions dependents de la distribució de dades, es divideixen les dades en dos grups d'entrenament i prova. Qualsevol operació es calcula amb les dades del grup d'entrenament i després s'aplica al grup de proves per evitar estimacions massa optimistes. [15]

Per reduir el soroll i la dimensionalitat de les dades, s'eliminen gens amb un baix comptatge. Aquest criteri s'aplica sobre les dades d'entrenament i s'eliminen els mateixos gens del grup de proves. [13]

Finalment, aplicarem una transformació logarítmica amb l'objectiu de reduir la variància. Aquesta transformació la farem sobre el conjunt d'entrenament i transferirem els hiperparàmetres resultants al conjunt de proves. [13]

## 4.5 Models i alternatives considerades

Per a la selecció d'algorismes, s'ha tingut en compte que aquests tinguin un bon rendiment amb dades d'alta dimensionalitat, tinguin una validació prèvia en l'àmbit de la classificació CMS i que es pugui realitzar un benchmark comparable amb un cost computacional i una complexitat dins de l'abast del projecte.

Com a model principal, s'ha seleccionat Random Forest, ja que la proposta original dels subtipus CMS incorpora aquest algorisme per realitzar la predicció. [1]

S'incorpora l'algorisme Support Vector Machines a causa del seu ampli ús dins de la classificació de dades d'alta dimensionalitat i constitueix una alternativa competitiva. [7]

Finalment, s'afegirà la Regressió Logística com a tercer model que gràcies a la seva simplicitat i interpretabilitat, serveix com a punt de comparació. Permet quantificar fins a quin punt aporta millora la interpretabilitat no lineal.

### **4.6 Protocol experimental i ajust d'hiperparàmetres**

En el context de dades d'expressió gènica, els autors conclouen que el rendiment dels models depèn fortament de l'ajust d'hiperparàmetres. [7] L'ajust d'hiperparàmetres es planteja com una cerca iterativa dins del grup d'entrenament. Per cada iteració, es prova una configuració. El rendiment s'estima amb una validació interna obtenint una mètrica que permet comparar configuracions de manera estable.

### **4.7 Avaluació i comparació**

L'avaluació dels diferents models es realitza amb l'objectiu d'obtenir una comparació objectiva sota un mateix conjunt de dades. Un cop seleccionada la millor configuració d'hiperparàmetres, cada model s'avalua una única vegada sobre el conjunt de dades de prova.

Per a comparar el rendiment s'utilitzen mètriques globals robustes complementades amb una matriu de confusió. Això ens permet treure conclusions sobre quins subtipus tendeixen a confondre's més habitualment i interpretar el comportament per detectar patrons d'error rellevants.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## 4.8 Reproductibilitat i traçabilitat

Per garantir la reproductibilitat del treball, s'incorporen mesures de control de versions de codi i de canvis rellevants. També es documenta cada etapa del procés des de l'obtenció de dades, el preprocessament, l'entrenament i l'avaluació.

L'entorn de treball es gestiona de manera consistent i aïllada per tal de tenir un entorn net i poder controlar dependències, llibreries i paquets. Addicionalment, s'estableix un sistema de llavors amb l'objectiu d'eliminar la variabilitat a causa de valors aleatoris.

Finalment, per assegurar la traçabilitat, es conserven els fitxers i identificadors necessaris per reconstruir el conjunt de dades de descàrrega inclòs el manifest i les metadades.

## 4.9 Eines i entorn de treball

Per al desenvolupament del projecte, i la gestió d'aquest, s'usen diferents eines per garantir l'organització, l'accés obert, la traçabilitat i reproductibilitat.

GitHub: Permet gestionar el control de versió del codi i gestió del repositori del projecte, cosa que permet la gestió de versions i un històric.

Trello: Planificació i seguiment de tasques, permet entendre l'estat de cada tasca d'una ullada.

Google Drive: Gestió i organització de documentació amb control de versions.

Python i Jupyter Notebook: Implementació del pipeline analític, exploració de les dades i execució d'experiments.

Conda: Gestió d'entorns i dependències. Facilita la reproductibilitat.

Google Sheets: Registre d'hores dedicades i tasques.

## **4.10 Consideracions d'ètica acadèmica i qualitat de les fonts**

Aquest projecte es desenvolupa sota els principis d'integritat acadèmica i respecte per l'autoria intel·lectual. Es considera plagi l'apropiació d'idees o textos d'altres autors sense reconèixer explícitament l'origen, per tant, totes les idees, fragments i dades procedents de tercers, s'incorporen amb citació dins del text amb la corresponent entrada a la bibliografia en format IEEE.

En relació amb la integritat científica, es preserva la veracitat del treball evitant pràctiques com la falsificació, l'alteració o l'omissió deliberada de dades rellevants.

Pel que fa a la privacitat i confidencialitat, el projecte utilitza dades públiques d'accés obert les quals segueixen els criteris generals de protecció de dades i no permeten identificar a persones.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## **5. Requisits funcionals i tecnològics**

### **5.1 Requisits funcionals**

Els requisits funcionals defineixen les funcionalitats mínimes que he de complir el sistema per assolir els objectius del projecte.

- Carregar i gestionar dades d'expressió gènica provinents de cohorts públiques.
- Preprocessar les dades per garantir la seva consistència i qualitat.
- Implementar tècniques de reducció de dimensionalitat per a l'exploració de les dades.
- Entrenar models d'aprenentatge automàtic per a la classificació dels subtipus CMS.
- Avaluar el rendiment dels models mitjançant mètriques quantitatives.
- Generar visualitzacions que permetis interpretar els resultats obtinguts.

### **5.2 Requisits no funcionals**

Els requisits no funcionals defineixen criteris de qualitat que ha de complir el sistema independentment de la funcionalitat concreta.

- Garantir la reproductibilitat del projecte mitjançant la fixació de versions i llibreries.
- Assegurar la transparència del codi font i dels processos.
- Estructurar el pipeline de forma reutilitzable.
- Mantenir una documentació clara i accessible.

- Facilitar la traçabilitat entre dades d'entrada, models i resultats obtinguts.

## **5.3 Requisits tecnològics**

Els requisits tecnològics descriuen els recursos de programari i les eines necessàries per desenvolupar el projecte amb garanties de rendiment i estabilitat.

### **5.3.1 Entorn de desenvolupament**

- Python 3.x com a llenguatge principal.
- Entorn virtual amb Conda per gestionar dependències.
- Desenvolupament del codi amb Visual Studio Code i Jupyter Notebook.

### **5.3.2 Llibreries i programari**

- Utilitzar Python Pandas per la manipulació de dades.
- Fer servir NumPy pel càlcul numèric i vectorial.
- Implementar models d'aprenentatge automàtic amb scikit-learn.
- Generar gràfics amb matplotlib i seaborn.

### **5.3.3 Gestió de projecte i control de versions**

- Gestió de les versions de codi mitjançant GitHub.
- Organització de les tasques amb Trello.
- Emmagatzematge dels conjunts de dades en format estàndard CSV/TSV.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## **6. Desenvolupament**

Aquest capítol descriu el desenvolupament del projecte. S’hi recullen decisions tècniques adoptades, la configuració de l’entorn de treball, el procés d’obtenció i preparació de les dades i les tasques d’anàlisi.

### **6.1 Entorn de treball i infraestructura del projecte**

#### **6.1.1 Entorn d’execució i gestió de dependències**


Abans d’implementar qualsevol component relacionat amb el tractament de dades, cal establir un entorn sobre el qual es construirà el projecte. Aquesta fase inicial condiciona la reproductibilitat. Per aquest motiu, s’ha definit de manera explícita el gestor d’entorns, de dependències i del codi reutilitzable.

##### **Selecció del gestor d’entorns**

La primera decisió va ser escollir el sistema de gestió d’entorns i dependències. En projectes python, la solució habitual és l’ús de “pip” combinat amb “venv”. En l’àmbit de la bioinformàtica es sol treballar amb eines que depenen de biblioteques del sistema operatiu o de paquets que no son Python pur. En aquest context, s’ha optat per usar Conda, ja que permet gestionar tant paquets Python com binaris dins d’un entorn completament aïllat. Aquesta característica redueix conflictes entre dependències i facilita la reproductibilitat del pipeline.

##### **Definició de l’entorn**

L’entorn Conda queda definit al fitxer “environment.yml”, on s’especifiquen el nom de l’entorn, la versió de Python i les dependències necessàries per a l’execució del projecte. Això permet construir l’entorn completament amb una única comanda.



```
mrivero@ThinkPadL13: ~/tcga-coad-cms-ml-pipeline
Archivo  Editor  Ver  Buscar  Terminal  Ayuda
(tcga-coad-cms-ml-pipeline) mrivero@ThinkPadL13:~/tcga-coad-cms-ml-pipeline$ cat environment.yml
name: tcga-coad-cms-ml-pipeline
channels:
  - conda-forge
  - defaults
dependencies:
  - python=3.11
  # Data manipulation
  - numpy
  - pandas
  # ML
  - scikit-learn
  # Visualization
  - matplotlib
  - seaborn
  # Dimensionality reduction
  - umap-learn
  # Notebooks
  - jupyterlab
  # Documentation
  - mkdocs
  - mkdocs-material
  # Pip packages
  - pip
  - pip:
    - -e .
(tcga-coad-cms-ml-pipeline) mrivero@ThinkPadL13:~/tcga-coad-cms-ml-pipeline$
```

Figura 11. Fitxer *enviroment.yml*

D'aquesta manera, el fitxer no actua com una simple llista orientativa de paquets, sinó com la definició de l'entorn d'execució. Entre les principals dependències, es troben “scikit-learn” per a l'entrenament de models d'aprenentatge automàtic, “pandas” i “numpy” per a la manipulació de dades, “matplotlib” i “seaborn” per a la visualització de les dades, “umap-learn” per a la reducció de dimensionalitat no lineal i “jupyterlab” per al treball d'exploració amb els notebooks.

### Empaquetat del codi

Un problema habitual en projectes Python amb estructura modular és la gestió de les importacions entre directoris. Quan s'utilitza codi reutilitzable és necessari que qualsevol script o neotbook el pugui importar sense recórrer a modificacions manuals del “Path”. Per evitar-ho, s'ha creat un fitxer “pyproject.toml” a l'arrel que declara el directori “src/” com a paquet Python instal·lable.

Amb aquesta configuració, la comanda “pip install -e .” Registra el paquet en mode editable. Això permet fer importacions estàndard des de qualsevol punt del projecte.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

El mode editable és especialment útil durant el desenvolupament, ja que qualsevol modificació feta als fitxers dins de “src/” queda actualitzat immediatament sense necessitat de reinstal·lar el paquet. Aquesta instal·lació també s’integra dins del procés de creació de l’entorn.

### 6.1.2 Estructura del repositori

Una decisió arquitectònica ha estat establir una separació clara entre el codi principi del pipeline i els mòduls reutilitzables. Aquesta distinció facilita el manteniment del projecte, evita duplicitat de codi i permet una millor lectura i comprensió del mateix.

Aquesta separació es concreta en dos directoris:

- “scripts/”: conté un script per cada etapa del pipeline, és a dir, “download.py”, “preprocess.py”, “train.py” i “evaluate.py”. Aquests fitxers actuen com a punts d’entrada executables i s’encarreguen de coordinar el flux d’execució.
- “src/”: conté els mòduls reutilitzables del projecte. Les funcions definides en aquest directori no depenen d’un únic context d’execució i poden ser usades tant per scripts com per notebooks.

Aquesta organització permet que el notebook utilitzi exactament les mateixes funcions que els scripts del pipeline. D’aquesta manera, qualsevol modificació feta en una funció s’aplica a tots els punts del projecte que la consumeixen.

Per representar aquesta organització d’una manera més visual, s’han utilitzat diagrames C4. Aquests diagrames permeten descriure l’arquitectura del projecte en diferents nivells de detall. En primer lloc, el diagrama de context mostra el sistema complet i la seva relació amb els actors i sistemes externs. En segon lloc, el diagrama de contenidors concreta els principals blocs interns que formen part del repositori i del pipeline.



Figura 12 Diagrama C4 Context

El diagrama de context situa el pipeline com a sistema central del projecte. L'actor principal és l'investigador o usuari del pipeline, que interactua amb el repositori, consulta la documentació i executa les diferents etapes del procés. També s'hi representen els sistemes externs utilitzats durant el desenvolupament, com el Genomic Data Commons per a l'obtenció de dades transcriptòmiques i, si escau, Synapse com a font de recursos o informació complementària.

Aquest primer nivell permet entendre el paper del projecte dins del seu entorn. El pipeline no funciona de manera aïllada, sinó que depèn de fonts de dades externes, d'un repositori de codi i d'una documentació associada. Per aquest motiu, el diagrama de context ajuda a mostrar la relació entre l'usuari, les dades, el codi i la documentació generada.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**




Figura 13. Diagrama C4 Contenedors

El diagrama de contenidors aprofundeix en l'estructura interna del projecte. En aquest nivell es representen els principals blocs del repositori: els scripts d'execució, els mòduls reutilitzables, els notebooks d'anàlisi, els directoris de dades, els resultats generats i la documentació tècnica. Aquesta vista permet entendre com es reparteixen les responsabilitats dins del projecte i com circula la informació entre les diferents parts.

Els scripts defineixen les etapes executables del pipeline. Els mòduls de `src/` encapsulen la lògica reutilitzable, com la càrrega de dades, el preprocessament, l'entrenament dels models i l'avaluació. Els notebooks s'utilitzen com a suport per a l'exploració, la validació visual i la interpretació dels resultats. Finalment, la documentació generada amb MkDocs recull les decisions tècniques i facilita que el projecte pugui ser entès i reproduït per terceres persones.

Aquesta estructura modular permet separar clarament el codi executable del codi reutilitzable i de la documentació. També facilita l'evolució del projecte, ja que cada etapa pot ser modificada o ampliada sense alterar necessàriament la resta del pipeline. Aquesta decisió és especialment important en un projecte orientat a la reproductibilitat, on cal mantenir una traçabilitat clara entre dades d'entrada, processos aplicats i resultats obtinguts.

### **6.1.3 Documentació tècnica amb MkDocs**

Des de l'inici del desenvolupament s'ha considerat necessari documentar el projecte en paral·lel a la implementació.

Per aquest motiu, s'ha seleccionat MkDocs amb el tema Material com a sistema de documentació. Aquesta eina permet generar un lloc web estàtic a partir de fitxers Markdown i ofereix una estructura clara, navegable i fàcilment actualitzable. Dins del directori “docs/”, cada etapa del pipeline disposa de la seva pròpia pàgina, on es descriuen l'objectiu de la fase, les decisions adoptades, els paràmetres configurables i els resultats més rellevants.

El resultat és una documentació accessible des del navegador i útil tant per al seguiment del projecte com per a la seva futura reproducció. Això permet que una tercera persona pugui entendre l'estructura general del pipeline i les principals decisions de desenvolupament sense haver d'analitzar directament el codi font.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**




Figura 14. Lloc web de documentació desplegat a GitHub Pages

## 6.1.4 Automatització amb GitHub Actions

Per evitar un procés manual de desplegament cada vegada que s’actualitza la documentació, s’ha configurat un flux de treball amb GitHub Actions que automatitza la publicació del lloc generat amb MkDocs. Aquesta automatització s’executa cada vegada que es fa “push” a la branca principal del repositori.

El flux de treball construeix la documentació i en publica el resultat a gh-pages, que és la branca utilitzada per GitHub Pages per servir el lloc web. D’aquesta manera, la versió publicada de la documentació reflecteix en tot moment l’estat actual de main, sense necessitat d’intervenció manual.




Figura 15. GitHub Actions executant-se correctament

## 6.1.5 Estratègia de control de versions amb Git

El control de versions s'ha plantejat com un mecanisme de seguiment i de traçabilitat del desenvolupament. La branca main conté sempre una versió funcional i documentada del projecte, i és la base sobre la qual es desplega automàticament la documentació.

El desenvolupament de cada fase es realitza en una branca específica amb un esquema de noms del tipus feat/etapaN-nom-descriptiu, com ara feat/etapa2-preprocessament. Quan una fase es considera completada, verificada i documentada, s'integra a main mitjançant el procés corresponent. Aquest esquema permet aïllar canvis, reduir errors i mantenir una evolució ordenada del projecte.

Dins de cada branca s'han utilitzat commits, de manera que cada commit correspon a un o uns canvis concrets, com ara la incorporació d'un nou mòdul, una modificació de configuració o una actualització de documentació. Aquesta disciplina facilita la reconstrucció del procés de desenvolupament i permet identificar amb precisió quan i per què s'ha introduït cada canvi rellevant.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**




Figura 16. Mostra dels commits i branques de GitHub

## 6.2 Descàrrega de dades del GDC


### 6.2.1 La cohort TCGA-COAD i el portal GDC

El punt de partida del projecte és un conjunt de dades públic procedent de The Cancer Genome Atlas (TCGA), iniciativa impulsada pel National Cancer Institute dels Estats Units per recopilar i harmonitzar dades moleculars de múltiples tipus de tumors. Dins d'aquest marc, la cohort seleccionada per al desenvolupament del pipeline ha estat TCGA-COAD (Colon Adenocarcinoma), que agrupa mostres corresponents a adenocarcinoma de còlon.

L'accés a aquestes dades es realitza a través del Genomic Data Commons (GDC) Data Portal, plataforma que centralitza i estandarditza els fitxers generats en projectes com TCGA. Aquest portal permet aplicar filtres específics segons el tipus de cohort, la naturalesa de l'experiment o el format de quantificació. En el projecte, la selecció s'ha restringit a la cohort TCGA-COAD, a experiments de RNA-seq i a fitxers de quantificació STAR-Counts amb anotació GENCODE v36, en modalitat unstranded. Amb aquests criteris, la consulta ha retornat 483 fitxers de comptatge gènic, un per mostra.

## APRENENTATGE AUTOMÀTIC APLICAT A BIOINFORMÀTICA

El resultat d'aquesta selecció s'exporta en forma de fitxer manifest "gdc\_manifest.txt". Aquest document no conté les dades en brut, sinó la informació necessària per recuperar-les de manera exacta, un identificador únic de cada fitxer (UUID), el nom, la mida i el resum MD5 corresponent. Aquesta distinció és rellevant des del punt de vista metodològic, ja que el manifest és un fitxer lleuger, apte per ser versionat dins del repositori, mentre que les dades originals ocupen diversos gigabytes i queden fora del control de versions.



```
mrivero@ThinkPadL13: ~/tcga-coad-cms-ml-pipeline/data/metadata
(tcga-coad-cms-ml-pipeline) mrivero@ThinkPadL13: ~/tcga-coad-cms-ml-pipeline/data/metadata$ cat gdc_manifest.2026-03-09.191818.txt
id      filename      md5      size      state
f7710149-0fc6-464a-93cb-e3b9bdcf3525  d9780581-dfca-4e83-9bb4-4836f22d910e  rna_seq.augmented_star_gene_counts.tsv  0322f762090e53965c964b763ce9cd7c  4204474 released
9e159c7f-39ac-4051-83db-983d3aeba5a9  eb67b977-b299-4bbc-b3f6-25d516473405  rna_seq.augmented_star_gene_counts.tsv  e8822385915d04e3f6578d51efd3894b  4239347 released
2063302d-2b9d-4550-8426-fb64f5ea89d1  db087000-74fa-4044-812f-01842b99f448  rna_seq.augmented_star_gene_counts.tsv  67bfff0bcb7e69b9cf608afa49cf32b0e  4201072 released
a44fa392-54c2-480b-b342-e3e9e8340a8f  de2e0c63-0c2d-43af-a006-7d84557a1c3c  rna_seq.augmented_star_gene_counts.tsv  7650ca1353b8acfc8a0b8c19fa3db710  4243733 released
31951036-bbb7-4f77-bce9-358a0ecd65ef  06114a88-396c-4815-8949-910e46345e47  rna_seq.augmented_star_gene_counts.tsv  1a62d41ae84243571005da81af010d25  4190933 released
c5f88d08-c755-403c-97a1-d0863d06a56b  2eaa09cd-8e3e-4de9-ab96-7a298d780a01  rna_seq.augmented_star_gene_counts.tsv  72b550cc712b9c61fb79c0c9bd27b467  4234693 released
57824d48-ad20-4ed1-a5d4-e458e9a75b46  7bcfb173-3054-42a1-8664-d0d074e4018c  rna_seq.augmented_star_gene_counts.tsv  4f509487189cd0b532dab3c27b46e43a  4226009 released
29085234-bd19-4a74-971e-730ad79f7e9a  89fa1644-e0e3-4d75-9250-b5eb4fb07593  rna_seq.augmented_star_gene_counts.tsv  73dfcd71758a90c970b305b6903732af  4243360 released
c2a9c773-efc2-46a3-a043-bb2985c03e2  7e314d4a-7158-4d60-a431-013abe183071  rna_seq.augmented_star_gene_counts.tsv  6a0f5b8b62717b428b07c857f1e24605  4226540 released
dde6631e-ef66-4db4-a7cb-be94f4b9c4fd  3d97737f-01a1-43f1-ba35-ee7cc84dc7ff  rna_seq.augmented_star_gene_counts.tsv  ae6da256bbce9e47844f95b5813fd674  4212937 released
785ff3a1-fff1-41fb-0c1e-21e538e407f5  fec205e8-388c-47a2-9400-ec9fce0efab1  rna_seq.augmented_star_gene_counts.tsv  cd0560643d0ad594817875cd5bb0204  4222213 released
08c9b174-59f5-4d74-8f01-99fbd2531f20  bd844a66-bb61-4ba1-9301-1bdec35620f  rna_seq.augmented_star_gene_counts.tsv  6c49113e3daef7c4faad1f34f79da22b  4217642 released
c4ac41f0-1880-4fc0-a9e9-69856a6c373d  349c48ca-ced2-42db-8a50-ea3293116623  rna_seq.augmented_star_gene_counts.tsv  960b7d2e383a90e08216426a9223e77b  4207707 released
8116cc59-d87d-4af5-9d62-05721ff9b340  2cec663c-00c8-48b5-967b-f2a53c8fb409  rna_seq.augmented_star_gene_counts.tsv  9159f6bbf6146ba8117b1ff72abd1680  4248181 released
fbf0b466-f383-441f-84ff-2513b6792b90  425dc52d-fb29-45d5-8d94-aab524136a83  rna_seq.augmented_star_gene_counts.tsv  b79ac32c5084b821c644b6f66cb5ebc2  4242225 released
21b76e1c-1129-4c97-8c87-a7fcd5251e5f  d7472c45-93c1-4237-82ac-c17e803b9a58  rna_seq.augmented_star_gene_counts.tsv  b2850d3de1046d37920290ec5b41d1f8  4210189 released
daba767c-5d22-4de1-81ba-8ad8f5626465  f27982fa-6d1b-476c-b91b-580f5c1bb034  rna_seq.augmented_star_gene_counts.tsv  67c270b22c09080298892706e2a73717  4239695 released
b064060e-4182-4737-0158-caa0454c411b  8f45c6c4-b98d-4e0b-9ab0-b5be3b94076d  rna_seq.augmented_star_gene_counts.tsv  361ea8d3f04102c06048c4b598989c43  4178265 released
1083938a-4277-49dc-a4a8-f8c3af7313e5  085e4228-8ed7-44d7-9ab5-8a09643ab650  rna_seq.augmented_star_gene_counts.tsv  95984d500a2ac18444f07eed59d18b76  4231843 released
ab6d59e0-21c2-4273-b094-3596d1b8b825  c874c481-cff8-4e2d-99b1-3b5aaeac8b8e  rna_seq.augmented_star_gene_counts.tsv  86b9d6c4d00495590553e874367dbd47  4205071 released
c10bd95e-b75b-4d47-a103-9c259dcf1a19  12b633ae-2a36-40b0-a4a3-c1d5f021fa23  rna_seq.augmented_star_gene_counts.tsv  d4c64e301ed291b5f02720d06bba262a  4210950 released
a77adf63-487b-476e-bd33-9030051cd8a9  0f35c851-1cb8-4f75-a661-eae9111b7362  rna_seq.augmented_star_gene_counts.tsv  aac5e0b7ed85c89f985d46bc3386bd22  4241366 released
00cdf2f9-697a-4a17-ba67-cf55c006b827  66e5440a-6b08-43cc-b007-82ac3f5221d1  rna_seq.augmented_star_gene_counts.tsv  6e11a571f9613040434b6262e2628b69  4238897 released
ea26486f-efa5-427f-ba0c-e1868773dcb6  c8c7600d-2c13-4df1-b058-2d02432bd49e  rna_seq.augmented_star_gene_counts.tsv  4f9639a7ecab8b0da8db9b17f145a2c  4216302 released
2c73d8ac-84b9-4094-9f5e-fbd6c28eabaf
```

Figura 17. Fitxer gdc\_manifest.txt mostrant les primeres línies

La incorporació del manifest al repositori garanteix la reproduïbilitat. En la pràctica, el manifest actua com una instantània exacta del conjunt de dades utilitzat al projecte. Això garanteix que qualsevol persona que disposi del repositori pugui descarregar exactament les mateixes mostres i reconstruir el mateix punt de partida experimental.

### 6.2.2 El client gdc-client i l'automatització de la descàrrega

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**




Figura 18. Diagrama C4 Etapa 1: Descàrrega

La descàrrega manual de 483 fitxers a través del navegador no és una opció viable en un entorn de treball reproducible, tant pel temps requerit com per la manca de traçabilitat i audibilitat del procés. Per aquest motiu, s'ha utilitzat gdc-client, l'eina oficial proporcionada pel GDC per a la descàrrega massiva des de línia de comandes. Aquesta eina interpreta el fitxer manifest i recupera automàticament tots els fitxers especificats, verificant-ne la integritat mitjançant el resum MD5 associat a cadascun.

El principal inconvenient pràctic és que gdc-client no forma part de l'entorn Python del projecte, sinó que es distribueix com un binari extern amb versions específiques per a Linux, macOS i Windows. Per evitar passos manuals de configuració i garantir un comportament homogeni entre plataformes, s'ha implementat un mòdul específic "src/gdc\_utils.py" encarregat d'automatitzar aquest procés. Aquest mòdul detecta el sistema operatiu, descarrega la versió adequada del client, n'extreu el binari i el deixa preparat dins del directori "tools/gdc-client/". Si el client ja és present al sistema, el reutilitza directament.

Aquesta lògica d'autoinstal·lació permet que l'execució de l'etapa de descàrrega sigui transparent per a l'usuari. En la pràctica, és suficient executar l'script corresponent perquè el

procés s'executi sense configuració prèvia. El directori “tools/”, on es desa el binari extern, queda exclòs del repositori mitjançant “.gitignore”, ja que es tracta d'un recurs regenerable i no d'un artefacte propi del projecte.

Un cop tenim el client, l'script de descàrrega crida al gdc-client amb el manifest i amb “data/raw/gdc/” com a directori de destí. L'eina descarrega cada mostra dins d'un subdirectori identificat pel seu UUID i, en finalitzar cada transferència, comprova automàticament la integritat del fitxer comparant el seu MD5 amb el valor registrat al manifest. Aquesta verificació aporta robustesa al procés, ja que permet detectar incidències de xarxa o descàrregues incompletes i repetir únicament els fitxers afectats.

Com a resultat, el directori “data/raw/gdc/” queda organitzat en una estructura jeràrquica formada per un subdirectori per mostra, cadascun dels quals conté el fitxer TSV de comptatge gènic. Aquesta estructura constitueix la base per a l'etapa de preprocessament, en què es construirà la matriu d'expressió a partir d'aquests fitxers.

## 6.3 Preprocessament de les dades RNA-seq




Figura 19. Diagrama C4 Etapa 2: Preprocessament

Aquest apartat descriu el procés de construcció del conjunt de dades utilitzat pel pipeline a partir dels fitxers de comptatge descarregats del GDC. El preprocessament inclou la integració de les mostres en una única matriu d'expressió, la neteja de registres no vàlids, la depuració de mostres

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

problemàtiques, la incorporació d'etiquetes CMS procedents d'una font externa i la definició del conjunt final sobre el qual es durà a terme l'entrenament dels models.

### **6.3.1 Integració dels fitxers de comptatge**

Un cop descarregats els 483 fitxers de comptatge gènic, el primer pas del preprocessament consisteix a integrar-los en una única estructura de dades que pugui ser utilitzada per la resta del pipeline. Cada fitxer TSV correspon a una sola mostra i conté aproximadament 60.664 files, una per gen, juntament amb diverses columnes de quantificació. La columna seleccionada per a l'anàlisi és unstranded, ja que conté els comptatges en brut de lectures assignades a cada gen sense distingir la cadena d'ARN d'origen.

Aquesta decisió respon al fet que les columnes alternatives, com ara `tpm_unstranded` o `fpm_unstranded`, ja incorporen normalitzacions prèvies per longitud gènica i profunditat de seqüenciació. L'ús d'aquests valors impediria aplicar de manera controlada les transformacions i els criteris de preprocessament definits dins del propi pipeline. Per aquest motiu, s'ha optat per treballar amb comptatges en brut, que constitueixen el punt de partida més adequat per a un flux d'anàlisi reproducible.

El procés d'integració consisteix a llegir els 483 fitxers, extreure'n la columna unstranded i combinar-les en una matriu comuna en què cada fila representa un gen i cada columna una mostra. El resultat inicial és una matriu de dimensions 60.664 gens  $\times$  483 mostres. Per identificar correctament cada mostra, s'utilitza el sample sheet del GDC, que permet associar el UUID de cada fitxer amb l'identificador del cas corresponent.

### **6.3.2 Filtratge inicial i tractament de les dades**

Abans de continuar amb el preprocessament, cal eliminar diversos elements que no formen part del senyal biològic rellevant per al problema de classificació. En primer lloc, cada fitxer de comptatge incorpora quatre files especials —`N_unmapped`, `N_multimapping`, `N_noFeature` i

N\_ambiguous— que no corresponen a gens reals, sinó a estadístiques del procés d'alineament. Si es mantinguessin dins de la matriu, els algorismes de classificació les tractarien com si fossin variables biològiques, introduint soroll artificial. Per aquest motiu, s'eliminen sistemàticament com a primer pas de neteja.

A continuació, es depuren les mostres problemàtiques a partir de la informació continguda al sample sheet. En concret, s'exclouen 13 mostres FFPE (formalin-fixed, paraffin-embedded), ja que aquest mètode de preservació pot alterar el perfil transcriptòmic i introduir variabilitat tècnica no desitjada. També s'eliminen 1 mostra metastàtica i 1 mostra de recurrència, atès que l'objectiu del projecte és treballar exclusivament amb tumors primaris.

Un tercer pas de depuració afecta els casos duplicats. En el conjunt inicial hi ha 10 pacients amb dues mostres vàlides. Per mantenir una única observació per pacient, es conserva la mostra amb major profunditat de seqüenciació, mesurada a partir de la suma total de comptatges, ja que és la que previsiblement conté més informació útil. Després d'aquest procés de neteja, la matriu queda reduïda a 458 mostres úniques, una per pacient.

En aquesta mateixa fase s'ha incorporat també la informació relativa als subtipus CMS, necessària per a l'aprenentatge supervisat. Inicialment es va assumir que aquestes etiquetes formarien part de les metadades disponibles al GDC, però la revisió del portal va posar de manifest que aquesta suposició era incorrecta. El GDC ofereix metadades clíniques estàndard, però no les etiquetes CMS, ja que aquestes no formen part del diagnòstic clínic oficial, sinó d'una classificació molecular proposada en la literatura científica.

Per resoldre aquesta mancança, es va recórrer al repositori Synapse del consorci CMS, des d'on es va obtenir el fitxer cms\_labels\_public\_all.txt. Atès que es tracta d'un fitxer lleuger i de caràcter públic, es va decidir incorporar-lo directament al repositori dins de data/metadata/, de manera que actués com a referència permanent i traçable per al pipeline. Aquest fitxer conté 573 mostres TCGA corresponents a COAD i READ, de les quals 459 disposen d'una etiqueta CMS vàlida i 114 apareixen marcades com a no classificables.

La integració d'aquestes etiquetes es duu a terme mitjançant un inner join entre la matriu d'expressió i el fitxer de metadades CMS. Aquest pas elimina automàticament les mostres sense

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

etiqueta vàlida i produeix un conjunt final de 370 mostres etiquetades, que constitueix la base sobre la qual s'entrenaran i s'avaluaran els models de classificació.

### **6.3.3 Transformacions aplicades**

Un cop definit el conjunt de mostres vàlides, el pas següent consisteix a establir la separació entre els conjunts d'entrenament i test. Aquesta decisió s'ha adoptat abans d'aplicar qualsevol transformació dependent dels valors de les dades, amb l'objectiu d'evitar situacions de data leakage. Si les estadístiques necessàries per al preprocessament es calculessin sobre el conjunt complet, la informació del test influiria indirectament sobre la construcció del model i les mètriques finals quedarien esbiaixades.

Per aquest motiu, el dataset etiquetat de 370 mostres es divideix en una proporció 80/20, obtenint 296 mostres d'entrenament i 74 mostres de test. La partició es fa de manera estratificada, de manera que la proporció de cada subtipus CMS es manté en ambdós conjunts. Aquesta precaució és especialment rellevant en el cas de CMS3, que representa el subtipus minoritari i podria quedar infrarepresentat si la divisió fos completament aleatòria. La fixació de la llavor 42 permet reproduir exactament la mateixa partició en execucions posteriors.

A partir del conjunt d'entrenament es defineixen també les transformacions de filtratge gènic que s'aplicaran a ambdós conjunts. En primer lloc, es restringeix l'anàlisi als gens codificants de proteïna, reduint la dimensionalitat inicial i descartant variables que queden fora de l'objectiu funcional del projecte. Sobre aquest subconjunt s'aplica posteriorment un criteri de comptatge mínim, mantenint només aquells gens que presenten un nivell d'expressió suficient en una fracció significativa de les mostres d'entrenament. Aquest procediment elimina gens amb expressió esporàdica o residual, que tendeixen a aportar poc senyal discriminatiu i augmenten el risc de sobreajustament.

Finalment, sobre els comptatges filtrats s'aplica la transformació  $\log_2(x + 1)$ , que redueix l'asimetria característica de les dades RNA-seq i comprimeix el rang dinàmic dels valors d'expressió. Aquesta transformació facilita l'ús posterior de tècniques de reducció de dimensionalitat i de classificació, ja que evita que els gens molt altament expressats dominin l'estructura numèrica del conjunt de dades.

### **6.3.4 Decisions adoptades durant el preprocessament**

El preprocessament ha estat condicionat per diverses decisions metodològiques que convé fer explícites. La primera és l'elecció de treballar amb comptatges en brut (unstranded) i no amb mesures ja normalitzades com TPM o FPKM. Aquesta decisió permet conservar el control sobre les transformacions aplicades i evitar dependències respecte a normalitzacions prèvies alienes al disseny del pipeline.

La segona decisió rellevant és la depuració estricta del conjunt de mostres, amb exclusió de mostres FFPE, mostres no primàries i casos duplicats. Aquesta neteja prioritza la coherència biològica del dataset per sobre del volum màxim de dades disponibles, amb l'objectiu de reduir la variabilitat tècnica i de garantir una única observació per pacient.

Una tercera decisió important deriva d'un error inicial de planificació: la suposició que les etiquetes CMS formarien part de les metadades del GDC. La necessitat d'incorporar-les des d'una font externa va obligar a modificar el disseny previst i a introduir un pas addicional d'integració de metadades. Tot i això, aquesta correcció no s'ha resolt de manera manual i puntual, sinó amb una estratègia traçable, basada en un fitxer de referència incorporat explícitament al repositori.

Finalment, la decisió de fer la partició train/test abans de qualsevol transformació dependent de les dades constitueix un principi central de tot el pipeline. Aquest criteri garanteix que el conjunt de test es mantingui completament aïllat fins al moment de l'avaluació final i que els resultats obtinguts reflecteixin de manera més fidel el comportament esperable davant de dades noves.

## **6.4 Anàlisi exploratori i reducció de dimensionalitat**

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Aquest apartat recull les verificacions realitzades sobre el conjunt de dades preprocessat i les tècniques d'exploració emprades per inspeccionar-ne l'estructura. L'objectiu no és encara entrenar models predictius, sinó comprovar que el preprocessament ha produït una matriu coherent, detectar possibles incidències i valorar si les dades contenen senyal suficient per distingir els subtipus CMS.

### **6.4.1 Verificacions inicials de qualitat**

Un cop definida la partició entre entrenament i test i aplicades les transformacions pertinents, es comprova que la matriu resultant presenti les propietats esperades. En aquest punt, el conjunt d'entrenament conté els gens seleccionats després del filtratge funcional i del filtratge per expressió mínima, així com els valors transformats en escala logarítmica. La verificació inicial se centra a confirmar que les dimensions de la matriu siguin coherents, que no existeixin valors nuls o infinits i que el rang numèric de les expressions sigui compatible amb el preprocessament aplicat.

Dins d'aquesta fase es revisa també l'efecte del filtratge per baixa expressió. L'objectiu és eliminar variables que augmenten la dimensionalitat sense aportar capacitat discriminativa significativa. En el conjunt d'entrenament, aquest criteri redueix substancialment el nombre de gens i millora la relació entre senyal i soroll. En termes pràctics, això facilita les etapes posteriors d'exploració i classificació i redueix el risc de sobreajustament.

La transformació  $\log_2(x + 1)$  també es valida visualment mitjançant histogrames i estadístiques descriptives. Les dades RNA-seq en brut presenten habitualment una distribució fortament esbiaixada cap a la dreta, amb molts gens de baixa expressió i uns pocs gens amb comptatges molt elevats. L'escala logarítmica redueix aquesta asimetria i produeix una distribució més adequada per a l'anàlisi posterior.




Figura 20. Histograma amb nombre de mostres que expressen cada gen

### 6.4.2 Exploració de l'estructura de les dades

Un cop verificada la coherència numèrica del conjunt de dades, es planteja una qüestió central: si les mostres preprocessades contenen prou estructura interna perquè els subtipus CMS puguin ser diferenciats. Per explorar aquesta pregunta s'ha desenvolupat el notebook `notebooks/data_exploration.ipynb`, que actua com a espai d'anàlisi visual i reutilitza directament les funcions implementades als mòduls del projecte.

La primera tècnica aplicada és l'Anàlisi de Components Principals (PCA), que permet obtenir una projecció lineal de les mostres en un espai de menor dimensionalitat. El PCA es calcula exclusivament sobre el conjunt d'entrenament i posteriorment s'aplica al conjunt de test, respectant així el mateix criteri d'aïllament utilitzat durant el preprocessament. Aquesta decisió és important, ja que ajustar el PCA sobre totes les mostres introduiria informació del test en la definició dels components principals.

La projecció sobre els primers components mostra una separació parcial entre els subtipus. En particular, les mostres corresponents a CMS1 i CMS2 tendeixen a agrupar-se en regions relativament diferenciades, mentre que CMS3 i CMS4 presenten més solapament. Aquest

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

resultat suggereix que el senyal biològic existeix, però també que la classificació no respon a categories completament separades en l'espai d'expressió.

Per complementar aquesta visió lineal, s'ha aplicat també UMAP, tècnica de reducció de dimensionalitat no lineal orientada a preservar millor l'estructura local del dataset. La representació obtinguda mostra una organització més gradual de les mostres, amb una disposició en què alguns subtipus ocupen extrems diferenciats i d'altres apareixen en posicions intermèdies amb cert grau de continuïtat. Aquesta observació és coherent amb la naturalesa dels subtipus CMS, que no necessàriament constitueixen clústers completament disjunts, sinó regions d'un espai transcriptòmic continu.

En conjunt, tant el PCA com l'UMAP apunten a la mateixa conclusió: el dataset conté estructura suficient per justificar l'entrenament de models de classificació, però també reflecteix una dificultat intrínseca del problema, especialment en els subtipus amb més solapament.

### **6.4.3 Incidències detectades i correccions adoptades**

Durant l'exploració es va detectar una incidència interpretativa relacionada amb la distribució dels valors d'expressió després de la transformació logarítmica. En una versió inicial de la documentació del notebook s'havia assumit que l'histograma resultant havia de mostrar una distribució bimodal, amb un primer pic corresponent a gens poc expressats i un segon associat a gens més actius. Tanmateix, les dades obtingudes mostraven una distribució unimodal, centrada aproximadament en valors intermedis de l'escala logarítmica.

En un primer moment, aquesta discrepància es va interpretar com un possible error en el preprocessament. No obstant això, una revisió més detallada va permetre identificar que l'expectativa inicial era incorrecta. El filtratge previ per baixa expressió havia eliminat precisament els gens que haurien contribuït al primer pic de la distribució. Per tant, la presència

d'una distribució unimodal no indicava una anomalia, sinó una conseqüència esperable del procés de selecció gènica aplicat.

Aquesta incidència es va resoldre corregint la documentació del notebook i reformulant la interpretació dels histogrames. El cas posa de manifest la utilitat de l'anàlisi exploratòria no només com a mecanisme de visualització, sinó també com a instrument de validació conceptual. En aquest sentit, el notebook no ha servit únicament per observar l'estructura de les dades, sinó també per detectar i corregir malentesos abans que aquests condicionessin decisions posteriors del pipeline.

## 6.5 Entrenament dels models

Aquest apartat descriu la fase d'entrenament dels models d'aprenentatge automàtic utilitzats per classificar les mostres segons els subtipus moleculars CMS. Aquesta etapa parteix del conjunt de dades preprocessat anteriorment, ja dividit en conjunt d'entrenament i conjunt de test, i té com a objectiu generar models comparables sota les mateixes condicions experimentals.

L'entrenament no es planteja com una cerca de nous algorismes ni com el desenvolupament d'una metodologia pròpia de classificació, sinó com un benchmark controlat de models supervisats clàssics. Aquesta decisió és coherent amb l'abast del projecte, que estableix la comparació de diversos models sota un mateix esquema de preprocessament i partició de dades, sense desenvolupar arquitectures noves ni models d'aprenentatge profund.

### 6.5.1 Construcció del conjunt d'entrenament

El procés d'entrenament utilitza com a entrada la matriu d'expressió generada durant el preprocessament. Aquesta matriu conté les mostres filtrades, les etiquetes CMS integrades i els valors d'expressió transformats a escala logarítmica. Abans d'entrenar els models, les dades ja han estat separades en dos subconjunts: un conjunt d'entrenament, emprat per ajustar els models, i un conjunt de test, reservat exclusivament per a l'avaluació final.

Aquesta separació és una decisió metodològica central del pipeline. El conjunt de test no participa en cap transformació dependent de les dades ni en cap decisió d'entrenament.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

D'aquesta manera, l'avaluació posterior reflecteix de manera més fidel el comportament dels models davant de mostres no utilitzades durant l'aprenentatge.

El conjunt d'entrenament és, per tant, l'únic conjunt utilitzat per aprendre els patrons d'expressió associats als subtipus CMS. Les etiquetes de classe corresponen als quatre subtipus moleculars principals: CMS1, CMS2, CMS3 i CMS4. Cada mostra queda representada per un vector de valors d'expressió gènica, i cada vector té associada una etiqueta CMS.

## **6.5.2 Models implementats**

S'han implementat tres models supervisats de classificació: regressió logística, Random Forest i Support Vector Machine. La selecció d'aquests models respon a l'objectiu de comparar aproximacions clàssiques, representatives i interpretables dins d'un context de dades d'alta dimensionalitat.


La regressió logística s'utilitza com a model lineal de referència. Tot i la seva simplicitat, és útil per establir una base comparativa i comprovar fins a quin punt la separació entre subtipus pot ser capturada mitjançant fronteres lineals en l'espai de característiques.

Random Forest s'inclou com a model basat en un conjunt d'arbres de decisió. Aquest enfocament permet capturar relacions no lineals entre variables i és especialment útil quan es treballa amb moltes característiques. A més, és un model robust davant de soroll i pot gestionar interaccions complexes entre gens sense requerir una transformació explícita prèvia.

Support Vector Machine s'incorpora com a model supervisat orientat a trobar fronteres de separació entre classes. Aquest model és habitual en problemes amb moltes variables i un nombre relativament reduït de mostres, situació freqüent en dades transcriptòmiques.

Els tres models s'entrenen sobre el mateix conjunt de dades i sota el mateix esquema de partició. Això permet que les diferències observades posteriorment en el rendiment siguin atribuïbles al

comportament dels models i no a diferències en el preprocessament o en la composició de les dades.




### 6.5.3 Script d'entrenament

L'entrenament dels models s'executa mitjançant l'script `train.py`, situat al directori `scripts/`. Aquest script actua com a punt d'entrada de l'etapa i coordina les funcions necessàries per carregar les dades preprocessades, inicialitzar els models, entrenar-los i desar els artefactes resultants.

La lògica específica de suport es troba encapsulada dins dels mòduls reutilitzables del directori `src/`. Aquesta separació evita duplicar codi i manté la coherència amb l'arquitectura general del projecte. Els scripts defineixen el flux d'execució, mentre que els mòduls de `src/` contenen les funcions reutilitzables.

Aquest disseny permet executar l'entrenament de manera independent, però també facilita la seva integració dins del pipeline complet. Així, l'usuari pot executar només aquesta etapa si les dades preprocessades ja existeixen, o bé executar tot el flux des de la descàrrega fins a l'avaluació.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**



```
mrivero@ThinkPadL13: ~/tcga-coad-cms-ml-pipeline
Archivo  Editar  Ver  Buscar  Terminal  Ayuda
(tcga-coad-cms-ml-pipeline) mrivero@ThinkPadL13: ~/tcga-coad-cms-ml-pipeline$ python3 scripts/train.py
22:14:31 [INFO] — Stage 4: Model training —
22:14:31 [INFO] processed-dir : /home/mrivero/tcga-coad-cms-ml-pipeline/data/processed
22:14:31 [INFO] output-dir : /home/mrivero/tcga-coad-cms-ml-pipeline/data/models
22:14:31 [INFO] results-dir : /home/mrivero/tcga-coad-cms-ml-pipeline/results
22:14:31 [INFO] models : logistic_regression, random_forest, svm
22:14:31 [INFO] random seed : 42
22:14:31 [INFO] Loading processed data from /home/mrivero/tcga-coad-cms-ml-pipeline/data/processed (suffix='none')
22:14:32 [INFO] Loaded — X train: (296, 15625), X test: (74, 15625), y_train: (296,), y_test: (74,)
22:14:32 [INFO] Full dataset loaded — 296 samples x 15625 genes
22:14:32 [INFO] CMS distribution in train: {'CMS1': 57, 'CMS2': 116, 'CMS3': 43, 'CMS4': 80}
22:14:32 [INFO] Training logistic_regression ...

22:17:21 [INFO] logistic regression — train accuracy: 1.0000, time: 168.6 s
22:17:21 [INFO] Model saved to /home/mrivero/tcga-coad-cms-ml-pipeline/data/models/logistic_regression.joblib
22:17:21 [INFO] Training random forest ...
22:17:22 [INFO] random_forest — train accuracy: 1.0000, time: 0.8 s
22:17:22 [INFO] Model saved to /home/mrivero/tcga-coad-cms-ml-pipeline/data/models/random_forest.joblib
22:17:22 [INFO] Training svm ...
22:17:23 [INFO] svm — train accuracy: 1.0000, time: 0.6 s
22:17:23 [INFO] Model saved to /home/mrivero/tcga-coad-cms-ml-pipeline/data/models/svm.joblib
22:17:23 [INFO] — Training unbalanced variants (class_weight=None) —
```

Figura 21. Execució de l'script train.py des de la terminal.

## 6.5.4 Control de reproductibilitat en l'entrenament

Per garantir que els resultats siguin reproduïbles, els models s'entrenen amb una configuració fixa sempre que l'algorisme ho permet. En particular, s'utilitzen llavors aleatòries definides en els punts del pipeline on hi ha processos estocàstics, com la partició de dades o l'entrenament de models que incorporen aleatorietat interna.

Aquest control és especialment rellevant en models com Random Forest, ja que el procés de construcció dels arbres pot variar si no es fixa una llavor. La fixació de la configuració permet repetir l'execució i obtenir resultats consistents, sempre que es mantinguin les mateixes dades, dependències i versions de l'entorn.

La reproductibilitat no depèn únicament de l'ús de llavors. També queda reforçada per la definició explícita de l'entorn Conda, la separació modular del codi, la traçabilitat del repositori i l'emmagatzematge dels fitxers intermedis necessaris per reconstruir el flux d'execució.

### 6.5.5 Artefactes generats

Com a resultat de l'entrenament, el pipeline genera els models ajustats i els fitxers necessaris per a la fase posterior d'avaluació. Aquests artefactes permeten separar clarament el moment d'entrenament del moment d'avaluació.

Els models entrenats es desen en fitxers persistents, de manera que poden ser reutilitzats sense necessitat de repetir tot el procés d'aprenentatge. Aquesta decisió és útil tant per reduir temps d'execució com per facilitar la verificació posterior dels resultats.

A més dels models, es poden generar fitxers auxiliars amb informació sobre les prediccions, les classes reals o la configuració utilitzada. Aquests fitxers constitueixen l'entrada natural de l'etapa d'avaluació, on es calcularan les mètriques de rendiment i es construiran les taules i figures comparatives.

### 6.5.6 Tancament de l'etapa d'entrenament

L'etapa d'entrenament transforma el conjunt de dades preprocessat en un conjunt de models supervisats preparats per ser avaluats. El resultat no és encara la conclusió sobre quin model és millor, sinó la generació controlada dels artefactes que permetran fer aquesta comparació en la fase següent.

Aquesta separació entre entrenament i avaluació és important perquè manté el pipeline organitzat en etapes independents. Primer es construeixen els models sota condicions homogènies i, posteriorment, s'avaluen amb les mateixes mètriques i sobre el mateix conjunt de test. D'aquesta manera, el projecte manté una estructura clara i reproducible.

## 6.6 Avaluació del pipeline

Aquest apartat descriu l'etapa d'avaluació dels models entrenats. Aquesta fase constitueix l'última etapa funcional del pipeline i té com a objectiu aplicar els models sobre el conjunt de test per obtenir mesures quantitatives del seu rendiment.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

L'avaluació s'ha dissenyat com una fase separada de l'entrenament. Aquesta separació permet mantenir una estructura modular, facilita la traçabilitat dels resultats i evita barrejar el procés d'ajust dels models amb la seva validació final. D'aquesta manera, els models s'entrenen en una etapa prèvia i, posteriorment, s'avaluen de manera homogènia sobre el mateix conjunt de dades.


L'etapa d'avaluació no modifica els models ni les dades d'entrada. La seva funció és carregar els artefactes generats durant l'entrenament, aplicar-los al conjunt de test i generar els fitxers de sortida necessaris per a l'anàlisi posterior dels resultats.

### **6.6.1 Objectiu de l'etapa d'avaluació**

L'objectiu principal de l'etapa d'avaluació és obtenir una mesura comparable del rendiment dels models implementats. Per aquest motiu, tots els models s'avaluen sobre el mateix conjunt de test i amb les mateixes mètriques.

Aquesta decisió permet comparar els resultats de manera coherent. Si cada model fos avaluat amb dades diferents o amb criteris diferents, la comparació no seria metodològicament vàlida. En canvi, l'ús d'un conjunt de test comú permet observar les diferències entre models sota les mateixes condicions experimentals.

L'avaluació també permet generar evidències quantitatives sobre el comportament del pipeline. Aquestes evidències es materialitzen en taules de mètriques, prediccions i figures de suport, que posteriorment s'utilitzen en el capítol d'anàlisi de resultats.



## 6.6.2 Entrada de l'etapa d'avaluació

L'etapa d'avaluació rep com a entrada els models entrenats durant la fase anterior i el conjunt de test generat en el preprocessament. Aquest conjunt de test conté les mostres reservades per a l'avaluació final i les etiquetes CMS reals associades a cada mostra.

Aquesta separació entre conjunt d'entrenament i conjunt de test és essencial per estimar el comportament dels models davant de dades no utilitzades durant l'aprenentatge. El conjunt de test no s'utilitza per ajustar els models, sinó únicament per calcular-ne el rendiment final.

Cada model genera una predicció per a cada mostra del conjunt de test. Aquestes prediccions es comparen amb les etiquetes reals per calcular les mètriques d'avaluació. El resultat d'aquest procés permet mesurar fins a quin punt cada model és capaç de reproduir correctament la classificació CMS assignada a les mostres.

## 6.6.3 Mètriques utilitzades

Per avaluar els models s'utilitzen mètriques habituals en problemes de classificació supervisada. Aquestes mètriques permeten analitzar el rendiment global dels models i també el seu comportament respecte a les diferents classes CMS.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

La primera mètrica considerada és l'exactitud, o *accuracy*. Aquesta mètrica indica la proporció de mostres classificades correctament respecte al total de mostres avaluades. És una mesura útil per obtenir una visió general del rendiment del model, però pot ser insuficient quan les classes no estan equilibrades.

Per aquest motiu, també es calculen mètriques complementàries com la precisió, el record i l'F1-score. La precisió mesura quantes de les mostres assignades a una classe determinada són realment d'aquella classe. El record mesura quantes de les mostres reals d'una classe han estat identificades correctament pel model. L'F1-score combina precisió i record en una única mètrica, i resulta especialment útil quan es vol valorar l'equilibri entre totes dues.

A més de les mètriques agregades, també es generen matrius de confusió. Aquestes matrius permeten observar de manera visual quines classes es classifiquen correctament i quines classes es confonen entre elles. Aquesta informació és rellevant perquè dos models poden tenir una exactitud global similar, però presentar patrons d'error diferents.

En conjunt, aquestes mètriques proporcionen una visió més completa del rendiment dels models que una única mesura global. Els valors concrets obtinguts s'analitzen posteriorment en el capítol de resultats.

#### **6.6.4 Script d'avaluació**

L'avaluació s'executa mitjançant l'script `evaluate.py`, situat al directori `scripts/`. Aquest script actua com a punt d'entrada de l'etapa i coordina la càrrega dels models entrenats, la lectura del conjunt de test i el càlcul de les mètriques.

L'ús d'un script específic per a l'avaluació manté la coherència amb l'estructura modular del pipeline. Cada etapa del procés disposa d'un punt d'entrada propi, fet que facilita l'execució individual de les fases i també la seva integració dins del pipeline complet.

Durant l'execució, l'script carrega els models prèviament desats, aplica cada model sobre les mostres del conjunt de test i recull les prediccions obtingudes. A partir d'aquestes prediccions i de les etiquetes reals, es calculen les mètriques definides a l'apartat anterior.

Aquesta automatització evita haver de calcular manualment els resultats de cada model i redueix el risc d'errors en la comparació. També permet repetir l'avaluació de manera consistent sempre que es mantinguin les mateixes dades, els mateixos models i la mateixa configuració de l'entorn.

```

(tcg-coad-cms-ml-pipeline) mrivero@ThinkPadL13:~/tcga-coad-cms-ml-pipeline$ python scripts/evaluate.py
14:56:12 [INFO] -- Stage 5: Model evaluation --
14:56:12 [INFO] processed-dir : /home/mrivero/tcga-coad-cms-ml-pipeline/data/processed
14:56:12 [INFO] models-dir : /home/mrivero/tcga-coad-cms-ml-pipeline/data/models
14:56:12 [INFO] output-dir : /home/mrivero/tcga-coad-cms-ml-pipeline/results
14:56:12 [INFO] figures-dir : /home/mrivero/tcga-coad-cms-ml-pipeline/figures
14:56:12 [INFO] Loading processed data from /home/mrivero/tcga-coad-cms-ml-pipeline/data/processed (suffix='none')
14:56:13 [INFO] Loaded - X train: (296, 15625), X test: (74, 15625), y_train: (296,), y_test: (74,)
14:56:13 [INFO] Test set - 74 samples x 15625 genes, classes: ['CMS1', 'CMS2', 'CMS3', 'CMS4']
14:56:13 [INFO] Loaded logistic regression from /home/mrivero/tcga-coad-cms-ml-pipeline/data/models/logistic_regression.joblib
14:56:13 [INFO] Loaded random forest from /home/mrivero/tcga-coad-cms-ml-pipeline/data/models/random_forest.joblib
14:56:13 [INFO] Loaded svm from /home/mrivero/tcga-coad-cms-ml-pipeline/data/models/svm.joblib
14:56:13 [INFO] Evaluating logistic regression ...
14:56:14 [INFO] logistic_regression accuracy=0.9459 F1_macro=0.9428 F1_weighted=0.9453
14:56:14 [INFO] Evaluating random forest ...
14:56:14 [INFO] random_forest accuracy=0.8514 F1_macro=0.8245 F1_weighted=0.8438
14:56:14 [INFO] Evaluating svm ...
14:56:14 [INFO] svm accuracy=0.9595 F1_macro=0.9540 F1_weighted=0.9594
14:56:14 [INFO] Confusion matrix saved to /home/mrivero/tcga-coad-cms-ml-pipeline/figures/confusion_matrix_logistic_regression.png
14:56:14 [INFO] Confusion matrix saved: /home/mrivero/tcga-coad-cms-ml-pipeline/figures/confusion_matrix_logistic_regression.png
14:56:14 [INFO] Confusion matrix saved to /home/mrivero/tcga-coad-cms-ml-pipeline/figures/confusion_matrix_random_forest.png
14:56:14 [INFO] Confusion matrix saved: /home/mrivero/tcga-coad-cms-ml-pipeline/figures/confusion_matrix_random_forest.png
14:56:15 [INFO] Confusion matrix saved to /home/mrivero/tcga-coad-cms-ml-pipeline/figures/confusion_matrix_svm.png
14:56:15 [INFO] Confusion matrix saved: /home/mrivero/tcga-coad-cms-ml-pipeline/figures/confusion_matrix_svm.png
14:56:15 [INFO] Metrics comparison saved to /home/mrivero/tcga-coad-cms-ml-pipeline/figures/metrics_comparison.png
14:56:15 [INFO] Metrics comparison saved: /home/mrivero/tcga-coad-cms-ml-pipeline/figures/metrics_comparison.png
14:56:15 [INFO] F1 per class saved to /home/mrivero/tcga-coad-cms-ml-pipeline/figures/f1_per_class.png
14:56:15 [INFO] F1 per class saved: /home/mrivero/tcga-coad-cms-ml-pipeline/figures/f1_per_class.png
14:56:15 [INFO] Benchmark table:
Benchmark table:
      Accuracy  F1 macro  F1 weighted  F1 CMS1  F1 CMS2  F1 CMS3  F1 CMS4
Model
Logistic Regression  0.945946  0.942825  0.945332  0.9333  0.9667  0.9524  0.9189
Random Forest      0.851351  0.824548  0.843806  0.8667  0.8923  0.7059  0.8333
SVM (linear)       0.959459  0.954033  0.959442  0.9333  0.9831  0.9524  0.9474
14:56:15 [INFO] Evaluation report saved to /home/mrivero/tcga-coad-cms-ml-pipeline/results/evaluation_report.json
14:56:15 [INFO] Evaluation report saved: /home/mrivero/tcga-coad-cms-ml-pipeline/results/evaluation_report.json
14:56:15 [INFO] -- Summary --
14:56:15 [INFO] Model          Accuracy  F1 macro  F1 weighted
-----
14:56:15 [INFO] logistic_regression  0.9459  0.9428  0.9453
14:56:15 [INFO] random_forest      0.8514  0.8245  0.8438
14:56:15 [INFO] svm                0.9595  0.9540  0.9594
14:56:15 [INFO] Figures saved to /home/mrivero/tcga-coad-cms-ml-pipeline/figures
  
```

Figura 22. Execució de l'script evaluate.py

## 6.6.5 Fitxers i figures generats

Com a resultat de l'etapa d'avaluació, el pipeline genera diversos fitxers de sortida. Aquests fitxers recullen les prediccions dels models, les mètriques calculades i les figures necessàries per interpretar el comportament dels classificadors.


**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Les prediccions permeten conservar, per a cada mostra del conjunt de test, la classe real i la classe assignada pel model. Aquest fitxer és útil perquè permet revisar posteriorment quines mostres han estat classificades correctament i en quins casos s’han produït errors.

Les taules de mètriques resumeixen el rendiment dels models de manera quantitativa. Aquestes taules faciliten la comparació entre classificadors i constitueixen la base de l’anàlisi posterior. En aquest apartat només es descriu la seva generació; la interpretació dels valors es reserva per al capítol de resultats.

Les figures generades, com ara les matrius de confusió o els gràfics comparatius, permeten representar visualment el comportament dels models. Aquestes figures són útils per detectar patrons d’error i diferències entre classificadors que poden no ser evidents observant únicament les mètriques agregades.

Aquest conjunt d’artefactes fa que l’avaluació sigui traçable. Cada resultat numèric o visual pot relacionar-se amb un model concret, un conjunt de test determinat i una execució específica del pipeline.



```
mrivero@ThinkPadL13: ~/tcga-coad-cms-ml-pipeline
Archivo Editar Ver Buscar Terminal Ayuda
(tcga-coad-cms-ml-pipeline) mrivero@ThinkPadL13:~/tcga-coad-cms-ml-pipeline$ ls results/
evaluation_report.json  evaluation_report_minimal_no_lowexpr_no_log2.json  predictions_minimal_no_lowexpr_no_log2.csv
(tcga-coad-cms-ml-pipeline) mrivero@ThinkPadL13:~/tcga-coad-cms-ml-pipeline$ ls figures/
confusion_matrix_logistic_regression.png  confusion_matrix_svm.png  f1_per_class.png  metrics_comparison.png
confusion_matrix_random_forest.png      f1_per_class_full_pipeline.png  global_metrics_full_pipeline.png
(tcga-coad-cms-ml-pipeline) mrivero@ThinkPadL13:~/tcga-coad-cms-ml-pipeline$
```

*Figura 23. Fitxers generats per l’etapa d’avaluació.*

## 6.6.6 Tancament de l’etapa d’avaluació

L’etapa d’avaluació tanca el flux principal del pipeline. A partir dels models entrenats i del conjunt de test, aquesta fase genera els resultats necessaris per comparar el rendiment dels diferents classificadors.

La separació entre entrenament i avaluació permet mantenir una estructura clara i reproduïble. Els models es construeixen en una etapa específica i s'avaluen posteriorment sota les mateixes condicions. Aquesta organització facilita la revisió del procés i permet repetir l'avaluació sense haver de modificar la resta del pipeline.

Els fitxers generats en aquesta etapa constitueixen la base del capítol següent. En el capítol d'anàlisi de resultats s'estudien les mètriques obtingudes, les diferències entre models i les limitacions detectades durant el procés experimental.

### **6.7 Resultats i validació de les hipòtesis**

Aquest apartat presenta els resultats finals obtinguts amb el pipeline desenvolupat. A diferència dels apartats anteriors, centrats en la implementació de cada etapa, aquí s'analitza la sortida obtinguda després d'executar el flux complet: preprocessament, entrenament i avaluació dels models.

L'objectiu d'aquest apartat és comparar el rendiment dels classificadors entrenats, identificar possibles diferències entre subtipus CMS i resoldre les hipòtesis plantejades per a l'avaluació. Per mantenir una comparació homogènia, tots els models s'han entrenat i avaluat amb el mateix conjunt de dades, el mateix esquema de partició train/test i la mateixa configuració general del pipeline.

#### **6.7.1 Resultat del conjunt de dades final**

Després de la integració de les dades d'expressió RNA-seq amb les etiquetes CMS, el conjunt final utilitzat pel pipeline està format per 370 mostres etiquetades. Aquest conjunt es divideix en una proporció 80/20, amb 296 mostres destinades a entrenament i 74 mostres reservades per al conjunt de test. La partició es realitza de manera estratificada i amb la llavor fixa 42, de manera que la distribució dels subtipus CMS es manté en ambdós subconjunts i es pot reproduir la mateixa divisió en execucions posteriors.

Després del filtratge i de les transformacions aplicades durant el preprocessament, la matriu preprocessada final conserva 15.625 variables, i el conjunt de test utilitzat per a l'avaluació té

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

74 mostres descrites per aquestes mateixes variables, corresponents als gens seleccionats. Les classes considerades són CMS1, CMS2, CMS3 i CMS4.

| Element                         | Valor                  |
|---------------------------------|------------------------|
| Mostres totals amb etiqueta CMS | 370                    |
| Mostres d'entrenament           | 296                    |
| Mostres de test                 | 74                     |
| Nombre de variables finals      | 15.625                 |
| Classes                         | CMS1, CMS2, CMS3, CMS4 |

*Taula 1. Resum del conjunt de dades final utilitzat pel pipeline*

La distribució de classes no és uniforme. CMS2 és el subtipus amb més representació i CMS3 és el menys representat. Per aquest motiu, l'avaluació no es basa únicament en l'accuracy, sinó que utilitza el F1 macro com a mètrica principal, ja que aquesta mètrica dona el mateix pes a totes les classes.

| Subtipus | Mostres totals | Percentatge aproximat |
|----------|----------------|-----------------------|
| CMS1     | 71             | 19%                   |
| CMS2     | 145            | 39%                   |
| CMS3     | 54             | 15%                   |
| CMS4     | 100            | 27%                   |

*Taula 2. Distribució de mostres per subtipus CMS*

## 6.7.2 Resultats globals dels models

La taula següent resumeix el rendiment global dels tres models entrenats: Logistic Regression, Random Forest i SVM lineal. Les mètriques principals són accuracy, F1 macro i F1 weighted. També s'hi inclou el F1-score per a cada subtipus CMS, ja que permet observar si el rendiment és homogeni entre classes o si algun model presenta dificultats en un subtipus concret.

| Model               | Accuracy | F1 macro | F1 weighted | F1 CMS1 | F1 CMS2 | F1 CMS3 | F1 CMS4 |
|---------------------|----------|----------|-------------|---------|---------|---------|---------|
| Logistic Regression | 0,945946 | 0,942825 | 0,945332    | 0,9333  | 0,9667  | 0,9524  | 0,9189  |
| Random Forest       | 0,851351 | 0,824548 | 0,843806    | 0,8667  | 0,8923  | 0,7059  | 0,8333  |
| SVM Lineal          | 0,959459 | 0,954033 | 0,959442    | 0,9333  | 0,9831  | 0,9524  | 0,9474  |

Taula 3. Resultats globals i F1-score per subtipus dels models avaluats

Els resultats mostren que SVM lineal obté el millor rendiment global, amb una accuracy de 0,959459 i un F1 macro de 0,954033. Logistic Regression obté resultats molt propers, amb una accuracy de 0,945946 i un F1 macro de 0,942825. Random Forest queda per sota en totes les mètriques globals, especialment en F1 macro.

Aquests resultats indiquen que els dos models lineals són els que millor generalitzen sobre el conjunt de test en aquesta configuració experimental. Random Forest, tot i ser un model capaç de capturar relacions no lineals, no obté en aquest cas el millor rendiment. Aquesta diferència s'ha d'interpretar dins del context del projecte: es treballa amb moltes més variables que mostres.

Aquest resultat és coherent amb un escenari d'alta dimensionalitat i nombre reduït de mostres, on els models lineals poden resultar competitius respecte a models més flexibles com Random Forest.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**




Figura 24. Comparació de mètriques globals dels models.

### 6.7.3 Resultats per subtipus CMS i patrons d'error

L'anàlisi per classe permet observar que el rendiment dels models no és uniforme per a tots els subtipus CMS. Aquesta lectura és especialment important perquè una mètrica global pot ocultar errors concentrats en una classe minoritària.

Logistic Regression presenta un rendiment alt en totes les classes, amb valors de F1 superiors a 0,91 en tots els subtipus. Els millors resultats els obté en CMS2 i CMS3, mentre que CMS4 és el subtipus amb el F1 més baix dins d'aquest model.

SVM lineal també presenta un comportament molt equilibrat. Obté el millor F1 macro global i mostra valors elevats en tots els subtipus, especialment en CMS2 i CMS4. En CMS3 obté el mateix F1 que Logistic Regression, amb un valor de 0,9524.

Random Forest mostra un comportament més desigual. El valor més baix apareix en CMS3, amb un F1 de 0,7059, clarament inferior al dels altres models. Aquesta diferència indica que el

model té més dificultats per recuperar correctament les mostres reals d'aquest subtipus. Els resultats per classe mostren que Random Forest obté una precision de 1,0000 en CMS3 però un recall de 0,5455; això significa que, quan prediu CMS3, ho fa correctament, però deixa sense recuperar una part important de les mostres reals d'aquest subtipus.

| Model               | CMS1   | CMS2   | CMS3   | CMS4   | Mitjana classes |
|---------------------|--------|--------|--------|--------|-----------------|
| Logistic Regression | 0,9333 | 0,9667 | 0,9524 | 0,9189 | 0,9428          |
| Random Forest       | 0,8667 | 0,8923 | 0,7059 | 0,8333 | 0,8245          |
| SVM lineal          | 0,9333 | 0,9831 | 0,9524 | 0,9474 | 0,9540          |

Taula 4. F1-score per subtipus CMS i mitjana per model

Les matrius de confusió permeten aprofundir en aquests patrons d'error. En el cas de Logistic Regression i SVM lineal, la major part de les mostres del conjunt de test es classifiquen correctament. En canvi, Random Forest concentra més errors i presenta confusions especialment rellevants en CMS3 i CMS4.




Figura 25. F1-score per subtipus CMS.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**




Figura 26. Matriu de confusió de Random Forest




Figura 27. Matriu de confusió de SVM




Figura 28. Matriu de confusió de Logistic Regression

### 6.7.4 Validació de les hipòtesis

Per complementar la comparació descriptiva de les mètriques, s’han definit cinc hipòtesis d’avaluació. Aquestes hipòtesis permeten contrastar si les diferències observades entre models són consistents amb les dades disponibles i si el preprocessament complet aporta una millora respecte a una versió minimal del pipeline.

En aquest apartat s’utilitzen dues formes d’evidència estadística. En primer lloc, s’utilitza bootstrap per estimar intervals de confiança del 95 % sobre diferències de F1 macro. Aquesta és l’evidència principal en les hipòtesis formulades sobre F1 macro, ja que el F1 macro és la mètrica principal del benchmark. En segon lloc, s’utilitza el test exacte de McNemar com a evidència complementària per comparar patrons d’encert i error entre dos classificadors aplicats sobre les mateixes mostres.

En aquesta anàlisi, McNemar s’utilitza per comparar encerts i errors aparellats, mentre que el bootstrap s’utilitza per estimar intervals de confiança de les mètriques i de les diferències entre mètriques.

El llindar de significació utilitzat és  $\alpha = 0,05$ . Quan el criteri estadístic definit per una hipòtesi permet rebutjar la hipòtesi nul·la, s’indica que **es rebutja  $H_0$** . Quan aquest criteri no es compleix, s’indica que **no es pot rebutjar  $H_0$** . No s’utilitza l’expressió “s’accepta  $H_0$ ”, perquè un resultat no significatiu no demostra que la hipòtesi nul·la sigui certa; només indica que no hi ha

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

evidència suficient per rebutjar-la amb les dades disponibles. Aquest criteri també queda definit al notebook d'avaluació.

#### **6.7.4.1 Definició de la notació**

Segui  $D_{test}$  el conjunt de test, format per 74 mostres. Per a cada model  $m$ , es defineix:

$$F_m = F1_{macro}(m)$$

On  $F_m$  representa el F1 macro del model  $m$  sobre el conjunt de test.

Per comparar dos models  $A$  i  $B$ , es defineix la diferència:

$$\Delta_{A-B} = F_A - F_B$$

Si  $\Delta_{A-B} > 0$ , el model  $A$  obté un F1 macro superior al model  $B$ . Si  $\Delta_{A-B} < 0$ , el model  $B$  obté un F1 macro superior al model  $A$ .

Per a les proves basades en bootstrap, es generen 2000 re-mostrejos del conjunt de test i es calcula un interval de confiança del 95 % per a la diferència de F1 macro. Una diferència es considera positiva i consistent quan l'interval de confiança és completament superior a zero. Si l'interval inclou el zero, la diferència es considera no conclouent. S'han utilitzat 2000 iteracions bootstrap i un llindar  $\alpha = 0,05$ .

En el cas de la hipòtesi d'equivalència entre Logistic Regression i SVM lineal, s'utilitza un marge d'equivalència pràctica:

$$\varepsilon = 0,02$$

Aquest marge indica que diferències absolutes inferiors a 0,02 punts de F1 macro es consideren metodològicament poc rellevants en aquest experiment.

## 6.7.4.2 Hipòtesis formulades

| Hipòtesi | Objectiu                                                             | Hipòtesi nul·la                      | Hipòtesi alternativa              | Evidència principal                                                      | Evidència complementària               |
|----------|----------------------------------------------------------------------|--------------------------------------|-----------------------------------|--------------------------------------------------------------------------|----------------------------------------|
| H1       | Comparar Logistic Regression amb Random Forest                       | $\Delta_{LR-RF} \leq 0$              | $\Delta_{LR-RF} > 0$              | Bootstrap de $\Delta_{F1_{macro}}$                                       | McNemar exacte                         |
| H2       | Comparar SVM lineal amb Random Forest                                | $\Delta_{SVM-RF} \leq 0$             | $\Delta_{SVM-RF} > 0$             | Bootstrap de $\Delta_{F1_{macro}}$                                       | McNemar exacte                         |
| H3       | Avaluar equivalència pràctica entre Logistic Regression i SVM lineal | $ \Delta_{LR-SVM}  \geq \varepsilon$ | $ \Delta_{LR-SVM}  < \varepsilon$ | IC bootstrap de $\Delta_{LR-SVM}$ dins de $[-\varepsilon, +\varepsilon]$ | Concordança de prediccions aparellades |
| H4       | Avaluar si CMS3 és més difícil que la resta de subtipus              | $\Delta_{CMS3} \geq 0$               | $\Delta_{CMS3} < 0$               | Bootstrap de $\Delta_{CMS3}$ per model                                   | F1 per classe i matriu de confusió     |
| H5       | Avaluar l'impacte del preprocessament complet                        | $\Delta_{full-minimal} \leq 0$       | $\Delta_{full-minimal} > 0$       | Bootstrap de $\Delta_{F1_{macro}}$                                       | McNemar exacte                         |

Taula 5. Formulació estadística de les hipòtesis d'avaluació

En aquesta taula, *LR* fa referència a Logistic Regression, *RF* a Random Forest i *SVM* a SVM lineal.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Per a H4, la diferència es defineix de la manera següent:

$$\Delta_{CMS3,m} = F1_{CMS3,m} - \text{mean}(F1_{CMS1,m}, F1_{CMS2,m}, F1_{CMS4,m})$$

on  $m$  representa cadascun dels models. Si  $\Delta_{CMS3,m} < 0$ , CMS3 presenta un F1 inferior a la mitjana de la resta de classes per aquell model. Si l'interval de confiança bootstrap és completament negatiu, es considera que la dificultat de CMS3 és consistent per aquell model.

Per a H5, la diferència es defineix com:

$$\Delta_{full-minimal,m} = F1_{macro,full,m} - F1_{macro,minimal,m}$$

On *full* representa el pipeline complet i *minimal* representa la versió sense filtratge de gens amb baixa expressió i sense transformació  $\log_2(x + 1)$ . Aquest criteri s'ha aplicat de manera sistemàtica en l'avaluació

### 6.7.4.3 Criteris de decisió

Per a H1, H2 i H5, el criteri principal de decisió és l'interval de confiança bootstrap de la diferència de F1 macro. Es rebutja  $H_0$  quan el límit inferior de l'interval de confiança és superior a zero:

$$IC_{95\%}(\Delta) = [L, U]$$

Es rebutja  $H_0$  si  $L > 0$

Aquesta condició indica que la diferència positiva observada no depèn només d'una mostra concreta del conjunt de test, sinó que és consistent sota el procediment de re-mostreig.

El test exacte de McNemar s'utilitza com a evidència complementària. Per a dos classificadors  $A$  i  $B$ , es compten les mostres discordants:

$b$  = nombre de mostres on  $A$  encerta i  $B$  falla

$c$  = nombre de mostres on  $A$  falla i  $B$  encerta

McNemar contrasta si els errors discordants estan equilibrats. En una prova unilateral a favor d' $A$ , la hipòtesi alternativa és que  $b > c$ . Tot i això, aquest test no mesura directament el F1 macro, sinó la diferència en patrons d'encert/error. Per aquest motiu, no s'utilitza com a única evidència per resoldre hipòtesis formulades sobre F1 macro.

Per a H3, el criteri és diferent perquè es tracta d'una hipòtesi d'equivalència pràctica. No n'hi ha prou amb observar que la diferència entre models és petita. Cal que tot l'interval de confiança de  $\Delta_{LR-SVM}$  quedi dins del marge d'equivalència:

$$IC_{95\%}(\Delta_{LR-SVM}) \subset [-\varepsilon, +\varepsilon]$$

Amb  $\varepsilon = 0,02$ , això significa que l'interval ha de quedar completament dins de:

$$[-0,02, +0,02]$$

Si l'interval surt d'aquest marge, no es pot afirmar equivalència pràctica, encara que la diferència observada sigui petita.

Per a H4, la resolució global requereix que la dificultat de CMS3 sigui consistent en tots els models. Per tant:

Es rebutja  $H_0$  globalment si tots els models tenen  $IC_{95\%}(\Delta_{CMS3,m}) < 0$

Si només un model presenta una diferència negativa consistent, la resolució seria parcial. Si cap model presenta un interval completament negatiu, no es pot rebutjar  $H_0$ .

#### 6.7.4.4 Resultats estadístics de les hipòtesis

| Hipòtesi | $\Delta$ observat | IC 95% Bootstrap | McNemar      | Resolució        |
|----------|-------------------|------------------|--------------|------------------|
| H1       | +0,1183           | [0.0444, 0.2159] | p = 0,007812 | Es rebutja $H_0$ |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

|           |           |                           |              |                                    |
|-----------|-----------|---------------------------|--------------|------------------------------------|
| <b>H2</b> | +0,1295   | [0.0517,<br>0.2288]       | p = 0,003906 | Es rebutja $H_0$                   |
| <b>H3</b> | -0,0112   | [-0.0405,<br>0.0000]      | p = 1,0000   | Equivalència no concloent          |
| <b>H4</b> | Per model | Veure taula<br>específica | No aplica    | No es pot rebutjar                 |
| <b>H5</b> | Per model | Veure taula<br>específica | Per model    | Evidència parcial a favor<br>de H1 |

*Taula 6. Resultats estadístics de les hipòtesis d'avaluació*

Els resultats de H1 mostren una diferència observada de F1 macro de +0,1183 a favor de Logistic Regression respecte a Random Forest. L'interval de confiança bootstrap és [0,0444, 0,2159], completament superior a zero. A més, McNemar dona un p-value de 0,007812. Per tant, es rebutja  $H_0$  i es conclou que Logistic Regression supera Random Forest en aquesta configuració experimental.

Els resultats de H2 mostren una diferència observada de F1 macro de +0,1295 a favor de SVM lineal respecte a Random Forest. L'interval de confiança bootstrap és [0,0517, 0,2288], també completament superior a zero. McNemar dona un p-value de 0,003906. Per tant, es rebutja  $H_0$  i es conclou que SVM lineal supera Random Forest.

En H3, la diferència observada entre Logistic Regression i SVM lineal és petita:  $\Delta_{LR-SVM} = -0,0112$ . Tot i això, l'interval de confiança bootstrap és [-0,0405, 0,0000], i no queda completament dins del marge d'equivalència [-0,02, +0,02]. Per tant, no es pot afirmar

equivalència pràctica entre els dos models. La resolució correcta és **equivalència no concloent**, no “models equivalents”.

#### 6.7.4.5 Resultat específic de H4

| Model               | F1 CMS3 | F1 mitjà resta | $\Delta$ CMS3 | IC 95% inferior | IC 95% superior | Interpretació           |
|---------------------|---------|----------------|---------------|-----------------|-----------------|-------------------------|
| Logistic Regression | 0,9524  | 0,9396         | +0,0127       | −0,1053         | 0,0991          | Diferència no concloent |
| Random Forest       | 0,7059  | 0,8641         | −0,1582       | −0,4656         | 0,0450          | Diferència no concloent |
| SVM                 | 0,9524  | 0,9546         | −0,0022       | −0,1179         | 0,0768          | Diferència no concloent |

Taula 7. Contrast de la dificultat de classificació de CMS3 respecte a la resta de subtipus

En Random Forest, CMS3 presenta un F1 clarament inferior a la mitjana de la resta de classes. Tanmateix, l’interval de confiança bootstrap inclou el zero. En Logistic Regression i SVM lineal, la diferència tampoc és estadísticament concloent. Per tant, no es pot rebutjar  $H_0$  en H4. Això significa que, amb les dades disponibles, no es pot afirmar que CMS3 sigui de manera consistent més difícil de classificar que la resta de subtipus.

#### 6.7.4.6 Resultat específic de H5

| Model               | $\Delta$ F1 observat | Mitjana bootstrap | IC 95 % inferior | IC 95 % superior | Interpretació           |
|---------------------|----------------------|-------------------|------------------|------------------|-------------------------|
| Logistic Regression | +0,0885              | +0,0910           | −0,0014          | 0,1883           | Diferència no concloent |
| Random Forest       | +0,0026              | +0,0012           | −0,0609          | 0,0508           | Diferència no concloent |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

|            |         |         |        |        |                                   |
|------------|---------|---------|--------|--------|-----------------------------------|
| <b>SVM</b> | +0,1514 | +0,1551 | 0,0523 | 0,2631 | Diferència positiva<br>consistent |
|------------|---------|---------|--------|--------|-----------------------------------|

*Taula 8. Contrast de l'impacte del preprocessament complet respecte al pipeline*

El preprocessament complet millora descriptivament el F1 macro dels tres models, però aquesta millora només és estadísticament consistent en SVM lineal. En Logistic Regression, la diferència observada és positiva, però l'interval de confiança inclou lleugerament el zero. En Random Forest, la diferència és molt petita i també no concloent.

El test de McNemar reforça aquesta interpretació. Per SVM lineal, el p-value és 0,003693 i es rebutja  $H_0$ . En canvi, per Logistic Regression el p-value és 0,054688 i per Random Forest és 0,500000, de manera que no es pot rebutjar  $H_0$  en aquests dos models.

Per tant, la resolució de  $H_5$  és parcial. No es pot afirmar que el preprocessament complet millori de manera estadísticament consistent tots els models. Sí que es pot afirmar que millora de manera consistent el rendiment de SVM lineal i que mostra una millora descriptiva en Logistic Regression.

#### 6.7.4.7 Síntesi de la validació estadística

| Hipòtesi  | Resolució final                           | Interpretació                                                                             |
|-----------|-------------------------------------------|-------------------------------------------------------------------------------------------|
| <b>H1</b> | Es rebutja $H_0$                          | Logistic Regression supera Random Forest en F1 macro de manera consistent                 |
| <b>H2</b> | Es rebutja $H_0$                          | SVM lineal supera Random Forest en F1 macro de manera consistent                          |
| <b>H3</b> | No es pot demostrar equivalència pràctica | Logistic Regression i SVM lineal són molt propers, però l'IC excedeix el marge $\epsilon$ |

|           |                              |                                                                                                                  |
|-----------|------------------------------|------------------------------------------------------------------------------------------------------------------|
| <b>H4</b> | No es pot rebutjar $H_0$     | CMS3 no queda demostrat com a subtipus més difícil de manera global                                              |
| <b>H5</b> | Es rebutja $H_0$ parcialment | El preprocessament complet millora SVM lineal de manera consistent, però no Logistic Regression ni Random Forest |

Taula 9. Resolució final de les hipòtesis amb criteri estadístic

### 6.7.5 Síntesi dels resultats

Els resultats obtinguts mostren que el pipeline desenvolupat permet entrenar, avaluar i comparar models de classificació CMS sota condicions homogènies. El conjunt de test utilitzat per a l'avaluació conté 74 mostres i 15.625 variables, fet que reflecteix un escenari d'alta dimensionalitat i nombre reduït de mostres, habitual en dades d'expressió gènica.

SVM lineal és el model amb millor rendiment global, amb una accuracy de 0,959459 i un F1 macro de 0,954033. Logistic Regression obté resultats molt propers i manté un rendiment elevat en totes les classes. Random Forest queda per sota dels dos models lineals, principalment per la seva menor capacitat de recuperar les mostres CMS3.

La validació de les hipòtesis confirma que els dos models lineals superen Random Forest en aquesta configuració experimental. No obstant això, no es pot afirmar una equivalència pràctica concloent entre Logistic Regression i SVM lineal, tot i que les seves prediccions són gairebé idèntiques. Tampoc es pot afirmar que CMS3 sigui de manera consistent el subtipus més difícil per a tots els models, ja que aquesta dificultat es manifesta sobretot en Random Forest.

Finalment, l'anàlisi d'ablació mostra que el preprocessament complet aporta valor, amb una millora estadísticament consistent en SVM lineal i una millora descriptiva en Logistic Regression. Aquest resultat reforça la importància de mantenir un flux de preprocessament controlat abans de l'entrenament dels models.

En conjunt, el pipeline compleix l'objectiu de proporcionar un entorn reproducible i traçable per comparar classificadors supervisats aplicats a la classificació CMS a partir de dades RNA-seq.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## 7. Estudi de viabilitat del projecte

### 7.1 Planificació inicial

La planificació inicial d'aquest projecte s'ha realitzat mitjançant una combinació del diagrama de PERT (Program Evaluation and Review Technique) i el diagrama de Gantt amb l'objectiu d'obtenir una visió complementària tant de la línia temporal de cada tasca, la distribució cronològica com del camí crític.

L'ús del diagrama de PERT està especialment indicat per a projectes de recerca i desenvolupament, caracteritzats per un alt grau d'incertesa en la durada de les seves activitats. Segons Malcolm et al. (1959), PERT permet modelar aquesta incertesa mitjançant l'estimació probabilística de la durada de les tasques, a partir de tres valors: el temps mínim, el temps més probable i el temps màxim [16]. A partir d'aquestes estimacions, Malcolm et al. (1959) proposen el càlcul del temps esperat de cada tasca mitjançant una mitjana ponderada la qual dona més pes al temps més probable.

$$T. \text{esperat} = T_{\min} + 4 T_{\text{prob}} + T_{\max} / 6$$

Aquesta formulació permet obtenir una estimació temporal més realista que una mitjana simple, ja que té en compte la incertesa inherent a les tasques pròpies dels projectes.

En aquest projecte, s'ha usat el diagrama PERT per definir les tasques principals, establir les dependències entre elles i identificar el camí crític del projecte, tal com proposen Malcolm et al. en la seva formulació original del mètode [16].

| ID | Tasca                                        | Mínim | Probable | Màxim | Esperat | Depèn de |
|----|----------------------------------------------|-------|----------|-------|---------|----------|
| A  | Càrrega i gestió de dades d'expressió gènica | 25    | 30       | 40    | 30,8    | -        |
| B  | Preprocessament de dades                     | 55    | 60       | 75    | 61,7    | A        |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

|          |                                                           |    |    |    |      |   |
|----------|-----------------------------------------------------------|----|----|----|------|---|
| <b>C</b> | Reducció de dimensionalitat i exploració de dades         | 35 | 40 | 50 | 40,8 | B |
| <b>D</b> | Entrenament de models d'aprenentatge automàtic            | 60 | 70 | 85 | 70,8 | C |
| <b>E</b> | Optimització i validació dels models                      | 60 | 70 | 90 | 71,7 | D |
| <b>F</b> | Avaluació del rendiment dels models                       | 35 | 40 | 50 | 40,8 | E |
| <b>G</b> | Generació de visualitzacions i interpretació de resultats | 30 | 35 | 45 | 35,8 | F |

Taula 10. Estimació temporal de les tasques del projecte segons el mètode PERT

La base en la construcció del diagrama PERT és una graella de tasques amb les estimacions temporals, on es recullen, per cada tasca, el temps mínim, més probable i màxim. Aquesta taula, permet calcular el temps esperat de cada tasca segons el mètode probabilístic de PERT.

A partir d'aquesta taula, s'ha elaborat el diagrama PERT, el qual representa gràficament la seqüència de tasques, les seves dependències i el camí crític del projecte.




Figura 29. Diagrama PERT del projecte que mostra la seqüència de tasques.

L'anàlisi del diagrama PERT mostra que totes les tasques principals del projecte formen part del camí crític, ja que estan encadenades de manera seqüencial i no disposen de marge temporal entre el temps de començament de la tasca més aviat i el més tardat. Aquest fet és coherent amb la naturalesa del projecte ja que les diferents fases del projecte, acaben constituint un pipeline fortament dependent. Les tasques que no corresponen al camí crític corresponen a tasques transversals com a reproductibilitat i la documentació, les quals es desenvolupen al llarg del projecte i se superposen amb les altres fases. Aquesta estructura confirma que el risc principal de retard del projecte es concentra en les tasques tècniques de la pipeline.

De manera complementària, s'ha usat un diagrama de Gantt per visualitzar la planificació temporal.

Tal com indiquen Malcolm et al. (1959), l'ús combinat d'eines analítiques com el mètode PERT orientat a l'anàlisi de dependències i del camí crític, amb eines de planificació temporal com el diagrama de Gantt, facilita la presa de decisions del projecte [16].

A diferència del diagrama de PERT, el diagrama de Gantt inclou també les tasques de caràcter transversal, com la documentació i l'estructura del codi. Aquestes tasques no s'han representat com activitats crítiques de PERT, ja que aquestes no tenen principi ni fi, sinó que el seu desenvolupament és de manera continuada al llarg del projecte i se superposen amb les diverses fases del pipeline principal.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**




Figura 30. Diagrama de Gantt del projecte que mostra la planificació temporal de les diferents fases.

Les dates assignades a cada etapa s'han estimat de manera proporcional al pes relatiu de cadascuna, segons el temps esperat calculat mitjançant el mètode PERT i respectant les dependències. Això permet una planificació realista, mantenint un cert marge d'adaptació propi d'un projecte de recerca.

|               | Data Inici | Data fi    |
|---------------|------------|------------|
| <b>Etap 1</b> | 19/02/2026 | 24/02/2026 |
| <b>Etap 2</b> | 25/02/2026 | 10/03/2026 |
| <b>Etap 3</b> | 11/03/2026 | 20/03/2026 |
| <b>Etap 4</b> | 21/03/2026 | 07/04/2026 |
| <b>Etap 5</b> | 08/04/2026 | 06/05/2026 |
| <b>Etap 6</b> | 07/05/2026 | 08/05/2026 |

*Taula 11. Temporalització de les etapes del projecte*

En conjunt, l'ús combinat del diagrama de PERT i del diagrama de Gantt proporciona una planificació coherent del projecte.

## 7.2 Pressupost

El pressupost d'aquest projecte s'ha elaborat a partir de la planificació anteriorment tractada.

### 7.2.1 Recursos humans

El principal actiu del projecte és el temps dels recursos humans. El treball té una càrrega de 600 hores les quals inclouen el disseny, la implementació i la documentació.

Per estimar els costos associats al departament de recursos humans, s'ha considerat un salari mitjà de 25 €/hora per a un perfil júnior de bioinformàtica.  $600 \text{ hores} \times 25 \text{ €/hora} = 15.000 \text{ €}$

### 7.2.2 Recursos materials i llicències

En relació amb els recursos materials i llicències, el projecte es desenvolupa usant un ordinador personal amb prou capacitat per al tractament de dades d'expressió gènica i per l'entrenament d'algorismes d'aprenentatge automàtic.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Per estimar els costos associats, s'ha considerat que l'ordinador personal té un valor de 2.000 €, que té una vida útil de cinc anys i que pel desenvolupament d'aquest treball, es requereix un període de sis mesos.

Nombre de mesos en cinc anys. 5 anys 12 mesos = 60 mesos en cinc anys

Cost per mes de l'ordinador.  $2000 \text{ €} / 60 \text{ mesos} = 33,33 \text{ €/mes}$

Cost total de l'ordinador personal.  $6 \text{ mesos } 33,33 \text{ €/mes} = 200 \text{ €}$

Addicionalment, s'ha tingut en compte l'alta demanda elèctrica de l'ordinador a l'entrenar models d'aprenentatge automàtic. Aquest consum s'ha estimat en 15 €, tenint en compte la potència mitjana en alt rendiment i el nombre d'hores d'ús.

En relació amb les llicències de programari, en aquest projecte, per motius de reproductibilitat únicament usarem programari i dades de codi obert. Aquest fet elimina la necessitat d'adquirir llicències de programari propietari.

### 7.2.3 Cost global del projecte

A partir dels recursos necessaris descrits, el cost global estimat es resumeix en la taula següent.

| Recurs             | Cost (€)      |
|--------------------|---------------|
| Recursos humans    | 15.000        |
| Recursos materials | 200           |
| Cost energètic     | 15            |
| <b>Cost total</b>  | <b>15.215</b> |

*Taula 12. Desglossament dels costos estimats del projecte per tipus de recurs*

## **7.3 Viabilitat**

### **7.3.1 Anàlisi de viabilitat tècnica**

Des del punt de vista tècnic, el projecte es considera viable amb els recursos disponibles. El volum de dades d'expressió gènica és prou representatiu i manejable per equips de computació convencionals.

Les tècniques usades, tant pel preprocessament de dades com per l'entrenament i avaluació dels models, estan àmpliament documentades i validades. A més, l'ús de tecnologies consolidades redueix el risc tècnic.

En conseqüència, es considera una solució proposada sense limitacions tècniques i plenament viable.

### **7.3.2 Anàlisi de viabilitat econòmica**

En tractar-se d'un projecte acadèmic, no es planteja un model de negoci ni un estudi de mercat.

S'ha realitzat una estimació del cost total del projecte en l'apartat 6.2. Aquesta estimació permet concloure que el projecte seria econòmicament viable en un context professional.

### **7.3.3 Anàlisi de viabilitat mediambiental**

L'impacte mediambiental és limitat. Tot i que l'aprenentatge automàtic requereix un consum energètic elevat, aquest es restringeix a un ordinador personal i a un nombre d'execucions controlat.

En el context del projecte, es considera que aquest és mediambientalment viable i no genera impacte significatiu.

### **7.3.4 Aspectes Legals**

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Pel que fa als aspectes legals, el projecte compleix la normativa vigent de protecció de dades i propietat intel·lectual. Les dades usades provenen de repositoris públics oficials els quals ofereixen dades anonimitzades.

El projecte es considera una obra acadèmica pròpia de l'estudiant, protegida per la normativa de propietat intel·lectual vigent.

### **7.3.5 Gestió de la diversitat i la perspectiva de gènere**

La gestió de diversitat i perspectiva de gènere té una incidència limitada en aquest projecte a causa de la seva naturalesa tècnica i computacional. El treball no recull dades de sexe, gènere, raça o altres atributs personals, ja que es treballa exclusivament amb dades provinents de repositoris públics.

El projecte inclou una entrevista, recollida als annexos amb l'objectiu de contextualitzar el problema i obtenir una visió experta sobre l'àmbit. L'expert entrevistat ha donat el seu consentiment explícit per a la inclusió de la seva imatge en aquest treball amb finalitats exclusivament acadèmiques.

A més, s'ha tingut en compte que la documentació del projecte que estigui dissenyada de manera clara i accessible per a usuaris amb diferents nivells de coneixement tècnica. La documentació està dissenyada per perfils tant bioinformàtics com tècnics interessats en l'aprenentatge automàtic o l'anàlisi de dades.

En conseqüència, el projecte no discrimina i adopta un enfocament inclusiu.

## 8. Conclusions

Aquest treball ha desenvolupat un pipeline reproduïble per a la classificació dels subtipus moleculars CMS del càncer colorectal a partir de dades d'expressió gènica RNA-seq. El projecte ha integrat en un mateix flux les fases d'obtenció de dades, preprocessament, entrenament de models, avaluació i generació de resultats, mantenint una estructura modular i documentada.

El primer objectiu del projecte era construir un flux de treball clar i reproduïble. Aquest objectiu s'ha assolit mitjançant la definició d'un entorn Conda, la separació del codi en scripts executables i mòduls reutilitzables, l'ús de fitxers de configuració, la documentació del pipeline i la incorporació d'evidències de reproductibilitat. A més, la prova realitzada en Windows 10 mostra que el projecte pot ser reconstruït i executat en un entorn diferent de l'entorn principal de desenvolupament.

Pel que fa al tractament de dades, el pipeline ha permès construir un conjunt final de 370 mostres etiquetades amb subtipus CMS, dividides en 296 mostres d'entrenament i 74 mostres de test. Després del filtratge i de les transformacions aplicades, la matriu final conserva 15.625 variables. Aquest resultat mostra que el flux de preprocessament és capaç de transformar els fitxers de comptatge inicials en una matriu d'expressió apta per a l'entrenament de models supervisats.

En relació amb els models d'aprenentatge automàtic, s'han entrenat i comparat tres classificadors: Logistic Regression, Random Forest i SVM lineal. Els resultats mostren que SVM lineal obté el millor rendiment global, amb una accuracy de 0,959459 i un F1 macro de 0,954033. Logistic Regression obté un resultat molt proper, amb una accuracy de 0,945946 i un F1 macro de 0,942825. Random Forest queda per sota dels dos models lineals, especialment en F1 macro.

La validació estadística de les hipòtesis reforça aquesta lectura. Logistic Regression i SVM lineal superen Random Forest de manera consistent en aquesta configuració experimental. En canvi, tot i que Logistic Regression i SVM lineal presenten resultats molt propers i una alta

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

concordança de prediccions, no es pot afirmar formalment que siguin pràcticament equivalents, ja que l'interval de confiança bootstrap no queda completament dins del marge d'equivalència definit.

L'anàlisi per subtipus CMS mostra que el rendiment dels models no és completament homogeni entre classes. Random Forest presenta una dificultat descriptiva clara en CMS3, però aquesta dificultat no queda confirmada estadísticament com a patró general de tots els models. Per tant, no es pot afirmar que CMS3 sigui de manera consistent el subtipus més difícil de classificar en aquest experiment.

L'anàlisi d'ablació també aporta una conclusió rellevant. El preprocessament complet millora el rendiment de manera estadísticament consistent en SVM lineal i mostra una millora descriptiva en Logistic Regression. En Random Forest, en canvi, la diferència respecte al preprocessament minimal és pràcticament negligible. Aquest resultat indica que les transformacions finals del preprocessament tenen un impacte especialment rellevant en els models lineals.

En conjunt, el projecte compleix l'objectiu principal: establir un pipeline reproducible i traçable per comparar models supervisats aplicats a la classificació CMS a partir de dades RNA-seq. El treball no pretén substituir eines especialitzades de classificació CMS ni proposar un nou model clínic, sinó oferir un entorn controlat per entendre, executar i comparar diferents aproximacions d'aprenentatge automàtic sota les mateixes condicions experimentals.

Finalment, el projecte també posa de manifest la importància de la claredat metodològica en bioinformàtica. En aquest tipus d'anàlisi, els resultats no depenen només del model escollit, sinó també de decisions prèvies com la selecció de dades, el filtratge de mostres, la integració d'etiquetes, la partició train/test i les transformacions aplicades. Per aquest motiu, la traçabilitat del pipeline és un dels principals resultats del treball.

## **9. Possibles ampliacions**

Tot i que el projecte assoleix els objectius plantejats dins de l'abast definit, existeixen diverses línies de continuació que podrien ampliar-ne la utilitat, la robustesa i l'abast metodològic. Aquestes ampliacions deriven principalment dels elements que han quedat fora de l'abast inicial del treball.

### **9.1 Incorporació de dades crues i processament primari**

Una primera ampliació seria incorporar el processament de dades crues, com ara fitxers FASTQ, dins del pipeline. En aquest treball s'ha decidit operar únicament amb matrius d'expressió RNA-seq ja processades, ja que incloure fases com el control de qualitat, l'alineament i la quantificació de lectures hauria incrementat de manera notable la complexitat del projecte.

Com a ampliació futura, es podria afegir una etapa inicial que automatitzés aquest processament primari. Això permetria controlar tot el flux des de les lectures originals fins a la matriu d'expressió final. Aquesta millora augmentaria la traçabilitat completa del procés, però també requeriria més recursos computacionals, més temps d'execució i una validació tècnica més extensa.

### **9.2 Integració de múltiples cohorts i correcció d'efectes de batch**

El projecte actual treballa amb un únic conjunt de dades, la cohort TCGA-COAD, per mantenir un flux homogeni i reduir fonts addicionals de variabilitat. Una ampliació natural seria integrar múltiples cohorts públiques, per exemple dades procedents de TCGA-READ o d'altres repositoris transcriptòmics.

Aquesta ampliació permetria augmentar el nombre de mostres disponibles i avaluar millor la capacitat de generalització dels models. Tanmateix, també obligaria a incorporar estratègies de correcció d'efectes de batch, ja que diferents cohorts poden haver estat generades amb protocols,

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

plataformes o condicions tècniques diferents. Aquesta línia de treball permetria fer una validació més robusta, però requeriria un disseny experimental més complex.

## **9.3 Validació externa dels models**

Una altra ampliació rellevant seria validar els models entrenats sobre un conjunt de dades extern independent. En aquest treball, l'avaluació s'ha realitzat mitjançant una partició train/test dins del mateix conjunt de dades. Aquest enfocament és adequat per comparar models sota condicions controlades, però no permet avaluar completament la capacitat de generalització en cohorts independents.

Una validació externa permetria comprovar si el rendiment observat es manté quan els models s'apliquen a dades procedents d'un altre estudi. Aquesta ampliació seria especialment important si es volgués avançar cap a una aplicació més general del pipeline en contextos de recerca biomèdica.

## **9.4 Comparació amb classificadors CMS especialitzats**

El projecte compara tres models supervisats clàssics entrenats dins del mateix pipeline. Una possible ampliació seria comparar aquests resultats amb eines específiques de classificació CMS, com CMScaller o CMSFFPE.

Aquesta comparació permetria situar el benchmark desenvolupat en relació amb eines ja existents. També ajudaria a valorar fins a quin punt els models entrenats dins del projecte s'aproximen al comportament de classificadors especialitzats. Aquesta ampliació podria aportar una perspectiva més completa sobre la utilitat real del pipeline com a entorn d'anàlisi comparativa.

## **9.10 Síntesi de les ampliacions**

Les ampliacions proposades permetrien evolucionar el projecte en diverses direccions: augmentar l'abast de les dades, reforçar la validació externa, aprofundir en la interpretació biològica, comparar el pipeline amb eines especialitzades i millorar-ne la portabilitat. Tot i això, aquestes línies requereixen més temps, més recursos i un disseny experimental més ampli.

Per aquest motiu, el projecte actual es manté dins d'un abast controlat i coherent amb un Treball Final de Grau. Les possibles ampliacions no substitueixen els objectius assolits, sinó que defineixen camins de continuïtat per transformar el pipeline en una eina més completa i generalitzable.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## 10. Bibliografia

- [1] Guinney, J., Dienstmann, R., Wang, X., et al. The consensus molecular subtypes of colorectal cancer. *Nature Medicine*, 21(11), 1350–1356 (2015). doi:10.1038/nm.3967
- [2] World Health Organization. Colorectal cancer (Fact sheet), 11 Jul 2023.
- [3] CMScaller (Eide et al.)
- [4] de Back et al. 2024.
- [5] <https://rdrr.io/github/peterawe/CMScaller/> (23/12/2025)
- [6] Sirinukunwattana, K. et al. Image-based consensus molecular subtype (imCMS) classification of colorectal cancer using deep learning.
- [7] F. Alharbi and A. Vakanski, “Machine Learning Methods for Cancer Classification Using Gene Expression Data: A Review,” *Bioengineering*, vol. 10, no. 2, pp. 275–295, Feb. 2023. DOI: 10.3390/bioengineering10020275
- [8] NCI Genomic Data Commons (GDC). GDC Data Portal (consulta: 31/12/2025).  
[portal.gdc.cancer.gov](https://portal.gdc.cancer.gov)
- [9] NCI Genomic Data Commons (GDC). Data Types and File Formats (consulta: 31/12/2025).  
[gdc.cancer.gov](https://gdc.cancer.gov)
- [10] NCI Genomic Data Commons (GDC Docs). Bioinformatics Pipeline: mRNA Analysis [(Expression mRNA Pipeline) (consulta: 31/12/2025).  
[docs.gdc.cancer.gov](https://docs.gdc.cancer.gov)

[11] National Cancer Institute (NCI). The Cancer Genome Atlas Program (TCGA) / Using TCGA Data (consulta: 31/12/2025).

[12] <https://github.com/ywutan/CMSFFPE> (31/12/2025)

[13] Law et al., F1000Research (2016, workflow limma/edgeR/voom)

[14] Zhang et al., Nature Communications (2021, NCI GDC)

[15] Kapoor & Narayanan, Patterns (2023, data leakage)

[16] Malcolm, D. G., Roseboom, J. H., Clark, C. E., & Fazar, W. (1959). Application of a Technique for Research and Development Program Evaluation. Operations Research, 7(5), 646–669.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## **\*-11. Annexos**

### **11.1 Entrevista**

#### **11.1.1 Introducció**

Amb l'objectiu de complementar el projecte, des d'una perspectiva pedagògica, s'ha realitzat una entrevista a un perfil de formació en enginyeria biomèdica i ciència de dades aplicada a la salut. L'entrevista té com a finalitat obtenir una visió experta sobre les dificultats en l'aprenentatge automàtic i la bioinformàtica.



*Figura 31. Fotografia corresponent a una sessió d'entrevista.*

#### **11.1.2 Preguntes i respostes**

## APRENENTATGE AUTOMÀTIC APLICAT A BIOINFORMÀTICA

Pregunta 1. Quan intentes aprendre bioinformàtica, quina és la principal dificultat que et trobes al començament?

Resposta. La principal dificultat és la corba d'aprenentatge. Sovint et trobes amb una gran quantitat d'eines que requereixen habilitats de programació i estadística, mentre intentes comprendre la complexitat biològica que hi ha darrere de les dades.

Pregunta 2. Creus que el problema principal és entendre la biologia, les eines informàtiques, o la combinació de totes dues?

Resposta. La combinació de totes dues, ja que són dues branques que s'han d'entendre i coordinar per donar solució a un problema complex. No n'hi ha prou amb saber programar.

Pregunta 3. Les fonts de dades públiques et resulten clares o sovint difícils d'interpretar? Per què?

Resposta. En general, sí que resulten clares, perquè les fonts públiques acostumen a seguir estàndards que faciliten la seva comprensió.

Pregunta 4. Et sembla més fàcil aprendre amb exemples concrets i limitats o amb enfocaments molt generals?

Resposta. Prefereixo exemples concrets. És més fàcil començar amb un cas mínim i, a partir d'aquí, escalar el concepte cap a escenaris més complexos.

Pregunta 5. Creus que treballar amb un sol conjunt de dades ajuda a entendre millor el procés?

Resposta. Depèn de la situació, però en general sí. Treballar amb un conjunt específic permet reduir el nombre de variables a controlar.

Pregunta 6. Et resulta complicat entendre quin tipus de dades necessites per a un anàlisi concret?

Resposta. Amb l'experiència he millorat aquest aspecte, però al principi pot ser complicat.

Pregunta 7. Quan s'aplica aprenentatge automàtic en biomedicina, valories més entendre el funcionament del model o només el resultat final?

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Resposta. Valoro molt entendre el model. Actualment és comú parlar de la “caixa negra”, on s’introdueixen dades i només s’espera el resultat. Això dificulta la interpretació. Eines com Grad-CAMs o Saliency Maps són un bon recurs per intentar entendre aquesta caixa en el deep learning.

Pregunta 8. Consideres útil un projecte que prioritzi la claredat del procés per davant de la complexitat tècnica?

Resposta. Sempre prioritzo la claredat. Prefereixo encarar un projecte simple on pugui defensar i explicar cada pas del procés que no pas un de molt complex on no estic segur dels meus passos.

### **11.1.3 Conclusió**

Les respostes posen en manifest que una de les principals dificultats és la necessitat d’integrar coneixements de biologia, programació i estadística de manera aplicada. Tanmateix, es destaca la importància d’enfocaments pedagògics basats en exemples concrets, conjunts de dades controlats i processos clarament estructurats.

Aquestes aportacions reforcen l’orientació del projecte, que prioritza un pipeline reproduïble, traçable i comprensible. En aquest sentit, l’entrevista valida l’enfocament adoptat i aporta una perspectiva externa alineada amb els objectius del treball.

## **11.2 Prova de reproductibilitat en Windows 10**

### **11.2.1 Introducció**

Amb l’objectiu de complementar la validació tècnica del projecte, s’ha realitzat una prova de reproductibilitat en un entorn Windows 10 diferent de l’entorn principal de desenvolupament. Aquesta prova té com a finalitat comprovar que el projecte es pot preparar, instal·lar i executar correctament seguint el flux definit al repositori.

La prova inclou la verificació de les eines base, la clonació del repositori, la creació de l'entorn Conda, la instal·lació del paquet local, la comprovació de les dependències principals i l'execució de les etapes principals del pipeline.

Aquesta prova no té com a objectiu substituir l'anàlisi de resultats del cos principal de la memòria, sinó aportar evidència complementària sobre la portabilitat i reproductibilitat tècnica del projecte.

## 11.2.2 Entorn utilitzat

La prova s'ha dut a terme en un sistema Windows 10 Pro de 64 bits. La informació del sistema mostra que l'equip utilitzat disposa d'un processador AMD64 i 16.307 MB de memòria física total. El fitxer systeminfo\_windows10.txt també confirma que la versió del sistema operatiu és Microsoft Windows 10 Pro, versió 10.0.19045, compilació 19045.

| Element              | Valor                                                   |
|----------------------|---------------------------------------------------------|
| Sistema Operatiu     | Microsoft Windows 10 Pro                                |
| Versió del sistema   | 10.0.19045                                              |
| Compilació           | 19045                                                   |
| Tipus de sistema     | x64-based PC                                            |
| Processador          | AMD Ryzen 5 3600 6-Core Processor                       |
| Memòria física total | 16.307 MB                                               |
| Directorí de prova   | C:\Users\rivs\Documents\TFG_reproductibilitat_windows10 |

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**





Figura 32. Estructura de la carpeta d'evidències de la prova.



Figura 33. Versió del sistema operatiu Windows 10.




```

Windows PowerShell
PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> Get-ComputerInfo | Select-Object CsProcessors,CsTotalPhysicalMemory,OsName,OsVersion

CsProcessors                                CsTotalPhysicalMemory OsName                                OsVersion
-----
{AMD Ryzen 5 3600 6-Core Processor          } 17099538432 Microsoft Windows 10 Pro 10.0.19045

PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10>
    
```

Figura 34. Informació de CPU, memòria i versió del sistema.



```

Windows PowerShell
PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> Get-ComputerInfo | Select-Object CsProcessors,CsTotalPhysicalMemory,OsName,OsVersion

CsProcessors                                CsTotalPhysicalMemory OsName                                OsVersion
-----
{AMD Ryzen 5 3600 6-Core Processor          } 17099538432 Microsoft Windows 10 Pro 10.0.19045

PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> systeminfo > .\01_sistema\systeminfo_windows10.txt
PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> dir .\01_sistema

Directorio: C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\01_sistema


Mode                LastWriteTime         Length Name
----
-a----          26/05/2026   19:09           28933 01_estructura_carpeta_evidencies.PNG
-a----          26/05/2026   19:12           11366 02_powershell_directori_test.PNG
-a----          26/05/2026   19:13           17884 03_windows_version.PNG
-a----          26/05/2026   19:14           12858 05_computerinfo_cpu_ram.PNG
-a----          26/05/2026   19:15           14348 systeminfo_windows10.txt

PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10>
    
```

Figura 35. Generació del fitxer systeminfo\_windows10.txt.

### 11.2.3 Verificació de les eines base

Abans de preparar el projecte, s'han comprovat les eines necessàries per clonar el repositori, crear l'entorn d'execució i executar el pipeline. Les versions verificades són Conda 26.3.2, Git 2.54.0.windows.1 i Python 3.13.1 en l'entorn base.



```

Windows PowerShell
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> conda --version
conda 26.3.2
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> git --version
git version 2.54.0.windows.1
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> python --version
Python 3.13.13
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10>
    
```


Figura 36. Verificació de les versions de Conda, Git i Python.

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## 11.2.4 Clonació del repositori

Un cop verificades les eines base, s'ha clonat el repositori del projecte dins del directori de prova. Després de la clonació, s'ha executat git status per comprovar l'estat del repositori.

La sortida mostra que la branca local es troba sincronitzada amb origin/main i que no hi ha canvis pendents. Aquesta comprovació és important perquè assegura que la prova s'ha fet sobre una còpia neta del projecte.




```
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> conda --version
conda 26.3.2
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> git --version
git version 2.54.0.windows.1
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> python --version
Python 3.13.13
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> cd "$env:USERPROFILE\Documents\TFG_reproductibilitat_windows10"
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> git clone https://github.com/MartiRiveroGarcia/tcga-oad-cms-ml-pipeline.git projecte
Cloning into 'projecte'...
remote: Enumerating objects: 377, done.
remote: Counting objects: 100% (377/377), done.
remote: Compressing objects: 100% (273/273), done.
remote: Total 377 (delta 125), reused 331 (delta 79), pack-reused 0 (from 0)
Receiving objects: 100% (377/377), 5.73 MiB | 11.20 MiB/s, done.
Resolving deltas: 100% (125/125), done.
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10> cd .\projecte\
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte> git status
On branch main
Your branch is up to date with 'origin/main'.

nothing to commit, working tree clean
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte>
```

Figura 37. Clonació del repositori i comprovació de l'estat amb Git.

## 11.2.5 Creació i activació de l'entorn Conda

La instal·lació de dependències s'ha fet a partir del fitxer environment.yml del projecte. Aquest fitxer defineix l'entorn necessari per executar el pipeline i permet reconstruir-lo de manera controlada en una altra màquina.



```
(base) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte> conda env create -f environment.yml
Do you accept the Terms of Service (ToS) for https://repo.anaconda.com/pkgs/main? [(a)ccept/(r)eject/(v)iew]: a
Do you accept the Terms of Service (ToS) for https://repo.anaconda.com/pkgs/r? [(a)ccept/(r)eject/(v)iew]: a
Do you accept the Terms of Service (ToS) for https://repo.anaconda.com/pkgs/msys2? [(a)ccept/(r)eject/(v)iew]: a
# channel Terms of Service accepted
Retrieving notices: done
Channels:
- conda-forge
- defaults
Platform: win-64
Collecting package metadata (repodata.json): done
Solving environment: done


Downloading and Extracting Packages:
mkl-2026.0.0      109.1 MB ##### 100%
qt6-main-6.11.1   85.4 MB ##### 100%
libclang13-22.1.6 29.1 MB ##### 100%
llvmlite-0.47.0   21.9 MB ##### 100%
python-3.11.15    17.6 MB ##### 100%
scipy-1.17.1      14.6 MB ##### 100%
icu-78.3          14.3 MB ##### 100%
pandas-3.0.3      13.4 MB ##### 100%
statsmodels-0.14.6 11.1 MB ##### 100%
pyside6-6.11.1    11.0 MB ##### 100%
openssl-3.6.2     9.0 MB ##### 100%
scikit-learn-1.8.0 8.7 MB ##### 100%
jupyterlab-4.5.7  8.5 MB ##### 100%
matplotlib-base-3.10 7.6 MB ##### 100%
numpy-2.4.6        7.4 MB ##### 100%
babel-2.18.0       7.3 MB ##### 100%
pywin32-311        6.4 MB ##### 100%
numba-0.65.1       5.6 MB ##### 100%
mkdocs-material-9.7 4.6 MB ##### 100%
libgl1-2.88.1      4.3 MB ##### 100%
debugpy-1.8.20     3.8 MB ##### 100%
tk-8.6.13          3.4 MB ##### 100%
mkdocs-1.6.1       3.4 MB ##### 100%
fonttools-4.63.0   2.5 MB ##### 100%
libhwloc-2.13.0    2.3 MB ##### 100%
font-ttf-ubuntu-0.83 1.5 MB ##### 100%
cairo-1.18.4       1.5 MB ##### 100%
qhull-2020.2       1.3 MB ##### 100%
harfbuzz-14.2.0    1.3 MB ##### 100%
```

Figura 38. Creació de l'entorn Conda a partir de environment.yml.

## 11.2.6 Instal·lació del paquet local i verificació de dependències

Amb l'entorn activat, el projecte s'ha instal·lat en mode editable mitjançant la comanda “Python -m pip install -e .”.

Aquesta instal·lació permet que els scripts del projecte utilitzin els mòduls locals definits al directori src/. Després de la instal·lació, s'ha executat la comanda “Python -m pip check”



```
<tcga-coad-cms-nl-pipeline> PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte> python -m pip install -e .
Obtaining file:///C:/Users/rivs/Documents/TFG_reproductibilitat_windows10/projecte
Installing build dependencies ... done
Checking if build backend supports build_editable ... done
Getting requirements to build editable ... done
Preparing editable metadata (pyproject.toml) ... done
Building wheels for collected packages: tcga-coad-cms-nl-pipeline
Building editable for tcga-coad-cms-nl-pipeline (pyproject.toml) ... done
Created wheel for tcga-coad-cms-nl-pipeline: filename=tcga-coad-cms-nl-pipeline-0.1.0-0.editable-py3-none-any.whl size=3005 sha256=080491ba8200c5a1e052a121c5918e7ab92107e504fc09a3975576938df63e
Stored in directory: C:\Users\rivs\AppData\Local\Temp\pip-ephem-wheel-cache-h47x6lsp\wheels\2d\40\c9\3d9f261e7ace4f571b236bdac2dde00c0ab96768a81987cce82
Successfully built tcga-coad-cms-nl-pipeline
Installing collected packages: tcga-coad-cms-nl-pipeline
Attempting uninstall: tcga-coad-cms-nl-pipeline
Found existing installation: tcga-coad-cms-nl-pipeline 0.1.0
Uninstalling tcga-coad-cms-nl-pipeline-0.1.0:
Successfully uninstalled tcga-coad-cms-nl-pipeline-0.1.0
Successfully installed tcga-coad-cms-nl-pipeline-0.1.0
(tcga-coad-cms-nl-pipeline) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte> python -m pip check
No broken requirements found.
(tcga-coad-cms-nl-pipeline) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte>
```

Figura 39. Instal·lació del paquet local en mode editable i comprovació de dependències.


**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

## 11.2.7 Execució de les etapes principals del pipeline

Un cop preparat l'entorn, s'han executat les etapes principals del pipeline.

La primera etapa correspon a la descàrrega de dades mitjançant l'script `download.py`.

Aquesta etapa descarrega i prepara el client `gdc-client` per a Windows i inicia la descàrrega dels fitxers indicats pel manifest del projecte.



```
Windows PowerShell
(cgga-coad-cms-ml-pipeline) PS C:\Users\rivos\Documents\IFG_reproductibilitat_windows10\projecte> python.exe .\scripts\download.py
[INFO] gdc-client not found. Installing...
[INFO] Platform: Windows x64 (windows_x64)
[INFO] Download: https://gdc.cancer.gov/system/files/public/file/gdc-client_2.3_Windows_x64-py3.8-windows-2019.zip
[INFO] Target dir: C:\Users\rivos\Documents\IFG_reproductibilitat_windows10\projecte\tools\gdc-client\2.3.0\windows_x64
[INFO] Downloading zip...
[OK] MD5 verified.
[INFO] Extracting...
[INFO] Found nested zip: gdc-client_2.3_Windows_x64.zip, extracting...
[OK] Installed: C:\Users\rivos\Documents\IFG_reproductibilitat_windows10\projecte\tools\gdc-client\2.3.0\windows_x64\gdc-client.exe
[INFO] Running: C:\Users\rivos\Documents\IFG_reproductibilitat_windows10\projecte\tools\gdc-client\2.3.0\windows_x64\gdc-client.exe downlo
ad -m C:\Users\rivos\Documents\IFG_reproductibilitat_windows10\projecte\data\metadata\gdc_manifest.2026-03-09.191818.txt -d C:\Users\rivos\
Documents\IFG_reproductibilitat_windows10\projecte\data\raw\gdc
100% [#####] Time: 0:00:03 1.1 MiB/s
0% [ ] 1 ETA: --:--:-- 0.0 s/B
```

Figura 40. Execució de l'etapa de descàrrega de dades.

La segona etapa correspon al preprocessament.

La sortida mostra la lectura dels fitxers de comptatge, la integració de les etiquetes CMS, la separació train/test i la generació de les matrius preprocessades.

## APRENENTATGE AUTOMÀTIC APLICAT A BIOINFORMÀTICA

```
Selecció Windows PowerShell
(tcga-coad-cms-ml-pipeline) PS C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte> python.exe .\scripts\preprocess.py
21:14:27 INFO1 === TCGA-COAD Preprocessing Pipeline ===
21:14:27 INFO1 Sample sheet loaded: 483 rows from gdc_sample_sheet.2026-03-09.tsv
21:14:27 INFO1 CMS file: 573 TCGA samples total
21:14:27 INFO1 CMS labels: 512 with valid label (dropped 61 NOLBL/UNK)
21:14:33 INFO1 Loaded 50 / 483 files...
21:14:38 INFO1 Loaded 100 / 483 files...
21:14:44 INFO1 Loaded 150 / 483 files...
21:14:50 INFO1 Loaded 200 / 483 files...
21:14:55 INFO1 Loaded 250 / 483 files...
21:15:01 INFO1 Loaded 300 / 483 files...
21:15:07 INFO1 Loaded 350 / 483 files...
21:15:13 INFO1 Loaded 400 / 483 files...
21:15:21 INFO1 Loaded 450 / 483 files...
21:15:31 INFO1 Expression matrix built: 60664 genes x 483 files
21:15:32 INFO1 Removed 4 QC rows (N_unmapped, etc.)
21:15:32 INFO1 Protein-coding filter: 60660 -> 19962 genes (removed 40698)
21:15:32 INFO1 FPPE samples removed: 13
21:15:32 INFO1 Non-primary samples removed: 2
21:15:32 INFO1 Duplicate files resolved: 10 (kept highest depth)
21:15:32 INFO1 After deduplication: 458 samples
21:15:32 INFO1 CMS label join: 458 -> 370 samples (dropped 88 without label)
21:15:32 INFO1 CMS distribution: ('CMS2': 145, 'CMS4': 100, 'CMS1': 71, 'CMS3': 54)
21:15:35 INFO1 Train/test split: 296 train, 74 test (seed=42)
21:15:35 INFO1 Train CMS distribution: ('CMS2': 116, 'CMS4': 80, 'CMS1': 57, 'CMS3': 43)
21:15:35 INFO1 Test CMS distribution: ('CMS2': 29, 'CMS4': 20, 'CMS1': 14, 'CMS3': 11)
21:15:35 INFO1 Minimal dataset captured: 296 samples x 19962 genes (pre-filter, pre-log2)
21:15:39 INFO1 Low-count gene filter (count>=10 in >=20% of train): 19962 -> 15625 genes (removed 4337)
21:15:43 INFO1 Log2(x+1) transform applied. Value range: [0.00, 20.71]
21:17:05 INFO1 Saved processed data to C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\processed (7 files)
21:17:05 INFO1 Full dataset saved - 296 samples x 15625 genes (post-filter, log2-transformed)
21:17:05 INFO1 - Saving minimal dataset
21:17:07 INFO1 (minimal) All validation checks passed.
21:18:14 INFO1 (minimal) Saved 5 files to C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\processed - X_train: (29
6, 19962) (19962 genes), X_test: (74, 19962)
21:20:21 INFO1 == Preprocessing complete ==
21:20:21 INFO1 Output: C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\processed
21:20:21 INFO1 Full - Train: 296 samples x 15625 genes
21:20:21 INFO1 Minimal - Train: 296 samples x 19962 genes
(tcga-coad-cms-ml-pipeline) PS C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte>
```

Figura 41. Execució de l'etapa de preprocessament.

La tercera etapa correspon a l'entrenament dels models.

Aquesta etapa carrega les dades preprocessades, entrena els models definits al projecte i desa els fitxers .joblib corresponents. La sortida mostra l'entrenament de Logistic Regression, Random Forest i SVM, així com la generació dels models desats al directori data\models.

```
Windows PowerShell
(tcga-coad-cms-ml-pipeline) PS C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte> python.exe .\scripts\train.py
21:20:37 INFO1 -- Stage 4: Model training
21:20:37 INFO1 processed-dir : C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\processed
21:20:37 INFO1 output-dir : C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\models
21:20:37 INFO1 results-dir : C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\results
21:20:37 INFO1 models : logistic_regression, random_forest, svm
21:20:37 INFO1 random seed : 42
21:20:37 INFO1 Loading processed data from C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\processed (suffix='none')
21:20:39 INFO1 Loaded - X_train: (296, 15625), X_test: (74, 15625), y_train: (296,), y_test: (74,)
21:20:39 INFO1 Full dataset loaded: 296 samples x 15625 genes
21:20:39 INFO1 CMS distribution in train: ('CMS1': 57, 'CMS2': 116, 'CMS3': 43, 'CMS4': 80)
21:20:39 INFO1 Training logistic_regression ...
21:20:41 INFO1 logistic_regression - train accuracy: 1.0000, time: 1.3 s
21:20:41 INFO1 Model saved to C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\models\logistic_regression.joblib
21:20:41 INFO1 Training random_forest ...
21:20:42 INFO1 random_forest - train accuracy: 1.0000, time: 1.1 s
21:20:42 INFO1 Model saved to C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\models\random_forest.joblib
21:20:42 INFO1 Training svm ...
21:20:43 INFO1 svm - train accuracy: 1.0000, time: 0.8 s
21:20:43 INFO1 Model saved to C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\models\svm.joblib
21:20:43 INFO1 -- Training unbalanced variants (class_weight=None) --
21:20:43 INFO1 Training logistic_regression (unbalanced) ...
21:20:45 INFO1 logistic_regression (unbalanced) - train accuracy: 1.0000, time: 1.5 s
21:20:45 INFO1 Model saved to C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\models\logistic_regression_unbalanced.joblib
21:20:45 INFO1 Training random_forest (unbalanced) ...
21:20:46 INFO1 random_forest (unbalanced) - train accuracy: 1.0000, time: 1.0 s
21:20:46 INFO1 Model saved to C:\Users\rius\Documents\TFG_reproductibilitat_windows10\projecte\data\models\random_forest_unbalanced.joblib
21:20:46 INFO1 Training svm (unbalanced) ...
21:20:48 INFO1 svm (unbalanced) - train accuracy: 1.0000, time: 0.8 s
```


Figura 42. Execució de l'etapa d'entrenament dels models.

La quarta etapa correspon a l'avaluació dels models entrenats.

Aquest script carrega les dades preprocessades del conjunt de test i els models desats prèviament al directori data\models. A continuació, calcula les mètriques d'avaluació per a

**Error! Utilitzeu la pestanya  
Inici per aplicar Heading 1  
al text que voleu que  
aparegui aquí.**

Logistic Regression, Random Forest i SVM lineal, genera les figures de resultats i desa l'informe final al directori results.



```
(tcga-coad-cms-ml-pipeline) PS C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte> python.exe .\scripts\evaluate.py
14:49:53 [INFO] — Stage 5: Model evaluation
14:49:53 [INFO] processed-dir : C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\data\processed
14:49:53 [INFO] models-dir : C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\data\models
14:49:53 [INFO] output-dir : C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\results
14:49:53 [INFO] figures-dir : C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures
14:49:53 [INFO] Loading processed data from C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\data\processed (suffix='n
one')
14:49:55 [INFO] Loaded - X_train: (296, 15625), X_test: (74, 15625), y_train: (296,), y_test: (74,)
14:49:55 [INFO] Test set - 74 samples x 15625 genes, classes: ['CMS1', 'CMS2', 'CMS3', 'CMS4']
14:49:55 [INFO] Loaded logistic_regression from C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\data\models\logistic_
regression.joblib
14:49:56 [INFO] Loaded random_forest from C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\data\models\random_forest.j
oblib
14:49:56 [INFO] Loaded svm from C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\data\models\svm.joblib
14:49:56 [INFO] Evaluating logistic_regression ...
14:49:57 [INFO] logistic_regression accuracy=0.9459 F1_macro=0.9428 F1_weighted=0.9453
14:49:57 [INFO] Evaluating random_forest ...
14:49:57 [INFO] random_forest accuracy=0.8514 F1_macro=0.8245 F1_weighted=0.8438
14:49:57 [INFO] Evaluating svm ...
14:49:57 [INFO] svm accuracy=0.9595 F1_macro=0.9540 F1_weighted=0.9594
14:49:58 [INFO] Confusion matrix saved to C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\confusion_matrix_lo
gistic_regression.png
14:49:58 [INFO] Confusion matrix saved: C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\confusion_matrix_logi
stic_regression.png
14:49:58 [INFO] Confusion matrix saved to C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\confusion_matrix_ra
ndom_forest.png
14:49:58 [INFO] Confusion matrix saved: C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\confusion_matrix_rand
om_forest.png
14:49:58 [INFO] Confusion matrix saved to C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\confusion_matrix_sv
m.png
14:49:58 [INFO] Confusion matrix saved: C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\confusion_matrix_svm.
png
14:49:59 [INFO] Metrics comparison saved to C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\metrics_compariso
n.png
14:49:59 [INFO] Metrics comparison saved: C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\metrics_comparison.
png
14:49:59 [INFO] F1 per class saved to C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\f1_per_class.png
14:49:59 [INFO] F1 per class saved: C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\figures\f1_per_class.png
14:49:59 [INFO] Benchmark table:
Benchmark table:
      Accuracy  F1 macro  F1 weighted  F1 CMS1  F1 CMS2  F1 CMS3  F1 CMS4
Model
Logistic Regression  0.945946  0.942825  0.945332  0.9333  0.9667  0.9524  0.9189
Random Forest      0.851351  0.824548  0.843806  0.8667  0.8923  0.7059  0.8333
SVM (linear)       0.959459  0.954033  0.959442  0.9333  0.9831  0.9524  0.9474
14:49:59 [INFO] Evaluation report saved to C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\results\evaluation_report.
json
14:49:59 [INFO] Evaluation report saved: C:\Users\rivs\Documents\TFG_reproductibilitat_windows10\projecte\results\evaluation_report.js
on
```

Figura 43. Execució de l'etapa d'avaluació.

## 11.2.8 Conclusió

La prova confirma que el projecte es pot preparar i executar en un entorn Windows 10 partint d'un repositori clonat des de GitHub. Les evidències recollides mostren que les eines base estan disponibles, que el repositori es clona correctament, que l'entorn Conda es crea a partir de environment.yml, que el paquet local s'instal·la correctament i que les llibreries principals es poden importar dins de l'entorn.

També queda documentada l'execució completa de les quatre etapes principals del pipeline: descàrrega, preprocessament, entrenament i avaluació. L'etapa final d'avaluació genera les mètriques dels models, les matrius de confusió, les figures comparatives i l'informe final de resultats.

Aquest resultat reforça la reproductibilitat tècnica del projecte, ja que demostra que el flux principal pot executar-se en un entorn Windows 10 diferent de l'entorn original de desenvolupament. A més, les mètriques obtingudes en aquesta execució coincideixen amb les utilitzades en l'anàlisi final del projecte, fet que dona suport a la consistència de l'execució del pipeline.