

Aprenentatge automàtic aplicat a bioinformàtica


*Pipeline reproducible per a la classificació CMS
del càncer colorectal amb dades RNA-seq*

Autor: Martí Rivero Garcia

Tutor: Carles Bonet Papell

Grau: Grau en Enginyeria Informàtica de Gestió i Sistemes d'Informació

Curs: 2025–2026



Índex

01

Problema

02

Objectius
i abast

03

Metodologia

04

Pipeline

05

Dades

06

Models

07

Resultats

08

Reproductibilitat

09

Conclusions

Problema que resol

Del diagnòstic anatòmic i histològic a una tasca computacional

Diagnòstic clàssic

Anatomia i histologia
del tumor



Guinney et al. (2015)

Dades transcriptòmiques
Subtipus CMS1–CMS4



Problema computacional

Classificar mostres RNA-seq
quin subtipus CMS?

Per què calen models de machine learning?

Les dades RNA-seq generen un perfil d'expressió amb milers de gens per mostra. Processar-les i classificar-les automàticament de manera traçable i reproduïble requereix un enfocament computacional estructurat.

Objectiu i abast

TCGA-COAD · RNA-seq processat · 3 models supervisats

Objectiu principal

Desenvolupar un flux reproduïble per classificar mostres TCGA-COAD en subtipus CMS a partir de dades RNA-seq, comparant tres models supervisats sota condicions homogènies.

Cohort

TCGA-COAD — RNA-seq processat (GDC)

Models

Logistic Regression · SVM lineal · Random Forest

Avaluació


Accuracy, F1 macro, F1 per classe, matrius de confusió

Lliurables


Scripts, notebooks, mètriques i documentació

Metodologia

Fase en cascada



Fase iterativa




Tasques transversals

- Documentació, reproductibilitat contingut didàctic

Les dues fases es combinen per mantenir una estructura clara i adaptar-se al comportament real de les dades.

Pipeline



Estructura modular: cada etapa s'executa, revisa i documenta per separat → traçabilitat completa.

Pipeline

Contingut didàctic i documentació

Contingut didactic - Notebooks



Data_exploration.ipynb



Model_analysis.ipynb



Results_exploration.ipynb

Documentació – GitHub Pages

- Inici
- Execució
- Dades i pipeline
- Experiments i resultats
- Reproductibilitat i referència
- Glossari

Conjunt de dades

Dades processades obtingudes a través del Genomic Data Commons

GDC

Genomic Data Commons

TCGA-COAD

Cohort seleccionada

RNA-seq

Dades ja processades

Synapse

Etiquetes CMS

Unitat d'anàlisi

Mostra tumoral individual

Entrada del model

Perfil d'expressió gènica (RNA-seq)

Variable a predir

Subtipus CMS1–CMS4

Motiu de dades processades

Dades públiques, documentades i adequades per a una anàlisi reproducible amb RNA-seq processat

Conjunt de dades

De fitxers RNA-seq a matriu final per entrenar models

370

mostres etiquetades

296 / 74

train / test

8

Transformacions aplicades

15.625


variables/gens finals

- 0 **Integrar els fitxers** RNA-seq en una matriu única amb les etiquetes CMS
- 1 **Eliminar files** de control de qualitat (unstranded protocol)
- 2 **Filtrar gens** protein-coding
- 3 **Eiminar mostres duplicades**
- 4 Apicar **transformació $\log_2(x+1)$**
- 5 **Dividir** les dades: 296 mostres **d'entrenament** i 74 de **test**


Conjunt de dades

Efecte de la transformació $\log_2(x+1)$

Distribució post-transformació ($\log_2$)




Distribució pre-transformació (FPKM)




Conjunt de dades

Llindar de gens amb baixa expressió



Conjunt de dades

Distribució de conjunt d'entrenament per CMS1-4



Models de classificació

Logistic Regression

Lineal — probabilístic

Estima la probabilitat de pertànyer a cada classe CMS. Frontera de decisió lineal i coeficients associats a les variables.

SVM lineal

Lineal — basat en marge

Busca l'hiperplà que maximitza el marge entre classes. Útil per contrastar un enfocament lineal en dades d'alta dimensionalitat.

Random Forest

No lineal — basat en arbres





Ensemble de múltiples arbres de decisió. Pot capturar patrons no lineals entre variables.

Dos models lineals + un no lineal → contrast d'enfocaments sota les mateixes condicions.

Conjunt de dades

Gens per importància - LR





Regressió Logística — Top 10 gens per coeficient positiu (per classe)



Conjunt de dades


Gens per importància SVM lineal

SVM lineal — Top 10 gens per coeficient positiu (per classe OvR)



Conjunt de dades

Gens per importància RF



Avaluació dels models

Mateixes dades, mateix split i mateixes mètriques

Hipòtesis

- 1 Comparar Logistic Regression amb Random Forest
- 2 Comparar SVM lineal amb Random Forest
- 3 Avaluar equivalència pràctica entre Logistic Regression i SVM lineal
- 4 Avaluar si CMS3 és més difícil que la resta de subtipus
- 5 Avaluar l'impacte del preprocessament complet

Mètriques d'avaluació

Accuracy

Proporció de mostres ben classificades

F1 macro

Igual pes a cada subtipus CMS

F1 per classe

Rendiment específic per CMS1–4

Matriu de confusió


Distribució detallada dels errors

L'accuracy sola no és suficient: les classes CMS no tenen el mateix nombre de mostres → el F1 macro dona el mateix pes a cada classe.

Mètriques

Accuracy i F1 macro


SVM lineal obté el millor rendiment en el conjunt de test, seguit molt de prop per Logistic Regression.



Mètriques

Comparació del F1-score per CMS1–CMS4


En aquest experiment, SVM lineal i Logistic Regression obtenen millor rendiment en el conjunt de test que Random Forest.




Random Forest baixa especialment en CMS3 (F1 = 0,71). Els models lineals mantenen un rendiment més equilibrat entre CMS1–CMS4.

Mètriques


Matriu de confusió



Logistic Regression



Random Forest



SVM lineal

SVM classifica correctament 71/74 mostres · Logistic Regression 70/74 · Random Forest 63/74

Mètodes de contrast de les hipòtesis

Bootstrap

2000 remostrejos · IC 95%

IC > 0 diferència positiva consistent

IC inclou 0: resultat no concloent

IC < 0: diferència negativa consistent

McNemar

Llindar de significació: $\alpha = 0,05$

$p < 0,05$: es rebutja H_0

$p \geq 0,05$: no es pot rebutjar H_0

Avaluació d'hipòtesi

H1- Comparar Logistic Regression amb Random Forest

Formulació

Comparar Logistic Regression amb Random Forest

$$H_0 \rightarrow \Delta LR - RF < 0$$

$$H_a \rightarrow \Delta LR - RF \geq 0$$

$$\Delta_{LR-RF} = F1_{macro,LR} - F1_{macro,RF}$$

$$F1_{macro,RF} = 0,8245$$

$$F1_{macro,LR} = 0,9428$$


$$\Delta_{LR-RF} = 0,9428 - 0,8245$$

$$\Delta_{LR-RF} = 0,1183$$

$$IC\ 95\% \text{ bootstrap } [0.0444, 0.2159]$$

$$McNemar: p = 0.007812$$

Comparativa de models: Accuracy i F1 macro (test set)



Resolució: Es rebutja H_0 a favor d' H_a .

Logistic Regression supera Random Forest en F1 macro de manera consistent dins d'aquest experiment.

Avaluació d'hipòtesi

H2- Comparar SVM lineal amb Random Forest

Formulació

Comparar SVM lineal amb Random Forest

$$H_0 \rightarrow \Delta_{SVM - RF} < 0$$

$$H_a \rightarrow \Delta_{SVM - RF} \geq 0$$

$$\Delta_{SVM-RF} = F1_{macro,SVM} - F1_{macro,RF}$$

$$F1_{macro,RF} = 0,8245$$

$$F1_{macro,SVM} = 0,9540$$


$$\Delta_{SVM-RF} = 0,9540 - 0,8245$$

$$\Delta_{SVM-RF} = 0,1295$$

$$IC\ 95\%\ bootstrap\ [0.0517, 0.2288]$$

$$McNemar: p = 0.003906$$

Comparativa de models: Accuracy i F1 macro (test set)



Resolució: Es rebutja H_0 a favor d' H_a .

SVM lineal supera Random Forest en F1 macro de manera consistent dins d'aquest experiment.

Avaluació d'hipòtesi

H3- Equivalència entre Logistic Regression i SVM lineal

Formulació


Equivalència entre Logistic Regression i SVM lineal

Marge d'equivalència: $\varepsilon = 0,02$

$$H_0 \rightarrow |\Delta LR - SVM| \geq \varepsilon$$

$$H_a \rightarrow |\Delta LR - SVM| < \varepsilon$$

Comparativa de models: Accuracy i F1 macro (test set)



$$\Delta_{SVM-LR} = F1_{macro,SVM} - F1_{macro,LR}$$

$$F1_{macro,LR} = 0,9428$$

$$F1_{macro,SVM} = 0,9540$$

$$\Delta_{SVM-LR} = 0,9540 - 0,9428$$

$$\Delta_{SVM-LR} = 0,0112$$

$$IC\ 95\% \text{ bootstrap } [0.0405, 0.0000]$$

$$McNemar: p = 0.003906$$

Resolució: No es pot rebutjar H_0 .

No es pot demostrar equivalència pràctica entre Logistic Regression i SVM lineal.

Avaluació d'hipòtesi

H4- CMS3 és el subtipus més difícil de classificar?

Formulació

CMS3 és el subtipus més difícil de classificar?

$$\Delta_{CMS3} = F1_{CMS3} - \text{mitjana}(F1_{CMS1}, F1_{CMS2}, F1_{CMS4})$$

$$H_0 \rightarrow \Delta_{CMS3} \geq 0$$

$$H_a \rightarrow \Delta_{CMS3} < 0$$

$$\Delta_{CMS3}_{LR} = +0.0127$$


$$IC\ 95\%_{LR} = [-0.1053, 0.0991]$$

$$\Delta_{CMS3}_{RF} = -0.1582$$

$$IC\ 95\%_{RF} = [-0.4656, 0.0450]$$

$$\Delta_{CMS3}_{SVM} = -0.0022$$

$$IC\ 95\%_{SVM} = [-0.1179, 0.0768]$$



Resolució: No es pot rebutjar H_0 .

CMS3 no queda demostrat com el subtipus més difícil de classificar.

Avaluació d'hipòtesi

H5- Impacte del preprocessament

Formulació

Impacte del preprocessament

$$\Delta_{full-minimal} = F1_{macro,full} - F1_{macro,minimal}$$

$$H_0 \rightarrow \Delta_{full-minimal} \leq 0$$

$$H_a \rightarrow \Delta_{full-minimal} > 0$$

$$\Delta_{full-minimal}_{LR} = +0.0885$$

$$IC\ 95\%_{LR} = [-0.0014, 0.1883]$$

$$McNemar\ p_{LR} = 0,054688$$

$$\Delta_{full-minimal}_{RF} = +0.0026$$

$$IC\ 95\%_{RF} = [-0.0609, 0.0508]$$

$$McNemar\ p_{RF} = 0,50000$$

$$\Delta_{full-minimal}_{SVM} = +0.1514$$

$$IC\ 95\%_{SVM} = [0.0523, 0.2631]$$

$$McNemar\ p_{SVM} = 0,003693$$

Resolució: Es rebutja H_0 .

El preprocessament complet millora de manera consistent

Mesures de reproductibilitat i traçabilitat

Entorn

- Conda + environment.yml
- Dependències definides a l'entorn

Codi

- Versionat a GitHub
- Scripts per etapa (descàrrega, preprocessament, entrenament, avaluació)
- Notebooks documentats

Experiment

- Mateixa matriu per als 3 models
- Llavors fixades
- Partició train/test fixada

El repositori documenta els passos per reconstruir l'entorn, executar el flux i obtenir els resultats a partir de les dades especificades.

Conclusions

01

Flux complet i traçable per classificar subtipus CMS a partir de dades RNA-seq de TCGA-COAD.

02

Els resultats depenen tant del model escollit com de les decisions de preprocessament i del disseny experimental.

03

Els notebooks i la documentació converteixen el pipeline en un recurs didàctic pràctic, reproduïble i fàcil de seguir.

Aprenentatge automàtic aplicat a bioinformàtica

*Pipeline reproduïble per a la classificació CMS
del càncer colorectal amb dades RNA-seq*

Quasevol dubte, resto a la vostra disposició.

